Universidad Francisco de Vitoria

UFV Madrid

# TRABAJO DE FIN DE GRADO

PREDICCIÓN DE PRECIOS EN ACTIVOS DEL S&P 500 MEDIANTE TRANSFER LEARNING: UNA APROXIMACIÓN CON REDES NEURONALES PARA ENTORNOS CON DATOS ESCASOS

*S&P500 asset price prediction using Transfer Learning: a neural network approach for data-poor environments*

**Resumen**

Este trabajo desarrolla un sistema automatizado para la predicción del precio de acciones individuales del índice S&P 500, utilizando *Transfer Learning* y modelos de *Long Short-Term Memory* (LSTM) y *Gated Recurrent Unit* (GRU). Se evalúa si un modelo generalizado, preentrenado con un amplio conjunto de datos del S&P 500, mejora la precisión predictiva al aplicarse a empresas con datos históricos limitados, como Tesla y Uber. Para ello, se transfiere conocimiento desde el modelo preentrenado y se incorporan variables externas, como el análisis de sentimiento basado en noticias económicas. El sistema diversas particiones de datos y horizontes temporales, comparando modelos LSTM y GRU puros con aquellos que emplean *Transfer Learning*, analizando su impacto en la precisión predictiva, especialmente en los primeros períodos de disponibilidad de datos. Se realiza un backtesting en Uber, Apple y Planet Fitness para validar su eficacia, y entender la limitación de la tesis planteada. Los resultados obtenidos sugieren que el *Transfer Learning* mejora la precisión de las predicciones en los primeros años con datos limitados.

**Palabras clave:** Transfer Learning; LSTM; GRU; predicción de acciones; S&P 500; análisis de sentimiento; rentabilidad estimada; datos limitados; backtesting.

**Abstract**

This paper develops an automated system for individual stock price prediction of the S&P 500 index using Transfer Learning and Long Short-Term Memory (LSTM) and Gated Recurrent Unit (GRU) models. We evaluate whether a generalized model, pre-trained with a large dataset of the S&P 500, improves predictive accuracy when applied to companies with limited historical data, such as Tesla and Uber. To do this, knowledge is transferred from the pre-trained model and external variables, such as sentiment analysis based on economic news, are incorporated. The system various data partitions and time horizons, comparing pure LSTM and GRU models with those employing Transfer Learning, analyzing their impact on predictive accuracy, especially in the early periods of data availability. Backtesting is performed on Uber, Apple and Planet Fitness to validate its effectiveness, and to understand the limitation of the thesis. The results obtained suggest that Transfer Learning improves predictive accuracy in the early years with limited data.

**Key words:** Transfer Learning; LSTM; GRU; stock prediction; S&P 500; sentiment analysis; estimated return; limited data; back testing.

## Agradecimientos

# ÍNDICE

Índice de Figuras ..... iii
Índice de Tablas ..... iii
1. INTRODUCCIÓN ..... 1
1.1. Motivación y origen ..... 2
1.2. Análisis del Problema ..... 2
2. OBJETIVOS ..... 3
2.1. Objetivo General ..... 3
2.2. Objetivos Específicos ..... 3
3. ESTUDIO BIBLIOGRÁFICO ..... 4
3.1. Estado del arte ..... 4
3.2. Marco teórico ..... 8
3.2.1. Redes Neuronales Recurrentes ..... 8
3.2.2. Long Short-Term Memory (LSTM) ..... 8
3.2.3. Gated Recurrent Network (GRU) ..... 9
3.2.4. Transfer Learning ..... 10
4. INGENIERÍA DEL DATO ..... 11
4.1. Herramientas utilizadas: Justificación y descripción ..... 11
4.2. Tratamiento de Datos: S&P 500 ..... 12
4.2.1. Origen y Extracción de los Datos ..... 12
4.2.2. Transformación y Cálculo de Indicadores Técnicos ..... 13
4.2.3. Limpieza: Tratamiento de valores faltantes y nulos ..... 14
4.2.4. Análisis Descriptivo y Exploratorio ..... 15
4.2.5. Estacionariedad del precio de apertura S&P500 Stock ..... 20
4.3. Tratamiento de Datos: Tesla, Uber, Apple y Planet Fitness ..... 23
4.3.1. Extracción y Transformación de los datos ..... 23
4.3.2. Análisis Descriptivo y Exploratorio ..... 24
4.3.3. Estudio de estacionariedad ..... 26
5. ANÁLISIS DEL DATO ..... 28
5.1. Contextualización del Problema y Estrategia ..... 28
5.1.1. Plan de Acción ..... 28
5.1.2. Preparación del Entorno ..... 29
5.2. Exploración preliminar: primeros modelos ..... 30

5.2.1. Comparación Redes Neuronales en datos financieros: GRU y LSTM ..... 30
5.2.2. Redes Neuronales y Transfer Learning: Tesla ..... 32
5.3. Estrategia de ajuste de hiperparámetros dinámica ..... 33
5.3.1. Formulación de la Estrategia para Tesla ..... 33
5.3.2. Resultados de la Estrategia: Modelos Óptimos..... 35
5.4. Backtesting de la estrategia: UBER. ..... 38
5.5. Backtesting de hipótesis: Apple y Planet Fitness..... 42
5.6. Resumen de Resultados ..... 46
6. ANÁLISIS DE NEGOCIO..... 47
6.1. Presentación de la propuesta ..... 47
6.2. Modelo de Negocio..... 49
6.3. Respuesta a los Objetivos ..... 50
6.4. Recomendaciones y Limitaciones..... 51
7. CONCLUSIONES GENERALES DEL TRABAJO..... 53
8. REFENCIAS BIBLIOGRÁFICAS..... 54
9. ANEXO ..... 56

## ÍNDICE DE FIGURAS

Ilustración 1. Evolución Rendimientos Diario, Mensual y Anual S&P500. 16
Ilustración 2. Histogramas de retornos a corto, medio y largo plazo. 17
Ilustración 3. Correlación entre el Open del S&P500 y el resto de las variables. 17
Ilustración 4. Correlación entre el News Sentiment Index y el resto de las variables. 18
Ilustración 5. Evolución Volatilidad (ATR) y Sentimiento Económico en el tiempo. 20
Ilustración 6. Evolución del precio de Apertura del S&P500. 21
Ilustración 7. Evolución temporal precio de apertura Tesla Stock. 24
Ilustración 8. Histogramas y serie análisis temporal de los rendimientos Tesla 25
Ilustración 9. Estudio correlación entre precio de Tesla y resto de variables. 26
Ilustración 10. FAC y FACP de Tesla Stock. 27
Ilustración 11. Maquetación modelo con *Transfer Learning* 32
Ilustración 12. Correlación entre el tamaño de datos de entrenamiento y mejoría con TL 32
Ilustración 13. Predicciones Modelo GRU para Tesla (2012) 36
Ilustración 14. Evolución MAPE de modelos con y sin *Transfer Learning* (Tesla) 37
Ilustración 15. Relación entre años de datos y mejora porcentual del MAPE (TL - s/TL) 38
Ilustración 16. Predicciones Modelo GRU para Uber (2021) 39
Ilustración 17. Predicciones Modelo GRU para Uber (2022) 40
Ilustración 18. Predicciones Modelo GRU para Uber (2023) 40
Ilustración 19. Análisis de Volatilidad (ATR) anual 41
Ilustración 20. Resumen resultados estrategia hiperparámetros: Uber 41
Ilustración 21. Estudio Error Modelos Apple Con vs. Sin Transfer Learning. 43
Ilustración 22. Estudio Error Modelos Planet Fitness Con vs. Sin Transfer Learning. 44
Ilustración 24. Resumen mejora promedio por empresa con Transfer Learning. 45
Ilustración 24. Correlación precios de acciones con respecto al S&P500. 45
Ilustración 25. Síntesis MAPE promedio por Empresa (Con vs. Sin *Transfer Learning*). 46
Ilustración 26. Heatmap: Efectividad del *Transfer Learning* por empresa y año. 47

## ÍNDICE DE TABLAS

Tabla 1. Resumen de valores faltantes post-merge de ficheros 15
Tabla 2. Análisis descriptivo de las principales variables 16
Tabla 3. Resumen variables y tipología post-tratamiento S&P500. 22
Tabla 4. Resumen descriptivo principales variables TESLA Stock. 23
Tabla 5. Resumen resultante variables post-ETL Tesla Stock. 27
Tabla 6. Rendimiento GRU vs LSTM (MAPE) 31
Tabla 7. Compilación métricas de error modelos Tesla 36

# 1. INTRODUCCIÓN

Los datos nos hablan del presente, del pasado y del futuro. Cuentan historias, revelan patrones invisibles y transmiten realidades profundas. Son, en definitiva, la clave para comprender el mundo en que vivimos y para tomar decisiones informadas en un entorno cada vez más complejo.

Con el creciente uso de tecnologías avanzadas como el Deep Learning y la inteligencia artificial, el trading cuantitativo se ha consolidado como una de las estrategias más eficaces para maximizar los retornos en los mercados financieros. Este enfoque se basa en la capacidad de los algoritmos para detectar estructuras ocultas en grandes volúmenes de datos y anticipar movimientos del mercado, facilitando así decisiones de inversión más rápidas, precisas y objetivas. Sin embargo, esta revolución tecnológica también plantea nuevos desafíos: a medida que se generaliza su adopción, surge la necesidad de diseñar modelos cada vez más sofisticados que logren un equilibrio entre precisión, capacidad de generalización, eficiencia computacional y adaptabilidad ante escenarios volátiles.

En este contexto, el índice S&P 500 (que agrupa a las 500 empresas más representativas del mercado estadounidense) se consolida como un barómetro esencial de la economía global. Compuesto por compañías líderes de sectores como tecnología, salud, energía y consumo, no solo refleja el pulso económico de Estados Unidos, sino que también influye directamente en los flujos de capital internacionales. Además, su amplio historial de datos lo convierte en un entorno destacable para entrenar modelos de predicción financiera.

Pero en la práctica, la clave para una inversión sólida y sostenible en el largo plazo no está solo en el análisis de datos abundantes, sino en la capacidad de anticiparse cuando esa información aún no existe. ¿Cómo invertir con criterio cuando los datos históricos son escasos? En un mundo globalizado y tecnológico donde cada año emergen nuevas empresas, activos y oportunidades, esta pregunta se vuelve urgente. Deming afirmaba que "*sin datos, lo que tenemos son opiniones*"; y en decisiones de inversión, las opiniones sin datos y análisis auguran fracaso, asimilándose al juego.

Si asumimos que existe una correlación significativa entre ciertos activos financieros, y que dicha relación es reflejo de patrones comunes, ¿es posible reutilizar modelos entrenados con información de activos consolidados para mejorar la predicción en nuevos activos aún en etapas iniciales?

## 1.1. Motivación y origen

El mercado financiero no está compuesto únicamente por grandes corporaciones consolidadas. Cada vez es más común encontrar nuevas empresas, muchas de ellas tecnológicas o disruptivas, que ingresan al mercado sin un historial de datos suficiente. En estos casos, desarrollar modelos predictivos confiables se vuelve particularmente desafiante. La escasez de datos históricos puede limitar la eficacia de los modelos tradicionales de aprendizaje supervisado, generando un problema real para los inversores que deseen anticiparse al crecimiento de estas compañías emergentes.

De esta necesidad surge la motivación principal de este trabajo: explorar el potencial del aprendizaje por transferencia (Transfer Learning) como solución al problema de la escasez de datos en activos específicos: esto debido a que el verdadero potencial de una empresa está en los primeros años de existencia. Es ahí donde recaen los mayores retornos, a quienes son capaces de prever los comportamientos del mercado desde su IPO o fechas posteriores pero cercanas.

Se buscará evaluar si los patrones aprendidos a partir de activos consolidados, como el S&P 500, pueden ser útiles para mejorar la capacidad predictiva de redes neuronales aplicadas a empresas con historiales limitados, pero estrechamente relacionadas. Se basa en el supuesto de que existen similitudes estructurales y patrones comunes en el comportamiento de los precios financieros, incluso entre activos en apariencia distintos, lo cual puede ser aprovechado por arquitecturas como las redes LSTM y GRU.

La intención inicial del proyecto ha evolucionado hacia esta línea al detectar que, más allá del desarrollo de modelos predictivos puros, existe un valor estratégico en diseñar soluciones que permitan generalizar conocimiento en ausencia de datos extensos. Esta motivación, por tanto, no responde únicamente al interés técnico, sino también a la necesidad de innovar en la forma en que se toman decisiones de inversión en entornos complejos, dinámicos y poco explorados.

## 1.2. Análisis del Problema

El *Transfer Learning* es una técnica ampliamente utilizada en el ámbito del análisis de datos y el aprendizaje automático, especialmente valorada por su capacidad para reducir los costes computacionales asociados al reentrenamiento de modelos y por permitir reutilizar el conocimiento adquirido por modelos robustos en tareas nuevas, pero relacionadas. Aunque existen diversas aplicaciones que emplean modelos ensamblados con *Transfer*

*Learning* (incluido el sector financiero), su uso aún no se ha generalizado como una solución concreta a tres problemáticas clave: la escasez de datos en contextos caracterizados por un cambio vertiginoso, la necesidad de extrapolar y generalizar el comportamiento de activos financieros, y la falta de una evaluación metodológica comparativa rigurosa, con un ajuste explícito de hiperparámetros, que determine la verdadera utilidad del *Transfer Learning* en escenarios de predicción financiera.

En este contexto, el presente trabajo plantea como pregunta central en qué medida la aplicación del *Transfer Learning*, partiendo de un modelo generalista entrenado con datos del índice S&P 500, mejora la precisión y la capacidad de generalización de las predicciones de precios de las acciones individuales que lo componen, considerando distintos horizontes temporales y niveles de disponibilidad de datos. Las conclusiones extraídas tienen implicancias transversales, con potencial para ser adaptadas a otros contextos dentro del trading cuantitativo y del diseño de modelos predictivos en entornos financieros dinámicos.

## 2. OBJETIVOS

### 2.1. Objetivo General

El objetivo principal de este trabajo es evaluar la eficacia del aprendizaje por transferencia (*Transfer Learning*) aplicado a modelos predictivos financieros, utilizando como modelo base un sistema entrenado con datos del índice S&P 500 para mejorar la predicción del comportamiento de sus componentes individuales. En particular, se busca determinar si la transferencia de conocimiento permite generar predicciones más precisas en activos con datos históricos limitados, contribuyendo así a reducir el impacto de la escasez de información en las decisiones de inversión.

Para ello, se desarrollará un modelo algorítmico basado en redes neuronales recurrentes (LSTM y GRU), entrenado con datos técnicos y macroeconómicos del S&P 500. Posteriormente, este modelo será adaptado mediante *fine-tuning* a activos específicos, integrando series temporales de precios, indicadores técnicos y análisis de sentimiento económico, con el fin de evaluar su precisión en predicciones de corto, medio y largo plazo.

### 2.2. Objetivos Específicos

Se busca analizar si la técnica de fine-tuning aplicada a un modelo previamente entrenado con datos del índice S&P 500 permite obtener predicciones más estables y consistentes para activos individuales, especialmente en diferentes horizontes temporales

(corto, mediano y largo plazo). El propósito es determinar si esta estrategia permite no solo mejorar la precisión inmediata, sino también extrapolar el conocimiento de forma robusta a lo largo del tiempo.

Otro de los objetivos es diseñar una estrategia de ajuste de hiperparámetros generalizable, adaptable a la disponibilidad de datos y al tipo de activo considerado. Se busca establecer un marco replicable de configuración que permita optimizar el proceso de entrenamiento del modelo según el contexto temporal primordialmente, favoreciendo así su aplicabilidad en escenarios reales de inversión.

También se contempla la evaluación del impacto del sentimiento económico y diversos indicadores técnicos, así como la interrelación ente las distintas empresas respecto a la cotización de las acciones del índice S&P 500. Se analizará cómo las variaciones en el sentimiento del mercado (derivadas de noticias económicas) influyen en el comportamiento de los activos, y si la incorporación de esta variable en el modelo permite anticipar mejor los movimientos de precio, especialmente en contextos de alta volatilidad.

Finalmente, se establece como objetivo la optimización de los recursos computacionales necesarios para el entrenamiento y ajuste del modelo. Se examinará en qué medida es posible reducir el tiempo y gasto computacional sin comprometer significativamente la precisión de las predicciones, mediante el uso de técnicas como el aprendizaje transferido. Esta dimensión es clave para garantizar la escalabilidad y la viabilidad práctica del modelo.

# 3. ESTUDIO BIBLIOGRÁFICO

## 3.1. Estado del arte

Las redes neuronales Long Short Term Memory (LSTM) han demostrado ser eficaces para predecir precios de acciones y mercados financieros debido a su capacidad para manejar dependencias temporales largas. Por ejemplo, Fischer y Krauss (2018) aplicaron LSTM para predecir retornos de acciones, logrando resultados superiores a modelos tradicionales como *Random Forest* o *Support Vector Machines*, los cuales, si bien pueden trabajar con menos datos, son menos robustos y sofisticados.

En relación con el precio de acciones, Roondiwala publica en 2015 un trabajo de investigación aplicando LSTM al precio de la acción de Nifty 50, ajustando 100 épocas (pasadas completas por el conjunto de datos en el proceso de entrenamiento) y obteniendo

así en test un RMSE del 0.00859. De dicho trabajo cabe destacar sobre todo el proceso de preparación de los datos, donde incluyen la discretización de las variables y una multitud de variables cualitativas, incluyendo el análisis sentimental.

A continuación, cabe mencionar el trabajo de investigación presentado en *E3S Conferences* (2021), donde se explora el ensamblaje de modelos LightGBM y XGBoost para la predicción de precios de acciones, obteniendo resultados superiores a los de una red neuronal ordinaria. Estos modelos destacan por su capacidad de manejar múltiples variables, incluidas las categóricas en LightGBM, y su eficacia en grandes volúmenes de datos. Aunque no están optimizados para capturar dependencias temporales largas, complementan a las LSTM al enfocarse en la relación entre diversas variables incluyendo datos cualitativos.

Por otro lado, el quant trading se ha consolidado como estrategia fundamental de análisis de datos: Shaw (2024) elaboró con Python un proceso de predicción de datos en tiempo real empleando modelos algorítmicos basados en redes neuronales. Su proyecto se quedó en la ejemplificación del proceso con la acción de Tesla utilizando LSTM, obteniendo resultados favorables, y dejaba como propuesta a futuro la integración del modelo desarrollado en un entorno Python a una plataforma o web para generar predicciones dinámicas.

Asimismo, la utilización del *Transfer Learning* también se ha popularizado en los últimos años y en distintos sectores. Zhao (2017) elabora un trabajo titulado *Exploring Transfer Learning for Crime Prediction*, en el cual abordan un problema clave como lo es la falta de datos demográficos específicos en algunas zonas urbanas. Para ello, proponen un marco de aprendizaje por transferencia que permite aprovechar patrones espaciotemporales extraídos de un distrito con datos abundantes, con el objetivo de mejorar la predicción del crimen en otras zonas con menos información disponible. Este enfoque demuestra cómo el *Transfer Learning* puede ser una herramienta efectiva para superar la disparidad de datos y fue clave para motivar este trabajo de investigación.

El *Transfer Learning* también ha demostrado ser eficaz en mercados financieros al permitir la transferencia de conocimiento entre dominios relacionados, como índices o sectores similares, optimizando predicciones incluso en entornos con datos limitados o volátiles. Estudios como el de Liu et al. (2021) aplicaron redes neuronales profundas con TL para predecir movimientos de precios, logrando mejoras significativas en precisión frente a modelos que no emplean esta técnica. Además, afirman que esta metodología reduce tiempos y costos de entrenamiento, haciendo posible un enfoque más eficiente y adaptable,

características clave para el desarrollo de predicciones dinámicas en nuestro sistema. Por ello nuestra propuesta es profundizar nuestro modelo con esta técnica para llegar a un algoritmo predictivo que se ajuste mejor a los datos desde el principio.

Por parte de las variables utilizadas, el análisis de sentimiento del sector económico es tópico común. La extracción de noticias a través de APIs propias de entornos financieros, para su posterior tratamiento y valoración neta es una actividad muy común para la elaboración de algoritmos predictivos en el sector.

Otra técnica utilizada para el análisis de sentimiento y la identificación de este en el ámbito macroeconómico a través de noticias financieras es VADER, un modelo basado en un diccionario optimizado para interpretar texto corto, diseñado por investigadores de Georgia Tech en 2014. En este sentido, Shapiro, Sudhof y Wilson (2020) desarrollaron el Economic Sentiment Index, en colaboración con el Banco Federal de la Reserva de San Francisco. Este índice, basado y elaborado en el marco teórico y conceptual de VADER, pondera palabras clave asignándoles un puntaje numérico y, tras el procesamiento de las noticias, calcula el sentimiento total, permitiendo capturar patrones relevantes para el análisis macroeconómico.En 2023, Jorge Ballarín elaboró un modelo basado en LLM y *Bidirectional Encoder Representations from Transformers* (BERT) que empleando redes neuronales fue capaz de predecir un 90% de acierto si una noticia era positiva, negativa o neutra según la tokenización de palabras claves.

En relación con ello, Zhong (2021) elabora una serie de algoritmos que, tomando en cuenta variables macroeconómicas de sentimiento basadas en BERT, indicadores técnicos y datos de cotización del S&P 500, predicen el índice aplicando Transfer Learning al reentrenamiento de un modelo con diversos algoritmos, entre ellos LSTM, ARIMA y XGBoost. A diferencia de otros modelos de análisis de texto, BERT se destaca por su capacidad para procesar palabras en su contexto bidireccional (tanto a la izquierda como a la derecha de la palabra), lo que le permite entender mejor el significado completo de las frases y, por lo tanto, mejorar la precisión del análisis de sentimiento en el contexto financiero.

El enfoque de Shan Zhong (2021) integra tanto el análisis de sentimiento con modelos predictivos como LSTM para realizar predicciones más precisas. Este enfoque utiliza una metodología de conjunto (ensamblaje de modelos) que combina distintos algoritmos preentrenados con tres tipos de datos: precios históricos, informes financieros y análisis de

sentimiento de noticias. Su objetivo es predecir tanto el índice general del S&P 500 como las acciones individuales, utilizando múltiples modelos y tipos de datos. Este enfoque tiene como innovación principal la combinación de estos diferentes modelos y fuentes de datos.

En contraste, el trabajo propuesto en este proyecto se enfoca específicamente en explorar cómo el Transfer Learning puede mejorar la predicción de rentabilidad de empresas individuales dentro del S&P 500. Se utiliza LSTM inicialmente para aprender patrones generales del mercado, y luego se aplica un *fine-tuning* para especializar el modelo en una acción específica.

Ambos enfoques abordan el problema de datos insuficientes y simplificación del entrenamiento, así como aumento de la precisión en la predicción, pero lo hacen de manera distinta: el trabajo de Zhong lo resuelve mediante la combinación de datos de diversas acciones en un modelo ensemble, mientras que en este proyecto se utiliza Transfer Learning para aprovechar el conocimiento colectivo del mercado.

Más adelante, en 2022, Xue Wen Tan (et. al) elaboran un modelo capaz de optimizar un portafolio consistente de 10 acciones del S&P500, utilizando un modelo previo entrenado a través redes neuronales y utilizando fine tuning para transferir el conocimiento a las acciones en concreto, basándose principalmente en la predicción de rentabilidad y utilizando medidas como el Sharpe Ratio para evaluar la rentabilidad de la acción en concreto y por consiguiente el portafolio. Zemeng Chen (2024) elabora un algoritmo también basado en LSTM y Transfer Learning que se basa exclusivamente en el precio de cierre de la acción y las series temporales de los componentes del S&P500 para predecir el precio de la acción, es decir con metodología similar al nuestro pero objetivo distinto, y por ende, conclusiones distintas.

Un aspecto fundamental en el entorno del trabajo fue introducido por Haoyang Cao (2023): *transfer risk,* que junto con Haotian Gu, Xin Guo y Mathieu Rosenbaum, para evaluar la idoneidad del aprendizaje por transferencia (*transfer learning*) en tareas financieras. Si bien no lo exploramos en el presente trabajo, se complementa con líneas y estudios futuros en base al mismo.

Como se puede observar, dado el creciente interés y la popularización del sector financiero y el trading cuantitativo, existe un estado del arte robusto en este campo. Además de trabajos previos que exploran líneas similares, cada uno presenta objetivos, variables o propuestas diferentes. El enfoque distintivo del presente trabajo radica en la aplicación del ***transfer learning*** de modelos preentrenados, con el fin de mejorar la predicción de precios

futuros de acciones según disponibilidad de datos, evaluando así la relación con la similitud de los activos.

## 3.2. Marco teórico

### 3.2.1. Redes Neuronales Recurrentes

Una Red Neuronal Recurrente (RNN, por sus siglas en inglés) es una arquitectura de red diseñada para procesar secuencias de datos, donde el valor actual depende del histórico de entradas anteriores. Su fundamento matemático se basa en operaciones de multiplicación de matrices entre las entradas y los pesos sinápticos del modelo, que son ajustados durante el entrenamiento. A diferencia de las redes neuronales tradicionales, las RNN poseen conexiones recurrentes que permiten la retroalimentación de información en el tiempo, lo que les confiere la capacidad de modelar dependencias temporales.

Durante el entrenamiento, cada entrada de la secuencia es multiplicada por un conjunto de pesos, y el resultado se transforma mediante una función de activación (como tanh o ReLU). Esta salida se combina con el estado oculto anterior, generando un nuevo estado que incorpora memoria del pasado. Este proceso se repite de manera iterativa para cada instante temporal, lo que incrementa significativamente la complejidad computacional y el consumo de memoria, especialmente en secuencias largas. Además, las RNN convencionales presentan dificultades para aprender dependencias a largo plazo debido a problemas como el desvanecimiento y explosión del gradiente.

Estas limitaciones han motivado la evolución hacia arquitecturas mejoradas como LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Unit), que incorporan mecanismos de control interno para gestionar mejor la información relevante en series temporales largas (Goodfellow, Bengio & Courville, 2016).

### 3.2.2. Long Short-Term Memory (LSTM)

Las Long Short-Term Memory (LSTM) son una extensión de las redes neuronales recurrentes (RNN) diseñadas para solucionar el problema del desvanecimiento del gradiente en secuencias largas. Las RNN convencionales tienen dificultades para modelar dependencias a largo plazo debido a que los gradientes que se calculan durante el proceso de retro propagación tienden a desaparecer a medida que se propagan a través del tiempo (Hochreiter & Schmidhuber, 1997). Las LSTM introducen una arquitectura de memoria con

puertas (gates), que permiten el almacenamiento y control de información relevante a lo largo del tiempo.

Las LSTM mejoran las RNN al incluir tres puertas principales que controlan la memoria en cada paso de tiempo: la puerta de olvido, la puerta de entrada y la puerta de salida. Estas puertas funcionan mediante funciones matemáticas específicas que deciden, en cada paso, qué información se olvida, qué se guarda y qué se utiliza para producir la salida de la red. Estas funciones se implementan mediante la activación de sigmoide y tangente hiperbólica, las cuales son funciones que transforman los valores de manera que se mantengan dentro de rangos controlables.

Las fórmulas que describen este proceso son bastante técnicas (anexo 16), pero funcionan de la siguiente manera:

- **Puerta de olvido (forget gate)**: Decide qué información de la "memoria" anterior debe olvidarse.
- **Puerta de entrada (input gate)**: Decide qué nueva información debe añadirse a la memoria.
- **Puerta de salida (output gate)**: Decide qué parte de la memoria se usará para la salida final.

Esencialmente LSTM es un modelo que permite recordar y olvidar información de forma controlada y con el paso del tiempo. Esto le da mucho valor y soluciona el problema inherente de las RNN donde la gradiente se pierde a motivo de la estandarización de las predicciones.

### 3.2.3. Gated Recurrent Network (GRU)

Otra red neuronal, variante de las RNN, son las GRU (*Gated Recurrent Units*), que surgen igual que las LSTM para contrarrestar el problema de las RNN con el desvanecimiento de la gradiente. Introducidas por Cho et al. (2014), las GRU incorporan mecanismos de compuertas que permiten controlar el flujo de información a lo largo del tiempo, facilitando la conservación de información relevante y la eliminación de aquella que no contribuye a la predicción. En lugar de replicar toda la estructura de una RNN clásica, las GRU simplifican la arquitectura al utilizar dos compuertas principales: la compuerta de actualización y la compuerta de reinicio.

La compuerta de actualización determina qué parte del estado anterior se conserva, permitiendo al modelo recordar información de largo plazo sin necesidad de mantener todos los detalles. La compuerta de reinicio, en cambio, regula qué parte de la información anterior debe olvidarse en función del contexto actual. Esta estructura permite que las GRU sean más eficientes computacionalmente que las LSTM, al requerir menos parámetros, pero manteniendo una capacidad similar para capturar dependencias temporales en datos secuenciales. Por ello, las GRU han demostrado ser especialmente útiles en contextos donde el conjunto de datos es limitado o cuando se requiere una menor carga computacional sin sacrificar precisión (Cho et al., 2014).

### 3.2.4. Transfer Learning

El *Transfer Learning* (TL) es un enfoque de aprendizaje automático que aprovecha los conocimientos adquiridos de una tarea previa para mejorar el rendimiento en una tarea relacionada pero diferente. Esta técnica ha sido ampliamente utilizada en el ámbito del deep learning, ya que permite reducir significativamente el tiempo de entrenamiento y los recursos necesarios al reutilizar modelos previamente entrenados. En lugar de entrenar un modelo desde cero, TL utiliza un modelo previamente entrenado en un conjunto de datos grande y luego ajusta (fine-tuning) dicho modelo para que sea aplicable a un conjunto de datos más pequeño y específico.

El principal beneficio del TL es que, al transferir el conocimiento de un dominio de aprendizaje a otro, se mejora la capacidad del modelo para generalizar, especialmente cuando los datos para la tarea objetivo son limitados. Este tipo de aprendizaje es especialmente útil en áreas donde los datos etiquetados son escasos o costosos de obtener, como el procesamiento de lenguaje natural, la visión por computadora o la criminalística.

En términos matemáticos, el proceso de Transfer Learning implica la reutilización de pesos entrenados de una red neuronal profunda (por ejemplo, en tareas de clasificación de imágenes), donde el modelo original está compuesto por una serie de capas convolucionales (CNN). El proceso de fine-tuning implica actualizar parcialmente los pesos de la red en función de los datos de la nueva tarea, mientras que algunas capas preentrenadas pueden permanecer congeladas (no actualizadas).

El Transfer Learning se puede dividir en dos tipos:

- **Fine-tuning:** Se utiliza un modelo preentrenado y se ajusta ligeramente para que se adapte mejor a la nueva tarea, cambiando solo las últimas capas de la red. Las capas iniciales, responsables de la detección de características generales, se mantienen intactas.
- **Feature Extraction:** En este caso, el modelo preentrenado se utiliza solo para extraer características de los datos de entrada. Estas características se utilizan como entrada para un modelo de clasificación o regresión más sencillo. Este enfoque es útil cuando no es necesario realizar un ajuste profundo del modelo.

El TL se ha demostrado particularmente eficaz en tareas de clasificación de imágenes, donde redes como VGG o ResNet son preentrenadas en grandes bases de datos como ImageNet y luego se reutilizan en nuevos problemas. Sin embargo, esta técnica también ha sido aplicada en procesamiento de lenguaje natural (NLP), donde modelos como BERT o GPT son preentrenados en grandes corpus de texto y luego ajustados para tareas específicas como análisis de sentimientos o traducción automática.

En resumen, el Transfer Learning permite acelerar el desarrollo de modelos de machine learning y deep learning al aprovechar conocimientos adquiridos de tareas anteriores, mejorando la eficiencia y efectividad en el entrenamiento de modelos para nuevas aplicaciones.

# 4. INGENIERÍA DEL DATO

## 4.1. Herramientas utilizadas: Justificación y descripción

El desarrollo del presente trabajo se ha llevado a cabo en **Google Colab**, una plataforma que permite la ejecución de código **Python** en la nube, facilitando el uso de recursos computacionales sin necesidad de configuración local. Su entorno interactivo resulta especialmente útil para proyectos de análisis de datos y modelado predictivo.

El lenguaje utilizado ha sido Python, por su versatilidad y por contar con un amplio ecosistema de librerías especializadas. Para la manipulación de datos se emplearon Pandas y NumPy, y para la visualización de resultados se utilizaron Matplotlib y Seaborn.

Los modelos predictivos se implementaron mediante TensorFlow y Keras, herramientas de referencia en deep learning que permiten construir redes neuronales como LSTM y GRU,

así como aplicar técnicas como el aprendizaje por transferencia (Transfer Learning) y el ajuste dinámico de hiperparámetros.

Los datos financieros se obtuvieron a través de la API de Alpha Vantage, que proporciona acceso a precios históricos de acciones y del índice S&P 500, permitiendo trabajar con series temporales reales y actualizadas.

## 4.2. Tratamiento de Datos: S&P 500

### 4.2.1. Origen y Extracción de los Datos

Inicialmente, se descargaron 106 ficheros CSV a través de cinco procesos de extracción utilizando la API de Alpha Vantage. De esta manera, obtuvimos los datos históricos de precios y volumen de las principales empresas del S&P500: el precio de apertura (open), cierre (close), máximo (high), mínimo (low) y volumen de mercado, además de la fecha de cada entrada y el ticker correspondiente, clave para la posterior integración de datos. Del mismo modo, y con la misma información, se descargaron los datos del propio S&P500, concretamente del ETF vinculado al índice (SPY, cuyo precio es un décimo del S&P500 en cada momento), así como sus valores mínimo, máximo, volumen de mercado y la fecha correspondiente.

Por otro lado, se procedió con la obtención y descarga del índice de sentimiento. El Daily News Sentiment Index del Banco de la Reserva Federal de San Francisco es el resultado de un ambicioso proyecto que, bajo la metodología VADER de análisis de texto y sentimiento, tokeniza diariamente noticias económico-financieras del mercado estadounidense, asignando a cada palabra token un valor neto de sentimiento. La integración de los puntajes para cada palabra constituye el índice de sentimiento diario. Estos datos fueron originalmente utilizados para analizar el impacto del COVID-19 en la economía estadounidense, y su utilidad se extiende más allá de este contexto, convirtiéndose en una variable clave para comprender cómo el sentimiento económico diario influye en la especulación y por ende precio del fondo indexado más importante de EE. UU.: el S&P 500.

A continuación, a través de la función *merge* de Python, se incorporó la variable *News Sentiment* al *dataframe* con los datos del S&P 500. Para ello, se tomó la fecha como referencia y se realizó una búsqueda cruzada, estableciendo la correspondencia entre el sentimiento económico del día y el precio de apertura del fondo.

Asimismo, dado que uno de los objetivos es mejorar las predicciones permitiendo que el modelo identifique correlaciones entre empresas del índice (cuyos comportamientos están interrelacionados, como veremos más adelante), utilizamos la función *join* de Python para incluir, nuevamente en función de la fecha, el precio de apertura diario de las diez principales empresas del S&P 500: Apple (AAPL), Amazon (AMZN), Broadcom (AVGO), Berkshire Hathaway (BRK.B), Google (GOOGL), Alphabet (GOOG), Meta (META), Microsoft (MSFT), Nvidia (NVDA) y Tesla (TSLA).

El resultado son 6.332 observaciones iniciales, desde el 01 de noviembre del 1999 hasta el 31 de diciembre del 2024, 250 observaciones por año, una por cada día que la bolsa de valores de Nueva York ha estado abierta y, por ende, se producen transacciones que afectan el precio de la acción.

### 4.2.2. Transformación y Cálculo de Indicadores Técnicos

A continuación, procedemos con la creación de las nuevas variables, indicadores técnicos de inversión que puedan fortalecer el modelo y dar un mayor contexto. Si entendemos que son estos indicadores de volatilidad y estabilidad económica las que, de la mano con el sentimiento económico, derivan en la propensión de inversión de los particulares y fondos conglomerados, podemos considerar que estas variables tendrán peso a la hora de predecir el precio del S&P500:

- **Media Móvil (Moving Average - MA):** La media móvil es un indicador que se utiliza para suavizar las fluctuaciones de los precios y ayudar a identificar las tendencias. Para calcularla, usamos una ventana de 14 días.
- **Índice de Fuerza Relativa (Relative Strength Index - RSI):** El RSI es un indicador de momento que compara las magnitudes de los movimientos alcistas y bajistas recientes. Se calcula mediante la fórmula estándar: $RSI = 100 - \frac{100}{(1+RS)}$ , donde RS es la media de las ganancias de los días con cierre alcista dividida entre la media de las pérdidas de los días con cierre bajista. En este caso, utilizamos una ventana de 14 días para calcular las medias móviles de ganancias y pérdidas.
- **MACD (Moving Average Convergence Divergence):** El MACD se utiliza para detectar cambios en la fuerza, dirección, impulso y duración de una tendencia. Se calcula como la diferencia entre dos medias móviles exponenciales (EMA): una de corto plazo

(12 días) y otra de largo plazo (26 días). Luego, se calcula una "línea de señal", que es la media móvil exponencial (EMA) del MACD.

- **Bandas de Bollinger (Bollinger Bands):** Las Bandas de Bollinger son un indicador que mide la volatilidad del mercado. Se calcula como una media móvil (de 20 días, por ejemplo) más o menos dos veces la desviación estándar de los precios en esa ventana. Esto nos da una banda superior y una banda inferior.
- **Volatilidad:** La volatilidad se mide como la desviación estándar de los precios de cierre de un activo, lo que nos da una idea del nivel de incertidumbre o riesgo.
- **Average True Range (ATR):** El ATR es un indicador de la volatilidad que tiene en cuenta las brechas de precios entre las sesiones, además de la variación diaria. Se calcula como el promedio de la diferencia entre el precio máximo y el mínimo del día, y el cierre previo al día actual.

Por otro lado, cabe destacar que la ventana de tiempo empleada fue de 14 días, un estándar en muchos análisis técnicos que permite capturar la dinámica del mercado a corto plazo. Este período es suficiente para medir la dirección de la tendencia y detectar cambios en el comportamiento del activo sin ser excesivamente sensible a las fluctuaciones diarias.

Al incorporar los indicadores en el modelo, podemos analizar su correlación con las predicciones de precios y la rentabilidad futura de las empresas. Los indicadores técnicos resultan especialmente útiles para anticipar movimientos a corto y medio plazo, complementando así las predicciones basadas en datos fundamentales y de sentimiento.

### 4.2.3. Limpieza: Tratamiento de valores faltantes y nulos

Tenemos valores nulos en los precios de apertura de AVGO, GOOGL, GOOG, META y TSLA. Esto se debe a que la fecha de creación de dichas empresas o la fecha en que comenzaron a cotizar en bolsa es posterior a la fecha desde la que tenemos datos disponibles.

En ese sentido, se ha optado por rellenarlos con 0. Sin embargo, somos conscientes de que esta decisión podría distorsionar ciertos análisis, en particular, las correlaciones entre estas empresas y el fondo, así como entre ellas mismas. Al introducir ceros, podríamos estar generando relaciones artificiales o sesgando la interpretación de las tendencias de los datos.

Para mitigarlo, de cara a la creación de los modelos, aplicaremos una estrategia de *masking*, asegurándonos de que los ceros no influyan en los modelos de predicción. Así, el LSTM y ARIMA podrán interpretar correctamente la ausencia de datos en lugar de asumir que el precio real fue 0, evitando así efectos no deseados en el entrenamiento y la predicción.

Asimismo, hubo algunos valores nulos en los indicadores técnicos debido al requisito de ventanas temporales para su cálculo. Para manejar estos valores nulos, optamos por aplicar un *forward fill* o propagación hacia adelante. Esto significa que cada valor nulo se reemplaza con el último valor disponible, evitando así la pérdida de información y asegurando la continuidad de datos. Esta estrategia nos permite mantener la coherencia en el análisis sin introducir valores artificiales que podrían afectar la interpretación de los modelos.

Por otra parte, los valores atípicos (*outliers*, ver Anexo 1) se han conservado para garantizar la integridad del modelo, ya que podrían desempeñar un papel clave en la identificación de patrones y la relación entre el sentimiento del mercado y los precios de apertura del SPY. Dado que estos valores extremos pueden reflejar reacciones del mercado ante eventos inesperados o volátiles, su eliminación podría distorsionar el análisis y afectar la capacidad del modelo para capturar dinámicas relevantes y predecir.

**Tabla 1.** Resumen de valores faltantes post-merge de ficheros.

| Variable | Valores Nulos | Porcentaje de Nulos (%) |
|---|---|---|
| date | 0 | 0 |
| open | 0 | 0 |
| high | 0 | 0 |
| low | 0 | 0 |
| close | 0 | 0 |
| volume | 0 | 0 |
| News Sentiment | 0 | 0 |
| open_AAPL | 0 | 0 |
| open_AMZN | 0 | 0 |
| open_AVGO | 2466 | 38.77 |
| open_BRKB | 0 | 0 |
| open_GOOGL | 1209 | 19.03 |
| open_GOOG | 3632 | 57.2 |
| open_META | 3157 | 49.68 |
| open_MSFT | 0 | 0 |
| open_NVDA | 0 | 0 |
| open_TSLA | 2680 | 42.35 |

### 4.2.4. Análisis Descriptivo y Exploratorio

La tabla a continuación muestra un análisis descriptivo elemental de las principales variables de nuestro conjunto de datos. Se observa que la desviación estándar es considerablemente alta para los precios de las acciones, lo que refleja la volatilidad inherente

de los mercados financieros, ya que los precios de las acciones fluctúan ampliamente en el tiempo.

**Tabla 2.** Análisis descriptivo de las principales variables.

| Variable | Cantidad | Media | Desviación Estándar | Mínimo | Percentil 25 | Mediana | Percentil 75 | Máximo |
|---|---|---|---|---|---|---|---|---|
| open | 6332 | 210.61 | 123.54 | 67.95 | 120.39 | 148.39 | 274.04 | 607.69 |
| News Sentiment | 6332 | 0 | 0.2 | -0.67 | -0.12 | 0.02 | 0.15 | 0.42 |
| open_APPL | 6332 | 174.72 | 146.66 | 12.99 | 79.95 | 139.98 | 205.35 | 702.41 |
| open_TSLA | 6332 | 174.61 | 261.64 | 0 | 0 | 31.57 | 249.02 | 2295.12 |
| ATR | 6332 | 2.81 | 2.12 | 0.73 | 1.46 | 2 | 3.42 | 19.91 |

En cuanto al *News Sentiment,* su media es 0, lo que indica que, en promedio, el sentimiento del mercado se encuentra neutral, sin inclinaciones hacia el optimismo o pesimismo. El valor mínimo es -0.67 y el máximo 0.42, lo que implica que, la desviación no es muy alta y el sentimiento no ha sido marcadamente negativo o positivo en extremo. Estas fluctuaciones podrían estar relacionadas con eventos económicos, políticos o corporativos que afectan el sentimiento general del mercado.

Asimismo, antes de proceder con un análisis de estacionalidad de los datos bajo el entendimiento de que tratamos con series temporales, vemos que los rendimientos tanto mensuales como diarios siguen una distribución normal, con una media que tiende a 0.

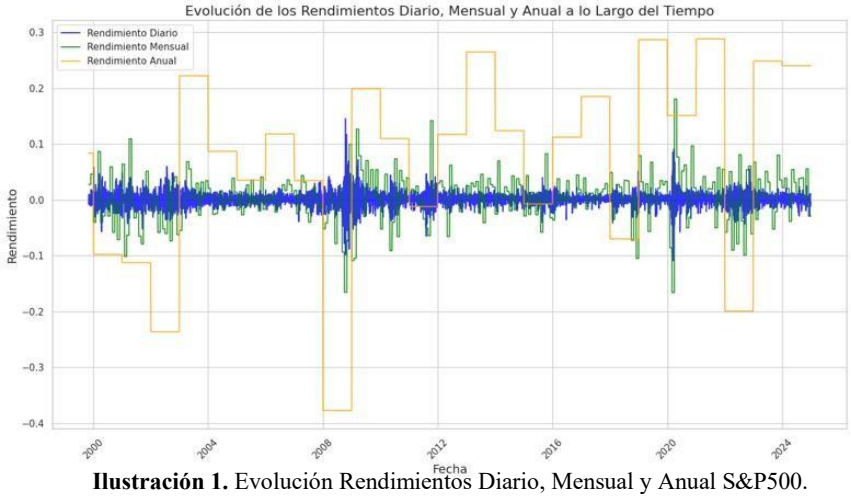


**Ilustración 1.** Evolución Rendimientos Diario, Mensual y Anual S&P500.

Esto se explica por la naturaleza del mercado monetario, cuyo comportamiento en el corto plazo es cuasi-aleatorio, tendiente a 0 en rentabilidad. Por el contrario, en el largo plazo vemos una tendencia creciente con un pico en 0.1, justo siendo la media anual de los retornos del S&P500 histórico en torno al 10%.

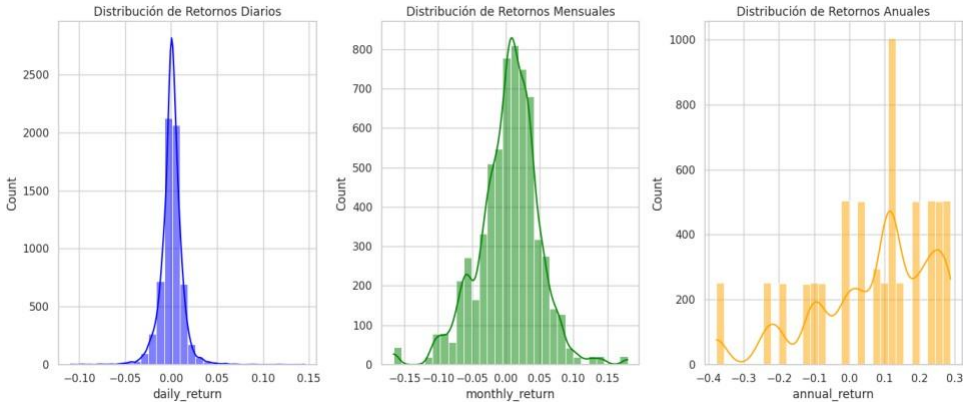


**Ilustración 2.** Histogramas de retornos a corto, medio y largo plazo.

A continuación, se realizó un análisis de correlación de las principales variables respecto a la variable objetivo, que en este caso es el precio de apertura del SPY (S&P 500). Como se puede observar en el gráfico 3, la mayoría de las variables muestran una correlación positiva con el precio de apertura del SPY. En verde se destacan aquellas variables con una correlación positiva, y en rojo las variables con correlación negativa (>0.5 o <-0.5 *tresholds*).

Es importante señalar que las variables con una correlación significativa son útiles para explicar los movimientos del precio del S&P 500, lo que favorece al modelo. Descartamos además del modelo aquellas cuya correlación sea exactamente 1, ya que estas son estrictamente dependientes o derivadas unas de otras, lo que podría generar redundancia y sobreajuste en el modelo.

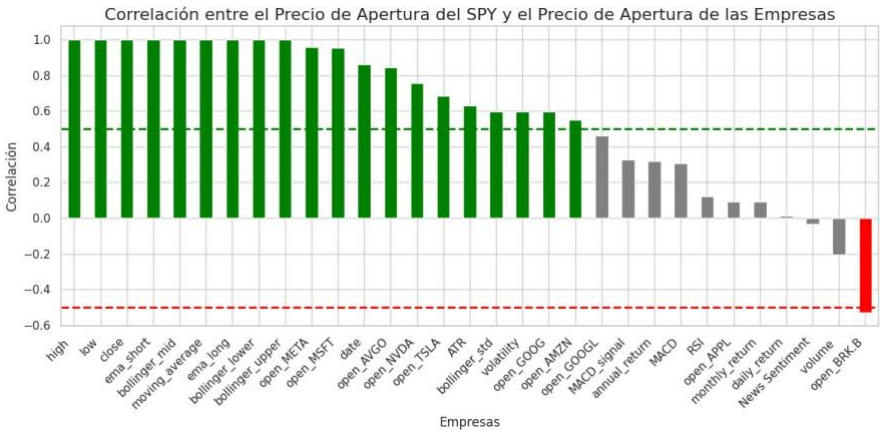


**Ilustración 3.** Correlación entre el Open del S&P500 y el resto de las variables.

Empresas como META, Microsoft, Broadcom (AVGO), Nvidia, Google y Amazon presentan una correlación alta y positiva con el S&P 500. Esto se debe a la interrelación entre el índice y estas acciones, las cuales, además de tener un peso significativo en el S&P 500, están profundamente vinculadas y determinadas por la economía estadounidense y global. Estas compañías actúan como un barómetro del rendimiento económico general, lo que explica su fuerte y significativa correlación con el índice. Para verificarlo, además de aplicar un umbral (threshold), se realizó una prueba de significancia del coeficiente de correlación de Pearson, obteniendo evidencia adicional sobre la relación entre las acciones del índice y su precio.

La correlación negativa entre el precio de apertura de Berkshire Hathaway (BRK.B) y el S&P 500 puede deberse a la estrategia de inversión de Warren Buffett, basada en el value investing y enfocada en el crecimiento sostenible a largo plazo. Esto hace que sus acciones no sigan siempre las tendencias generales del mercado y, en algunos casos, se muevan de manera contra cíclica, especialmente en períodos de alta volatilidad. Por ello, al integrar BRK.B en este modelo predictivo, es crucial considerar este comportamiento diferenciado, ya que podría introducir patrones distintos a los de otras acciones más alineadas con el índice.

Se realizó un análisis de correlación entre el News Sentiment y diversas variables del mercado con el objetivo de evaluar el impacto del sentimiento en los precios de apertura y otros indicadores financieros.

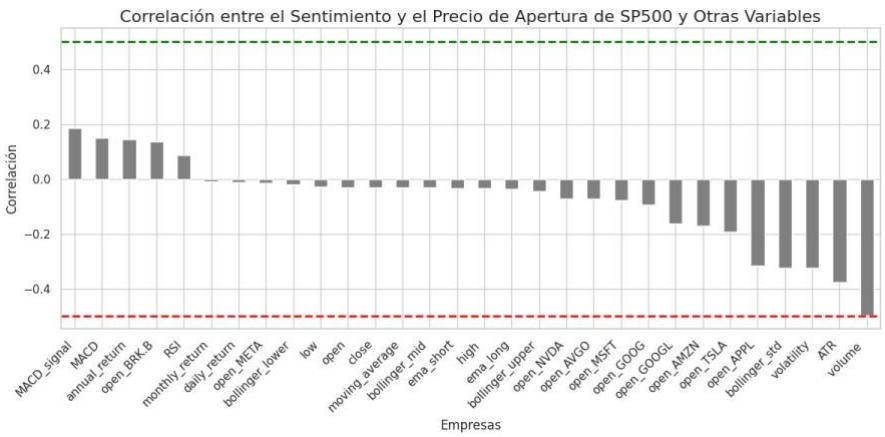


**Ilustración 4.** Correlación entre el News Sentiment Index y el resto de las variables.

Los resultados muestran que el ATR (Average True Range) y el volumen presentan la correlación negativa más fuerte con el News Sentiment. Esto sugiere que un mayor volumen

de negociación y una mayor volatilidad tienden a estar asociados con un sentimiento más negativo en el mercado. Este resultado es consistente con la teoría de que períodos de alta incertidumbre y volatilidad suelen coincidir con un sentimiento pesimista.

Por otro lado, el MACD Signal, junto con el MACD y el RSI, muestran una correlación positiva con el News Sentiment. Esto indica que un sentimiento más optimista podría estar vinculado con tendencias alcistas y señales técnicas favorables para la inversión.

En cuanto a los precios de apertura de las acciones del S&P 500, se observa una correlación negativa con el News Sentiment en empresas como AAPL, TSLA, AMZN, GOOGL y MSFT. Esto podría implicar que un mayor pesimismo en las noticias precede a caídas en los precios de apertura o que, en momentos de optimismo, los precios tienden a estabilizarse o subir menos agresivamente, lo esperado. Nuevamente destaca BRK.B, que muestra una correlación positiva con el News Sentiment.

Si bien las correlaciones son significativas, los coeficientes presentan valores relativamente bajos. Esto sugiere que, aunque el News Sentiment influye en el comportamiento del mercado, no es el principal determinante de los precios de apertura ni de la volatilidad de las acciones. Sin embargo, es muy probable que esta variable en conjugación con otras pueda ser determinante en el modelo.

Por otro lado, tal y como se explicó anteriormente, el ATR es la mejor métrica de volatilidad. Es por ello, la correlación entre el sentimiento y el ATR es negativa y de 0.38, lo que implica que en períodos donde el sentimiento es muy negativo, la volatilidad crece: lo cual es lógico. Es más, a mediados de 2020-2021 vemos un ATR que alcanza su máximo histórico (0.4) y se corresponde con un sentimiento en su mínimo histórico, de -0.6. El contexto histórico justificado por la crisis económica derivada de la pandemia que azotó no solo a Estados Unidos, si no al mundo. En 2008 (crisis financiera en EE. UU. particularmente) se corresponde un crecimiento de la volatilidad calculada con un sentimiento más negativo. Está correlación puede ayudar a entender el comportamiento del precio del S&P500 y su relación con el entorno económico y la especulación correspondiente. Todo ello se evidencia en la gráfica a continuación:

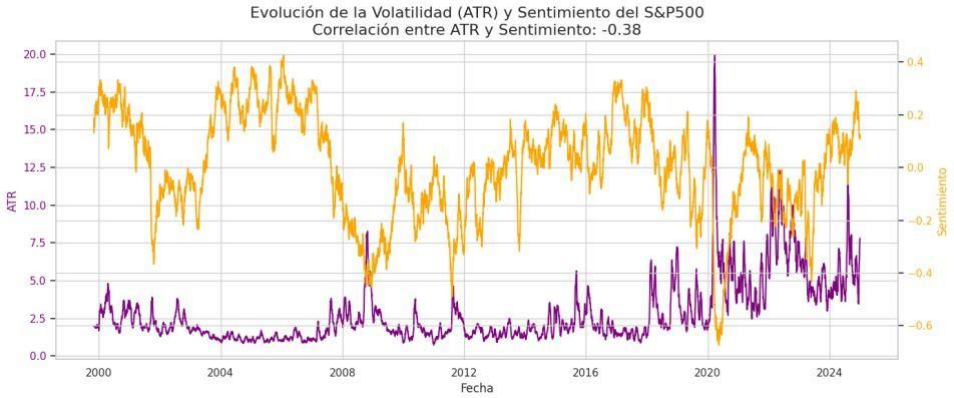


**Ilustración 5.** Evolución Volatilidad (ATR) y Sentimiento Económico en el tiempo.

A continuación, se realizó un análisis detallado del precio de apertura del S&P 500, descomponiendo la serie en sus tres componentes: tendencia, estacionalidad y residuos. El factor de estacionalidad varía entre 0.97 y 1.02, lo que sugiere que no hay una estacionalidad significativa en los datos (Ver Anexo 9). Por otro lado, los residuos, que son la diferencia entre los valores observados y los ajustados por el modelo, presentan una varianza constante, lo que indica que no existen patrones sistemáticos en los errores y que el modelo ajusta adecuadamente la serie.

### 4.2.5. Estacionariedad del precio de apertura S&P500 Stock

Seguidamente, para evaluar la estacionariedad de la serie temporal correspondiente al precio de apertura (open) del S&P 500, se aplicó la prueba de Dickey-Fuller aumentada (ADF). Los resultados obtenidos mostraron un estadístico ADF de 2.1510 y un valor p de 0.9988, con valores críticos de -3.4314, -2.8620 y -2.5670 para los niveles de significancia del 1%, 5% y 10%, respectivamente. Dado que el valor p es significativamente mayor a 0.05 y que el estadístico ADF no es menor que los valores críticos en ninguno de los niveles de significancia, no se puede rechazar la hipótesis nula de raíz unitaria. Esto implica que la serie no es estacionaria, es decir, presenta tendencia o varianza no constante a lo largo del tiempo, como vemos a continuación.

**Ilustración 6.** Evolución del precio de Apertura del S&P500.

La estacionariedad es un requisito fundamental en el modelado de series temporales, ya que muchos algoritmos de predicción, como ARIMA, requieren que las series sean estacionarias para obtener resultados fiables. En el caso de los modelos basados en redes neuronales recurrentes, como LSTM, aunque en teoría pueden manejar datos no estacionarios, la transformación de las series facilita el aprendizaje del modelo y mejora la estabilidad de las predicciones.

Tras evaluar la serie open, extendimos el análisis a otras variables del conjunto de datos. Se observó que las siguientes tampoco eran estacionarias: high, low, close, open_AAPL, open_AMZN, open_AVGO, open_BRK.B, open_GOOGL, open_GOOG, open_META, open_MSFT, así como varios indicadores técnicos, incluidos moving_average, ema_short, ema_long, bollinger_mid, bollinger_upper y bollinger_lower. Dado que la no estacionariedad en estas variables podría afectar la capacidad predictiva del modelo, se decidió transformarlas.

Para estabilizar la varianza y eliminar tendencias, se aplicó una transformación logarítmica seguida de diferenciación. La elección de esta técnica se debe a que, en series financieras, el logaritmo permite reducir la heterocedasticidad, es decir, las variaciones de la varianza a lo largo del tiempo, haciendo que la serie sea más homogénea. Posteriormente, la diferenciación de primer orden se emplea para eliminar tendencias y lograr una serie más adecuada para el modelado (Ver Anexo 8). Sin embargo, dado que el logaritmo solo puede aplicarse a valores positivos, se excluyeron de la transformación aquellas series que presentaban valores menores o iguales a cero, a los cuales solo se aplicó la diferenciación (Google, Meta y Annual Return).

Después de aplicar la transformación, se volvió a realizar la prueba de Dickey-Fuller sobre las series transformadas. Los resultados mostraron una mejora significativa, con varias variables que antes eran no estacionarias pasando a ser estacionarias tras la aplicación del logaritmo y la diferenciación. En particular, en el caso de la variable open, el valor p original de 0.9988 se redujo considerablemente después de la transformación, lo que indica que la serie se volvió estacionaria, lo que la hace más adecuada para la modelización.

Esta transformación logarítmica combinada con la diferenciación permitió estabilizar las series temporales, facilitando su utilización tanto en modelos ARIMA como en redes neuronales recurrentes. Para los modelos basados en ARIMA, esta transformación era imprescindible para cumplir con el requisito de estacionariedad. En el caso de LSTM, aunque el modelo podría manejar datos no estacionarios, esta transformación optimiza el entrenamiento al reducir la varianza y eliminar las tendencias que podrían dificultar la convergencia del modelo. Aun así, se mantienen ambas versiones para prueba futura.

Con todo ello, obtenemos las siguientes variables, resumidos de la siguiente manera:

**Tabla 3.** Resumen variables y tipología post-tratamiento S&P500.

| Nombre | Tipo | Exógena/Endógena | Fuente |
|---|---|---|---|
| S&P Price | Cuantitativa | Exógena (Independiente) | Datos de precios históricos (AlphaVantage) |
| Volume | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| News Sentiment | Cuantitativa | Endógena | Shapiro, Sudhof & Wilson (2020), Banco de la Reserva Federal de San Francisco |
| open_APPL | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_AMZN | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_AVGO | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_BRK.B | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_GOOGL | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_GOOG | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_META | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_MSFT | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_NVDA | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_TSLA | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| RSI | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| MACD | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| MACD_signal | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| bollinger_std | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| volatility | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| ATR | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| daily_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| monthly_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| annual_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |

### 4.3. Tratamiento de Datos: Tesla, Uber, Apple y Planet Fitness

#### 4.3.1. Extracción y Transformación de los datos

Uno de los principales objetivos de este trabajo es evaluar si la transferencia de conocimiento mejora la precisión de modelos predictivos en entornos con datos limitados, permitiendo anticipar el comportamiento de nuevas empresas en mercados dinámicos y altamente innovadores. Por esta razón, se busca potenciar un modelo utilizando otro pre-entrenado con un volumen de datos más grande. En este contexto, hemos seleccionado Tesla, una empresa que cuenta con aproximadamente 3.300 datos diarios desde su IPO en 2010, como caso principal. Posteriormente analizaremos también Uber, Apple y Planet Fitness, pero el procedimiento ETL y de Ingeniería de Dato se realiza de la misma manera para todos los activos selecionados.

Se extrajeron con la API los datos principales de Tesla (open, close, high, low y volume), con la fecha correspondiente. Y de la mano con las funciones merge y join de Python fuimos capaces de insertar las variables *News Sentiment* y los precios de apertura de las 10 principales empresas del S&P500, incluyendo el valor de la EFT de SPY como una de las 10 (reemplazando TESLA del apartado anterior. Asimismo, calculamos los mismos indicadores técnicos de cara a los datos extraídos de Tesla y su comportamiento económico a lo largo del tiempo.

Los valores nulos se imputaron utilizando *forward fill* para evitar distorsiones en las correlaciones. Para fechas en las que la empresa aún no cotizaba, los datos se dejaron como *0*, evitando introducir información artificial, y teniendo en cuenta que en un futuro deberemos emplear masking para que las correlaciones no se vean afectadas por el peso de los nulos. Acto seguido, se calcularon los indicadores técnicos del mismo modo en que se hizo en el apartado anterior, y las observaciones que quedan vacías por la necesidad de utilizar ventanas temporales para su cálculo se rellenaron a través del *forward fill*.

**Tabla 4.** Resumen descriptivo principales variables TESLA Stock.

| Variable | Cantidad | Media | Desviación Estándar | Mínimo | Percentil 25 | Mediana | Percentil 75 | Máximo |
|---|---|---|---|---|---|---|---|---|
| open | 3652 | 302.75 | 282.67 | 16.14 | 164.79 | 232.09 | 335.04 | 2295.12 |
| News Sentir | 3652 | -0.03 | 0.17 | -0.67 | -0.12 | 0 | 0.09 | 0.33 |
| open_APPL | 3652 | 245.35 | 150.28 | 90 | 136.4 | 178.51 | 326.97 | 702.41 |
| open_MSFT | 3652 | 139.2 | 124.98 | 23.09 | 37.87 | 74.97 | 238.53 | 467 |
| ATR | 3652 | 15.41 | 21.53 | 0.5 | 6.14 | 9.19 | 13.68 | 244.93 |

Asimismo, se realizó un estudio de los *outliers* (valores atípicos) obteniendo *554* valores atípicos (Anexo 4). Del mismo modo que con el S&P500 los mantenemos, ya que de lo contrario corremos el riesgo de suavizar la tendencia y sobre ajustar la serie, y en un modelo que aspira a tanta precisión no es lo correcto. Además, En una serie financiera, los *outliers* no representan errores, sino eventos significativos como anuncios de ganancias, crisis económicas o cambios de tendencia. Eliminar estos datos podría ocultar información valiosa sobre la volatilidad y la dinámica real del mercado, afectando la calidad de los modelos predictivos.

### 4.3.2. Análisis Descriptivo y Exploratorio

Inicialmente, podemos ver una correlación positiva de 0.54, obtenida mediante el análisis de significatividad del coeficiente de correlación de Pearson entre el precio de Tesla y el tiempo. Esto significa que, en términos generales, el precio de las acciones de Tesla ha tendido a aumentar a lo largo del tiempo, aunque con fluctuaciones. Una correlación de 0.54 indica una relación moderada, lo que sugiere que el tiempo influye en la evolución del precio, pero no de manera determinante, ya que existen otros factores que también afectan su comportamiento.

Un ejemplo destacado de los valores atípicos es el pico observado a finales de 2020, que se debe al fuerte crecimiento de Tesla impulsado por su inclusión en el S&P 500 en diciembre de ese año, lo que generó una ola de compras masivas por parte de fondos indexados e inversores individuales. Otro factor relevante en ese período fue el optimismo generalizado en torno a la adopción de vehículos eléctricos y la posición dominante de Tesla en el sector.

**Ilustración 7.** Evolución temporal precio de apertura Tesla Stock.

Desde 2023, la acción de Tesla cae significativamente, afectada por el endurecimiento monetario de la Reserva Federal, mayor competencia y recortes de precios. Su volatilidad exige analizar los valores atípicos en contexto para entender su evolución.

Los rendimientos se calculan en tres horizontes: diario, mensual y anual. A corto y medio plazo, siguen una distribución normal con media mensual cercana a cero, aunque negativa. A largo plazo, la variabilidad es alta, con rentabilidades que alcanzaron el 300% en 2013, impulsadas por su auge, pero contrarrestadas por la caída de 2022 tras la crisis energética derivada de la guerra en Ucrania.

A continuación, se ve claramente la relación de los retornos con el tiempo:

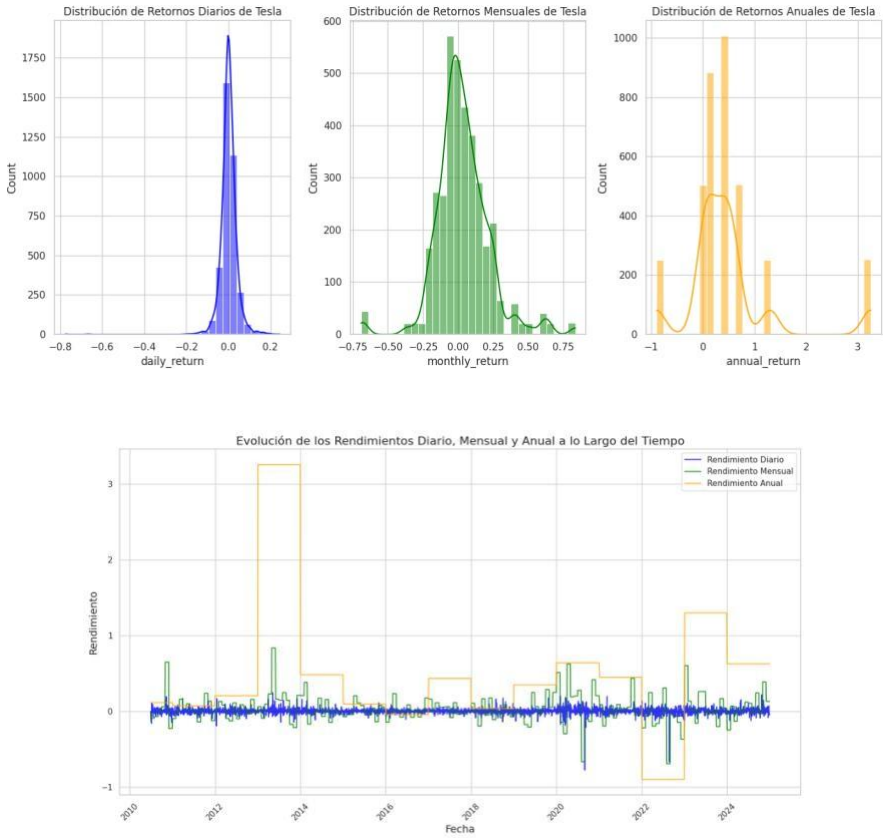


**Ilustración 8.** Histogramas y serie análisis temporal de los rendimientos Tesla.

Se realizó además un análisis de autocorrelación, notando que existe una gran correlación con los indicadores técnicos, y con algunas empresas como Amazon y Google. Descartamos las variables que tienen una correlación significativa e igual a 1 dado que existe una dependencia lineal auto explicativa que podría sobre ajustar el modelo en el futuro.

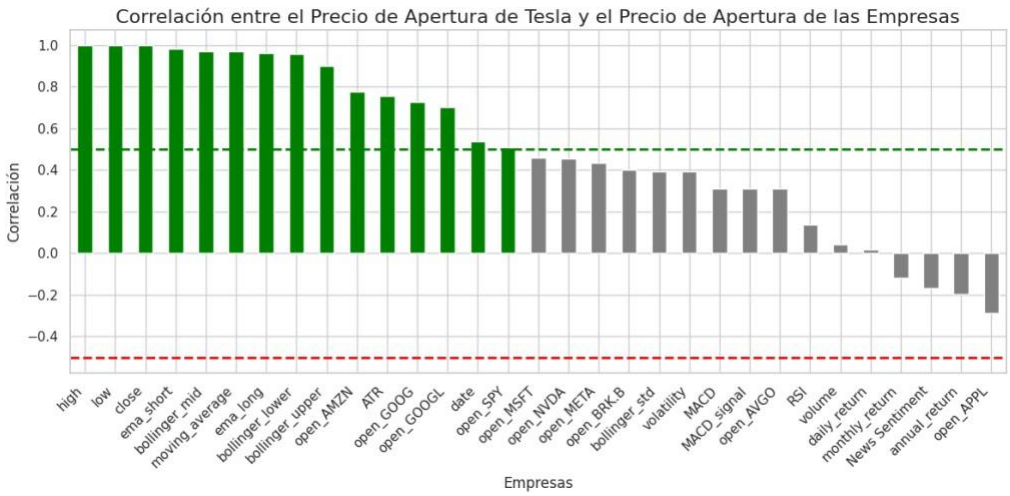


**Ilustración 9.** Estudio correlación entre precio de Tesla y resto de variables.

En este modelo, observamos una correlación alta y positiva entre el ATR (indicador de volatilidad) no solo con los precios de Apple, sino también con el sentimiento económico. Especialmente en 2020, podemos notar un aumento significativo en la volatilidad, acompañado de una caída en el sentimiento y el optimismo del mercado. Es interesante que la volatilidad aumente en un periodo posterior a la caída del sentimiento. Esto podría deberse a que, cuando el mercado experimenta un deterioro en el sentimiento económico, los inversores tienden a reaccionar con una mayor incertidumbre, lo que genera fluctuaciones más pronunciadas en los precios. Este fenómeno refleja cómo las expectativas de los inversores pueden influir en la volatilidad del mercado, con la tendencia a reaccionar de manera más intensa después de un cambio significativo en la confianza del mercado.

### 4.3.3. Estudio de estacionariedad

En cuanto al análisis de estacionariedad, la serie de precios de apertura de Tesla resulta ser estacionaria, lo que significa que sus estadísticas no dependen del tiempo y no presentan tendencias ni varianzas no constantes. Sin embargo, hay otras variables que no son estacionarias, como ‘volume’, ‘open_AAPL’, ‘open_AMZN’, ‘open_AVGO’, ‘open_BRK.B’, ‘open_GOOGL’, ‘open_GOOG’, ‘open_META’, ‘open_MSFT’, ‘open_SPY’, ‘ema_long’, y ‘annual_return’. Para estas variables no estacionarias, aplicamos una transformación logarítmica seguida de diferenciación, ya que este proceso ayuda a estabilizar la varianza y eliminar tendencias. Podemos ver a continuación la Función de Autocorrelación y Autocorrelación Parcial, que muestra correlación entre la variable objetivo y sus rezagos a lo largo del tiempo.

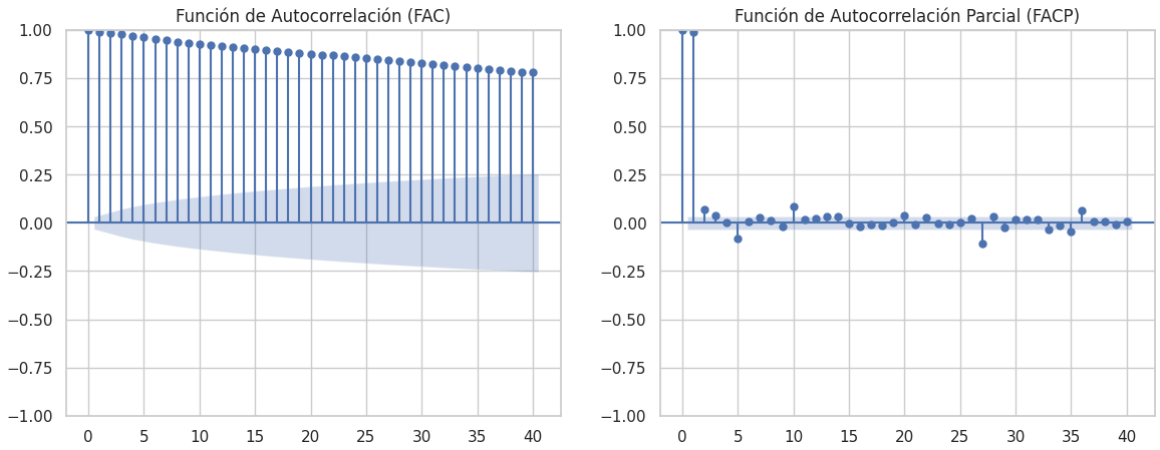


**Ilustración 10.** FAC y FACP de Tesla Stock.

La Prueba de Dickey-Fuller Aumentada (ADF) arroja un Estadístico ADF de -3.2469 y un p-valor de 0.0174, con 28 rezagos y 3,623 observaciones. Dado que el p-valor es menor a 0.05 y el estadístico ADF es inferior al valor crítico del 5% (-2.8623), podemos rechazar la hipótesis nula de raíz unitaria, concluyendo que la serie es estacionaria.

Lo dicho implica que las fluctuaciones del precio de apertura de Tesla no siguen una tendencia a largo plazo y que su comportamiento a lo largo del tiempo es predecible en términos de sus medias y varianzas. Para los modelos predictivos, esto es crucial, ya que muchas técnicas, como ARIMA, requieren que los datos sean estacionarios para hacer predicciones precisas. El resultado del proceso es la siguiente tabla:

**Tabla 5.** Resumen resultante variables post-ETL Tesla Stock.

| Nombre | Tipo | Exógena/Endógena | Fuente |
|---|---|---|---|
| TSLA Price | Cuantitativa | Exógena (Independiente) | Datos de precios históricos (AlphaVantage) |
| Volume | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| News Sentiment | Cuantitativa | Endógena | Shapiro, Sudhof & Wilson (2020), Banco de la Reserva Federal de San Francisco |
| open_APPL | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_AMZN | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_AVGO | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_BRK.B | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_GOOGL | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_GOOG | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_META | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_MSFT | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_NVDA | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| open_TSLA | Cuantitativa | Endógena | Datos de precios históricos (AlphaVantage) |
| RSI | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| ema_short | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| ema_long | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| MACD | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| MACD_signal | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| bollinger_std | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| volatility | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| ATR | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| daily_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| monthly_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |
| annual_return | Cuantitativa | Endógena | Calculado a partir de datos de precios |

Para las empresas Uber, Apple y Planet Fitness se ha seguido un procedimiento estandarizado que incluye la descarga y limpieza de datos, el análisis de correlación entre variables, la creación de nuevas variables derivadas y la gestión adecuada de valores nulos. A partir de este proceso se obtienen dos conjuntos de datos fundamentales: por un lado, los datos tratados del índice S&P 500; y por otro, los de Tesla, que constituyen el núcleo central del estudio. Paralelamente, los conjuntos de datos correspondientes a Uber, Apple y Planet Fitness también quedan completamente preparados, ya que resultan esenciales para validar la hipótesis principal del modelo propuesto. Su inclusión permite contrastar el enfoque aplicado en distintos contextos empresariales y evaluar la utilidad del aprendizaje por transferencia en escenarios con diferentes niveles de similitud y disponibilidad de datos (ver anexos 17 y 18).

# 5. ANÁLISIS DEL DATO

## 5.1. Contextualización del Problema y Estrategia

### 5.1.1. Plan de Acción

El propósito de este trabajo es evaluar si el uso de datos de un activo relacionado con el objetivo puede mejorar la precisión de las predicciones. En este caso, se analiza cómo la incorporación de precios históricos, indicadores técnicos y análisis macroeconómico del mercado estadounidense, en particular del S&P 500, puede optimizar la capacidad predictiva de un modelo enfocado en estimar el precio de uno de sus componentes, Tesla.

Para ello, el proceso técnico iterativo consiste en 4 pasos fundamentales:

1. Entrenamos una red neuronal con todos los datos de tesla hasta la primera fecha desde la cual se tienen datos del activo específico.
2. Clonamos el modelo, mantenemos los pesos iniciales y reentrenamos el modelo con los datos del activo específico.
3. Entrenamos una red neuronal exclusivamente con los datos del activo específico (en este caso Tesla), y realizamos las predicciones en un período de un año.
4. Comparamos los resultados de los dos modelos respecto a la realidad, calculando las principales métricas de error.

En este sentido, la clave del enfoque del trabajo es entender qué tan buena es esta integración de datos de un modelo a otro desde la perspectiva de la **cantidad de datos**

**existentes.** Cuando una empresa como Tesla realiza su IPO (entrada al mercado) en 2010, un inversor que quiera tomar una decisión en el año 2011 contará con solo 1 año de datos (250 entradas diarias), lo que suele ser muy poca magnitud para realizar predicciones en períodos temporales medios y largos, por lo que pobre para invertir en base a ellos[1].

Al utilizar los datos del S&P500, fondo indexado al que pertenece (y por ende la vinculación y relación), se espera encontrar una mejoría sustancial en las predicciones en los primeros períodos, donde un modelo con pocos datos del componente específico (Tesla) esperamos que sea superado por nuestro modelo, que cuenta ya con un entendimiento y conocimiento del funcionamiento de los indicadores de mercados, sus correspondientes interacciones y cambios esperados, mejorando y estabilizando así predicciones tempranas. Por ello se iterará con los distintos tamaños de entrenamiento, año tras año, mientras que test será siempre el año contiguo al entrenamiento del modelo.

Asimismo, se evaluará la utilidad de los modelos GRU y LSTM, ambos diseñados para capturar dependencias temporales en series temporales. Mientras que LSTM, con su mecanismo de memoria, es más eficaz en la captura de relaciones a largo plazo, GRU, al ser más simple y ligero, puede entrenar más rápido con menos datos. Se espera que, en los primeros años, con datos limitados, GRU ofrezca mejores resultados, mientras que, con más datos, LSTM pueda superar su rendimiento. Compararemos ambos enfoques para determinar cuál logra mayor precisión y estabilidad en distintas ventanas de entrenamiento.

### 5.1.2. Preparación del Entorno

En primera instancia, se asegurará la correcta normalización de los datos, previa a la elaboración de los modelos. Para este propósito, aplicamos una técnica de normalización basada en el *Min-Max Scaling*, que transforma los datos a un rango [0, 1]. Este enfoque ayuda a evitar problemas asociados con las diferencias en las escalas de las variables, lo que podría dificultar el proceso de aprendizaje de una red neuronal.

Asimismo, seleccionamos la utilización de ventanas deslizantes de 60 días para configurar la memoria del LSTM. Esencialmente esto es que cada predicción del modelo se basará en la información de los 60 días previos, permitiendo capturar patrones temporales en la evolución del precio. Esta elección busca equilibrar la capacidad del modelo para

[1] Se ha realizado el ajuste de los precios considerando los *stocks splits* realizados por Tesla en 2020 y 2022.

identificar tendencias sin introducir un exceso de ruido. Una ventana demasiado corta podría no captar dinámicas relevantes, mientras que una demasiado larga podría diluir la influencia de eventos recientes, fundamentales de cara a la volatilidad de los activos financieros.

Tal y como advertimos durante el análisis descriptivo, al reemplazar los datos nulos[2] por ceros para preservar el tamaño de la base de datos, se introdujo un sesgo en el modelo, otorgando un peso artificial a estos valores. Para corregirlo, aplicamos *masking*, una estrategia que ignora los ceros durante el entrenamiento, evitando la formación de patrones irreales sin significado técnico o económico. Esto permite mantener la integridad de los datos sin distorsionar las predicciones, asegurando que el modelo se enfoque en relaciones genuinas dentro del mercado financiero y entre las variables introducidas.

## 5.2. Exploración preliminar: primeros modelos

### 5.2.1. Comparación Redes Neuronales en datos financieros: GRU y LSTM

La primera elaboración de modelos nos permite contrastar la hipótesis de que, con pocos datos, GRU supera a LSTM. LSTM (*Long Short-Term Memory*) utiliza celdas de memoria y mecanismos de puertas para controlar el flujo de información, lo que le permite mitigar el problema del desvanecimiento del gradiente y captar relaciones a largo plazo de manera efectiva. Por otro lado, GRU (*Gated Recurrent Unit*) es una versión simplificada de LSTM, con menos parámetros y un mecanismo de actualización más eficiente, lo que puede hacerla más rápida en entrenamiento y adecuada para ciertos contextos con menos datos.

Se espera, por ende, que en escenarios donde el volumen de datos de entrenamiento es limitado (por ejemplo, los primeros años tras la IPO de Tesla), la estructura más simple de GRU pueda ofrecer ventajas en términos de rapidez y eficiencia. Sin embargo, en períodos con mayor disponibilidad de datos históricos, LSTM podría captar mejor las dinámicas complejas del mercado, ofreciendo predicciones más precisas. A través de la experimentación, se evaluará cuál de estos modelos logra un mejor equilibrio entre precisión y estabilidad en distintas ventanas de entrenamiento, determinando así su aplicabilidad en contextos de inversión temprana y a largo plazo.

[2] Fruto de la diferencia entre el inicio del S&P500 y los datos iniciales de la acción vinculada, en función de su IPO.

Para evaluar el rendimiento, utilizamos el MAPE como métrica clave, dado su utilidad en series temporales. El MAPE (*Mean Absolute Percentage Error*) mide el error porcentual absoluto medio entre los valores predichos y los valores reales. Esta métrica es especialmente útil en series temporales financieras, ya que permite evaluar la precisión del modelo de manera relativa, sin depender de la escala de los datos. A diferencia del RMSE, que mide el error en unidades absolutas, el MAPE expresa el error en porcentaje, lo que facilita la comparación entre diferentes activos o períodos de tiempo. Su principal limitación, no obstante, es que puede distorsionarse cuando los valores reales son cercanos a cero, ya que el denominador de la fracción se vuelve muy pequeño y amplifica el error.

Los resultados de los modelos son que, con solo 300 datos, GRU obtiene un MAPE de 25.93, mientras que LSTM alcanza 77, lo que confirma que, en condiciones de escasez de datos, GRU ofrece mejores predicciones. Sin embargo, a medida que aumenta la cantidad de datos de entrenamiento, esta ventaja se diluye. Para 2015, con 4.5 años de datos, LSTM mejora significativamente su rendimiento con un MAPE de 8.6 frente al 16.26 de GRU. En 2024, con 13 años de datos, LSTM sigue mostrando un desempeño superior (MAPE de 9.69 vs. 10.98 en GRU), aunque la diferencia ya no es tan marcada.

**Tabla 6.** Rendimiento GRU vs LSTM (MAPE)

| | GRU | LSTM |
|---|---|---|
| 2012 | 25.93% | 47.28% |
| 2016 | 8.60% | 9.19% |
| 2021 | 8.90% | 7.76% |
| 2024 | 10.98% | 9.69% |

El análisis del RMSE refuerza esta tendencia: en el corto plazo, GRU muestra una ligera ventaja, pero a medida que el volumen de datos crece, LSTM ofrece mejores resultados. Si bien la diferencia no es abismal, estos hallazgos nos permiten definir la estrategia de nuestro modelo: GRU se adapta mejor a escenarios con datos limitados, mientras que LSTM muestra su fortaleza cuando se dispone de un histórico más amplio.

### 5.2.2. Redes Neuronales y Transfer Learning: Tesla

A continuación, se realiza un análisis comparativo entre el modelo mejorado (pre-entrenado con los datos del S&P500 y *Fine-Tuned* con los datos de Tesla) respecto al modelo crudo, únicamente con los datos de Tesla. Esta primera prueba se realiza 4 veces: para 2011, 2015, 2020, 2023. Esquemáticamente, para obtener las predicciones para el 2023, se ha entrenado con los datos de S&P500 hasta el 2022, clonado y posteriormente aplicado *Fine-Tuning* con los datos de Tesla, desde 2010 (IPO Tesla), hasta 2022, y se predice en para 2023. A continuación, se ve cómo se gestiona el entrenamiento de cada modelo:

**Ilustración 11.** Maquetación modelo con *Transfer Learning*.

Donde el año elegido suele ser el siguiente al actual. Es decir, si estuviésemos en 2012 y quisiésemos ver cómo se comporta Tesla el año que viene, 2013 sería nuestro año objetivo. Por ello, el conjunto de entrenamiento es dinámico en función del año de predicción seleccionado. El modelo normal está entrenado únicamente con los datos disponibles de Tesla desde el año 2010 hasta el objeto a predicción.

Por cada ejecución, por ende, se crean dos modelos: uno con *Transfer Learning* (pre-entrenado con el S&P500), y otro sin *Transfer Learning*. Y se comparan respecto a su capacidad predictiva y precisión en el año deseado. Las primeras pruebas realizadas con 50 épocas para cada modelo y la inclusión de *early stopping* para evitar sobreajuste al training set original derivan resultados prometedores:

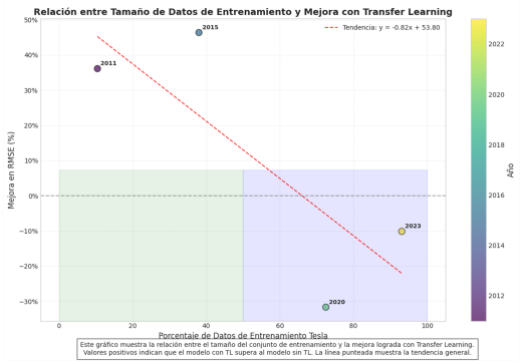


**Ilustración 12.** Correlación entre el tamaño de datos de entrenamiento y mejoría con TL.

Con los resultados iniciales, hemos hecho un cálculo de la mejora porcentual en RMSE del modelo con *Transfer Learning* respecto a aquel sin *Transfer Learning*. Para las predicciones de Tesla, con solo un año de datos de entrenamientos (inferior a lo necesario para un modelo robusto en predicciones a un año) el modelo con Transfer Learning obtiene un resultado un 37% mejores, y con 4 años de datos, un 45% de mejoría. Esto implica que, cuando hay pocos datos, el modelo con Transferencia de conocimiento es considerablemente mejor.

No obstante, hay una tendencia negativa. Y en períodos con muchos datos (10 años en 2020, 13 años en 2023) el modelo con *Transfer Learning* es considerablemente peor, atribuible a un sobreajuste a los datos del S&P500.

Por lo que llegamos a una segunda conclusión respecto a nuestra propuesta: conforme aumenta la cantidad de datos disponibles del activo objetivo (en este caso, Tesla), se reduce la mejoría atribuible al pre-entrenamiento con datos del S&P500 y rinde mejor un modelo con menos ajuste al S&P500.

## 5.3. Estrategia de ajuste de hiperparámetros dinámica

### 5.3.1. Formulación de la Estrategia para Tesla

En base a las conclusiones iniciales, formuladas ahora como hipótesis a validar, se desarrolla una estrategia dinámica de ajuste de hiperparámetros. El objetivo principal es reducir progresivamente la influencia de los datos del S&P 500 a medida que aumenta la disponibilidad de datos específicos de Tesla. En los primeros años, cuando el historial de Tesla es limitado, se prioriza el preentrenamiento con el S&P 500 para proporcionar una base sólida sin incurrir en sobreajuste. Sin embargo, conforme se amplía el conjunto de datos de Tesla, el modelo debe depender progresivamente más de su propia información, ajustándose a su comportamiento particular.

La estrategia de ajuste de hiperparámetros se basa en tres aspectos clave: (1) capas a congelar, (2) épocas de entrenamiento para el modelo base (S&P 500) y (3) épocas para el fine-tuning (activo específico, Tesla). La congelación de capas implica mantener constantes los pesos de ciertas capas de la red neuronal durante el entrenamiento, evitando su actualización y permitiendo que solo las capas restantes se ajusten a los nuevos datos. Esto

permite conservar las características generales aprendidas por el modelo base y mitigar el riesgo de sobreajuste.

En cuanto a las épocas de entrenamiento, el modelo base se entrena durante un número determinado de iteraciones hasta que los parámetros generales del S&P 500 converjan. Posteriormente, en la fase de *fine-tuning*, se permite una mayor adaptación a las particularidades de Tesla, ajustando los pesos de manera específica. Además, se implementa *early stopping* para evitar el sobreajuste, deteniendo el entrenamiento cuando el rendimiento en el conjunto de validación deje de mejorar.

Para garantizar una transición óptima entre el modelo base y el fine-tuning en Tesla, se implementa un ajuste progresivo en la congelación de capas, las épocas de entrenamiento y la selección del modelo óptimo según la cantidad de datos disponibles.

En primer lugar, la **cantidad de capas congeladas** se determina en función del historial de datos de Tesla. A medida que aumenta el número de años de datos, se reduce la cantidad de capas congeladas, permitiendo que el modelo se adapte progresivamente a las particularidades de la empresa. En los primeros años, donde la información de Tesla es escasa, se prioriza el aprovechamiento de las características generales del S&P 500, lo que implica congelar la mayoría de las capas. Sin embargo, conforme el modelo dispone de más datos propios, se van descongelando capas para que el aprendizaje se enfoque en patrones específicos de Tesla, mejorando su precisión sin perder la base estructural adquirida del S&P 500.

Por otro lado, el **número de épocas de entrenamiento** varía tanto en la fase de preentrenamiento como en la de fine-tuning. Inicialmente, el modelo base se entrena con 50 épocas, pero este número disminuye conforme se incrementa el historial de Tesla. Esto se debe a que, con más datos específicos de la empresa, la necesidad de depender de una base general disminuye. Paralelamente, el número de épocas dedicadas al fine-tuning aumenta progresivamente, permitiendo que el modelo refine su aprendizaje en función de los datos particulares de Tesla. Este balance busca optimizar la transición del conocimiento general del S&P 500 al conocimiento específico del activo, evitando tanto el sobreajuste como un ajuste insuficiente.

Finalmente, la selección del **tipo de modelo** depende del número de años de datos disponibles. Cuando Tesla cuenta con cinco años o menos de historial, se emplea GRU, dado que este modelo tiende a adaptarse mejor a secuencias cortas y muestra mejor desempeño con conjuntos de datos reducidos. En cambio, cuando se superan los cinco años de datos, se opta por LSTM, ya que su capacidad de capturar dependencias a largo plazo lo hace más adecuado para analizar tendencias extensas y complejas en series temporales con mayor volumen de información.

Este enfoque permite que el modelo evolucione de manera natural a medida que se dispone de más datos, garantizando una transición efectiva desde un conocimiento generalista basado en el mercado hacia una comprensión más precisa del comportamiento individual de Tesla.

### 5.3.2. Resultados de la Estrategia: Modelos Óptimos

Desarrollamos modelos anuales, utilizando como métrica de evaluación el MAPE de las predicciones a un año de las acciones de Tesla. Asimismo, guardamos otras métricas como el error cuadrático medio (RMSE), el $R^2$ y el MAE, que se calculan en el período anual posterior al último día de entrenamiento.

Iniciamos el análisis con el año 2012, situándonos en la perspectiva de un inversor a finales de 2011 que debe decidir si invertir o no en acciones de Tesla. Aplicamos nuestra estrategia considerando la limitada cantidad de datos disponibles: solo 300 registros diarios del precio de la acción, un volumen insuficiente para entrenar un modelo robusto. No obstante, entrenamos una red neuronal exclusivamente con estos datos de Tesla para evaluar su rendimiento. En paralelo, construimos otro modelo pre-entrenado con datos del S&P 500 hasta finales de 2010 (año de la IPO de Tesla) y luego aplicamos Transfer Learning, ajustándolo a los datos específicos de Tesla. Finalmente, utilizamos ambos modelos para realizar predicciones.

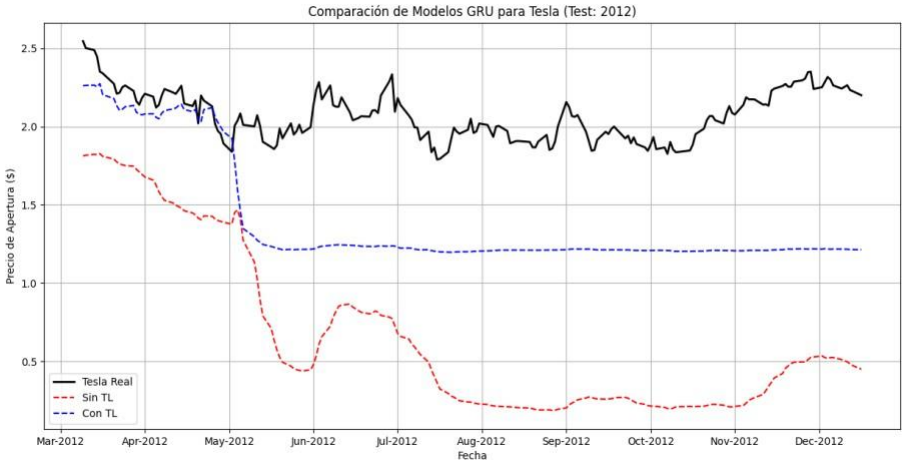


**Ilustración 13.** Predicciones Modelo GRU para Tesla (2012).

Los resultados muestran que, durante los dos primeros meses de predicción, el modelo con *Transfer Learning* (TL) logra una precisión notablemente superior, capturando patrones del mercado con gran fidelidad. En contraste, el modelo entrenado solo con los datos de Tesla no logra identificar adecuadamente las dinámicas del activo. A partir del tercer mes, la precisión de ambos modelos disminuye considerablemente, lo cual es esperable debido a la naturaleza cambiante del mercado. Sin embargo, el modelo con Transfer Learning sigue superando al modelo puro. En términos globales, el modelo con TL alcanza un MAPE de 33%, frente al 66% del modelo sin TL. Esto implica que la transferencia de conocimiento desde el S&P 500 permite mejorar significativamente la capacidad predictiva en los primeros períodos de cotización de Tesla, mitigando la escasez de datos propios y proporcionando estimaciones más confiables para la toma de decisiones de inversión.

Repetimos este proceso año a año, registrando las principales métricas de evaluación de los modelos. Entre ellas destacan el MAPE (Mean Absolute Percentage Error), el RMSE (Root Mean Squared Error) y el coeficiente de determinación ($R^2$). A continuación, presentamos los resultados obtenidos, junto con la configuración dinámica de hiperparámetros utilizada en cada periodo.

| | RMSE Sin TL | RMSE Con TL | R2 Sin TL | R2 Con TL | MAPE Sin TL | MAPE Con TL | Porcentaje Train Tesla | Modelo (GRU / LSTM) | Años de datos | Épocas modelo base | Épocas fine-tuning | Capas congeladas |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **2012** | 1.484141 | **0.744926** | -88.025512 | -21.427953 | 68.891725 | **32.821397** | 10.460022 | GRU | 1.505818 | 49 | 30 | 3 |
| **2013** | 6.531817 | **5.820252** | -4.359348 | -3.255273 | 68.323998 | **59.865952** | 17.305586 | GRU | 2.507871 | 48 | 31 | 2 |
| **2014** | **7.836866** | 7.926629 | -23.67519 | -24.243685 | 49.546953 | **37.151804** | 24.205915 | GRU | 3.507187 | 48 | 31 | 2 |
| **2015** | 2.113021 | **0.936248** | -1.488057 | 0.511534 | 11.93482 | **4.724238** | 31.106243 | GRU | 4.506502 | 47 | 32 | 1 |
| **2016** | 2.973599 | **2.290353** | -4.712513 | -2.388966 | 18.349126 | **16.054575** | 38.006572 | LSTM | 5.505818 | 47 | 32 | 1 |
| **2017** | 6.492343 | **3.456971** | -14.665829 | -3.441625 | 28.536696 | **14.79459** | 44.9069 | LSTM | 6.507871 | 46 | 33 | 0 |
| **2018** | 1.455088 | **1.421437** | 0.480634 | 0.504378 | **5.272923** | 6.043538 | 51.779847 | LSTM | 7.507187 | 46 | 33 | 0 |
| **2019** | **1.087505** | 1.761707 | 0.914515 | 0.775665 | **5.16078** | 9.030037 | 58.652793 | LSTM | 8.506502 | 45 | 34 | 0 |
| **2020** | **90.557873** | 98.060634 | -1.900715 | -2.401277 | **60.189882** | 66.122031 | 65.553122 | LSTM | 9.505818 | 45 | 34 | 0 |
| **2021** | **55.091146** | 62.235496 | 0.121135 | -0.121593 | 15.767428 | **14.124048** | 72.480832 | LSTM | 10.507871 | 44 | 35 | 0 |
| **2022** | **25.660297** | 37.242022 | 0.789729 | 0.557083 | **8.996523** | 15.429963 | 79.381161 | LSTM | 11.507187 | 44 | 35 | 0 |
| **2023** | 12.3115 | **8.438407** | 0.873426 | 0.940538 | 4.515805 | **2.770935** | 86.254107 | LSTM | 12.506502 | 43 | 36 | 0 |
| **2024** | **38.94177** | 56.825856 | 0.745908 | 0.458933 | **14.661286** | 16.698948 | 93.099671 | LSTM | 13.505818 | 43 | 36 | 0 |

**Tabla 7.** Compilación métricas de error modelos Tesla.

En negrita, destacamos el modelo superior en términos de MAPE. Salvo en cinco periodos, nuestro modelo con Transfer Learning obtiene mejores resultados. Desde el primer año, observamos que el modelo preentrenado con datos del S&P 500 logra un ajuste considerablemente superior, lo que indica que ha sido capaz de capturar patrones generales en la relación entre los indicadores técnicos y macroeconómicos y el precio de la acción objetivo, incluso si la dinámica y la escala de precios de Tesla difieren de las del índice.

Los años en los que el modelo sin Transfer Learning supera al otro son 2018, 2019, 2020, 2022 y 2024. Sin embargo, en 2018, 2021 y 2024, la diferencia de MAPE es inferior al 1%, lo que entra dentro del margen de error aceptable, permitiendo considerar que en esos años ambos modelos tienen una precisión comparable.

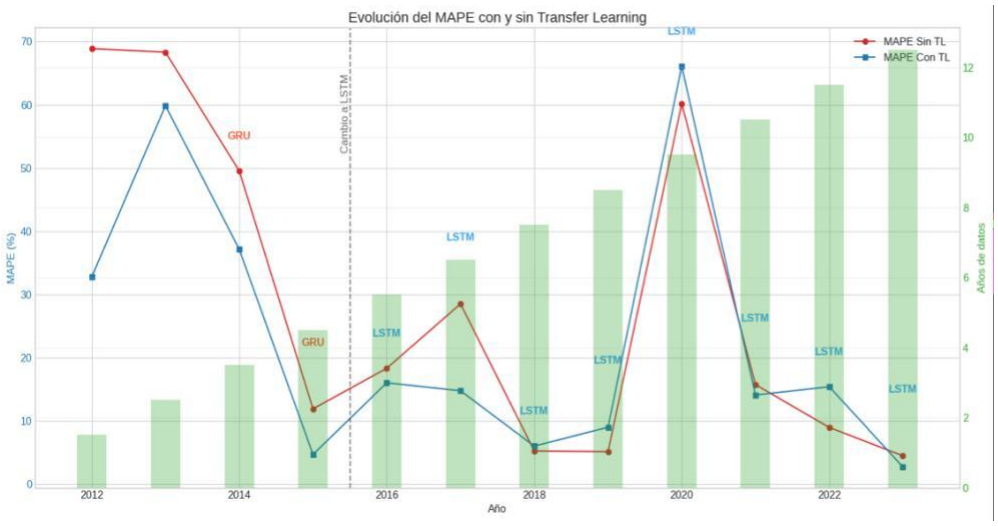


**Ilustración 14.** Evolución MAPE de modelos con y sin *Transfer Learning* (Tesla).

El año 2020 es un caso atípico. La crisis provocada por el COVID-19 generó una volatilidad extrema en los mercados financieros, lo que se refleja en un MAPE superior al 60% en ambos modelos y un $R^2$ negativo (-1.9 y -2.4, respectivamente), indicando que las predicciones no capturan la variabilidad del precio con precisión. Este comportamiento se debe a la gran incertidumbre del mercado en ese periodo, en el que sectores como el energético experimentaron crecimientos abruptos y desproporcionados.

Finalmente, observamos que el modelo con *Transfer Learning* es capaz de mejorar la precisión (medida por el MAPE) más rápidamente en los primeros años de entrenamiento. El gráfico de barras transpuesto que se corresponde con el eje del lado derecho representa el año de datos (250 anuales) disponibles para cada modelo creado.

Asimismo, a partir de 2018 (cuando el modelo ya ha sido entrenado con 7 años de datos), la capacidad de las redes LSTM para recordar información relevante y olvidar detalles menos significativos empieza a estabilizar el rendimiento del modelo (ver anexo 15). Este comportamiento se debe al mecanismo de puertas de memoria en las LSTM, que filtra la información relevante conforme aumenta el historial de datos.

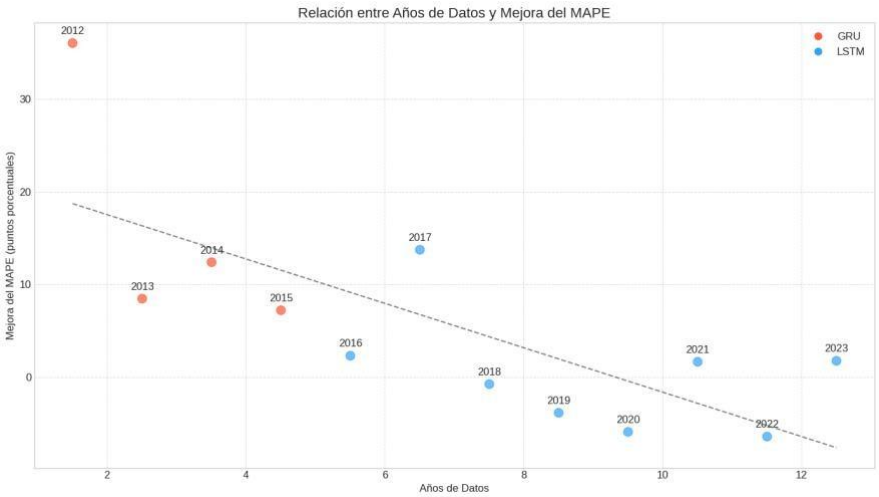


**Ilustración 15.** Relación entre años de datos y mejora porcentual del MAPE (TL - s/TL).

Como resultado, las predicciones de ambos modelos convergen dentro de un margen de error aceptable, obteniendo desempeños similares en los últimos años, donde la mejoría del MAPE tiende a 0. La pendiente de la Ilustración 15 demuestra como, mientras más datos disponibles hay, menos se beneficia el activo específico de la transferencia de conocimiento.

### 5.4. Backtesting de la estrategia: UBER.

La hipótesis que estamos buscando validar es si la aplicación de Transfer Learning, utilizando un modelo preentrenado con los datos del S&P 500, mejora la capacidad predictiva para activos individuales. Este modelo se ha mostrado eficaz en la detección de patrones técnicos y macroeconómicos generales, lo que sugiere que la estrategia podría ser igualmente efectiva cuando se aplica a empresas con datos más limitados. Para probar esta hipótesis, decidimos realizar un backtesting de la estrategia en el caso de Uber, cuya salida a bolsa (IPO) ocurrió el 10 de mayo de 2019.

La reciente entrada de Uber en los mercados financieros implica que la disponibilidad de datos históricos de la empresa es limitada, lo que hace que esta situación sea particularmente adecuada para aplicar Transfer Learning y evaluar su capacidad para mejorar las predicciones, especialmente en sus primeros años de cotización.

El proceso de ejecución para Uber se hará con la estrategia de ajuste de hiperparámetros a la que llegamos con Tesla, entrenando un modelo hasta el año 2019 (justo el día de la IPO de Uber, ver gráfico 1), clonándolo y a partir de ahí aplicando el ajuste fino a los datos de Uber concretos.

El primer modelo dispone de un año y medio de datos, por lo que, siguiendo la estrategia definida, se aplica un modelo GRU. En este caso, se congelan 3 capas del modelo base, dejando 49 capas para el modelo base y 30 capas para el fine-tuning con los precios de Tesla. Los resultados de las predicciones muestran que ambos modelos tienen un comportamiento similar, con métricas de error muy cercanas.

**Ilustración 16.** Predicciones Modelo GRU para Uber (2021).

Sin embargo, en 2022 se observa una notable diferencia entre ambos modelos: mientras que el modelo sin Transfer Learning presenta un comportamiento errático (debido, lógicamente, a la falta de datos), el modelo con Transfer Learning es capaz de capturar de manera sobresaliente la tendencia general del mercado. A pesar de esto, es importante reconocer que, en los meses posteriores a agosto de 2022, el modelo sin Transfer Learning muestra un comportamiento más regular, con las predicciones acercándose bastante a la realidad, aunque con una diferencia constante de aproximadamente 10 dólares en el precio.

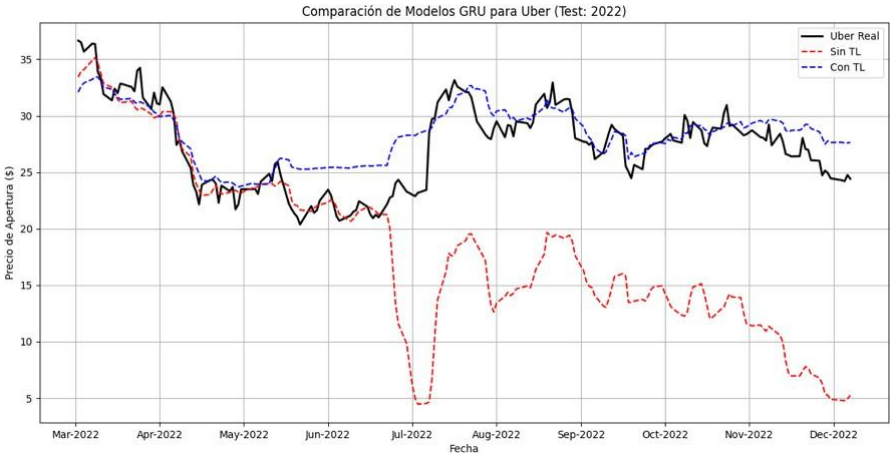


**Ilustración 17.** Predicciones Modelo GRU para Uber (2022).

En 2023 vemos como existe cierta convergencia: ambos modelo muestran buena precisión, ganando por una leve diferencia el modelo sin Transfer Learning.

**Ilustración 18.** Predicciones Modelo GRU para Uber (2023).

No obstante, las predicciones realizadas para el año 2024 (ver anexo 5) son considerablemente mejores cuando no se aplica Transfer Learning (gráfico 10), aunque en ambos casos los resultados siguen siendo insatisfactorios. Esta discrepancia se puede explicar por la volatilidad del mercado. Como mencionamos anteriormente, las predicciones de 2021 fueron particularmente erróneas, lo cual atribuimos principalmente a la falta de datos suficientes. Sin embargo, un factor adicional a considerar es la volatilidad, para la cual contamos con las métricas de Volatilidad (ATR). En 2021, la volatilidad de los mercados, impulsada por la recuperación económica post-COVID-19 y el repunte en diversas industrias, afectó significativamente las predicciones de Uber.

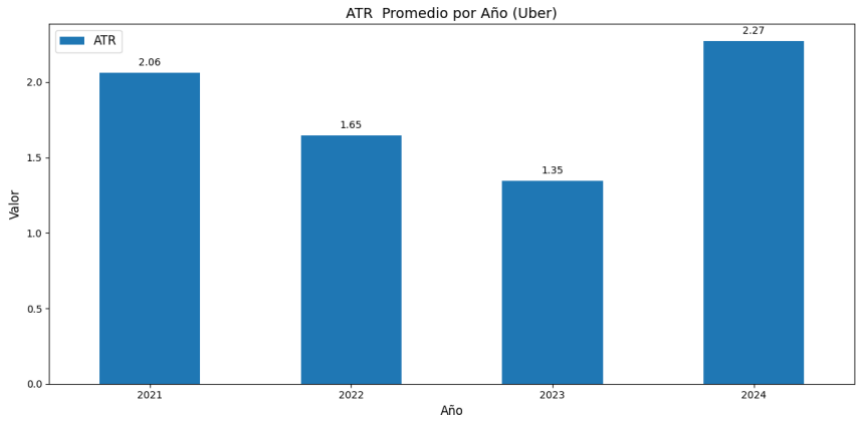


**Ilustración 19.** Análisis de Volatilidad (ATR) anual.

En 2024, se observan niveles de volatilidad similares, lo que podría estar contribuyendo a la imprecisión de las predicciones. En ese año, Uber enfrentó desafíos adicionales relacionados con los ciclos económicos, como la desaceleración de la demanda en ciertos mercados clave, fluctuaciones en los precios del combustible, y cambios regulatorios a nivel global, lo cual pudo haber impactado en sus operaciones. Estos factores pudieron haber influido en la volatilidad de sus precios y, por ende, en la capacidad predictiva de los modelos.

No obstante, respecto a la volatilidad no hemos podido hallar ninguna correlación directa con la impresición de los modelos con Transfer Learning para las predicciones de Tesla. El ATR annual respecto del MAPE tienen un coeficiente de correlación de 0.3, lo cual es bastante bajo para indicar la existencia de cualquier vinculación entre ambos factores. Por lo pronto, podemos apreciar el comportamiento del MAPE según el año a predecir y, por consiguiente, la cantidad de datos disponibles:

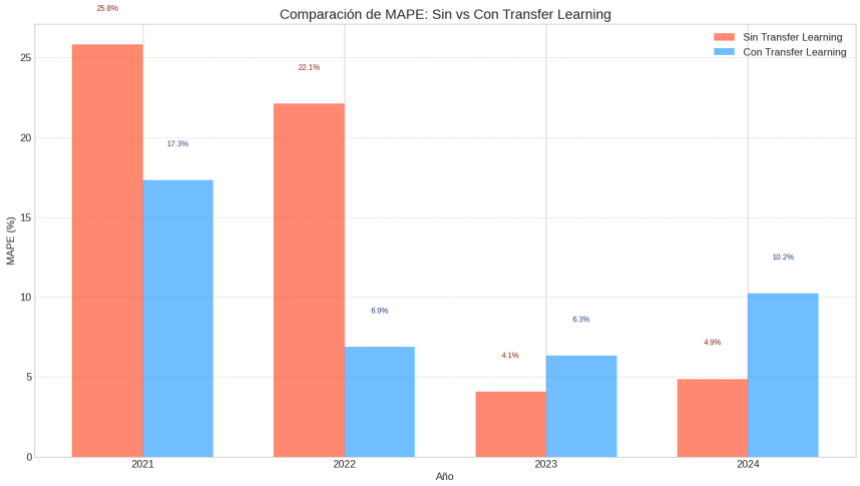


**Ilustración 20.** Resumen resultados estrategia hiperparámetros: Uber.

Con lo visto, hemos podido comprobar que los modelos elaborados son en terminos absolutos, mejores con Transfer Learning, principalmente en los primeros años en pos de la reducción del MAPE. A partir de cierto año, se alcanza una convergencia debido a la naturaleza y funcionamiento de las redes neuronales, donde las neuronas van olvidando la información antigua y por tanto hay un claro cruce entre ambas, evaluadas a través de las métricas de evaluación más importantes. Más adelante veremos como esto se explica desde la correlación entre los activos origen y destino.

### 5.5. Backtesting de hipótesis: Apple y Planet Fitness.

Como se mencionó anteriormente, no encontramos una relación directa entre la volatilidad del precio de apertura del activo y la eficacia del Transfer Learning en este caso en concreto. Por ello, evaluamos otras dos empresas, para determinar si esto se explica dado el nivel de similitud existente con el activo objetivo (ya sea cuantitativa o cualitativa). Por un lado, presentamos a Apple, empresa que acompaña al índice desde hace más de 30 años, siendo una de las empresas más importantes de Estados Unidos, su comportamiento económico es reflejo (ya sea por causalidad o consecuensialidad) de la situación macroeconómica del país, consecuente al S&P500.

Por otro lado, Planet Fitness, si bien es una empresa de notable relevancia dentro del mercado estadounidense, no forma parte del índice S&P 500 y pertenece además a un sector completamente distinto. A diferencia de la mayoría de las compañías que integran el S&P 500 (concentradas en sectores como tecnología, energía, finanzas o salud, y cuya capitalización bursátil y volumen de transacciones reflejan un comportamiento altamente influenciado por dinámicas macroeconómicas globales) Planet Fitness opera en el ámbito del bienestar físico y el fitness minorista, con un modelo de negocio centrado en franquicias y las suscripciones individuales. Esta diferencia estructural y sectorial marca una distancia significativa respecto al tipo de activos analizados en este trabajo, lo que justificaría si los resultados del *Transfer Learning* en este caso particular fuesen menos notables.

Por ello, iteramos nuevamente el proceso, aplicando la estrategia dinámica de ajuste de hiperparámetros previamente definida durante el backtesting. En el caso particular de Apple, disponemos de datos históricos desde el año 1999, coincidiendo con el mismo punto de inicio desde el cual se han recopilado los datos del S&P 500. Sin embargo, para efectos del experimento y con el objetivo de evaluar la utilidad del aprendizaje por transferencia en

contextos con historial limitado, se simula una IPO hipotética de Apple en el año 2005. Esta elección resulta razonable, ya que dicho año representó un punto de inflexión estratégico en la evolución de la compañía. En consecuencia, el modelo se preentrenará con los datos del S&P 500 hasta el año 2005, y a partir de ese momento utilizará los datos de Apple disponibles, ajustándose dinámicamente en función del año específico elegido para la predicción.

En el caso de Planet Fitness, contamos con datos desde el 2015, por lo que al mismo tiempo nos permite evaluar el impacto en un período temporal distinto a Uber y Tesla, evaluadas anteriormente. Con ello, repetimos el proceso, y realizamos dos modelos para cada año desde el año inicial seleccionado (es decir, 36 modelos para Apple y 18 para Planet Fitness), uno con Transfer Learning y el otro sin. Del mismo modo, reservamos las métricas de error más importantes con el fin de compararlas. Para Apple, los resultados son bastante buenos tomando por referencia el MAPE (error porcentual de las predicciones):

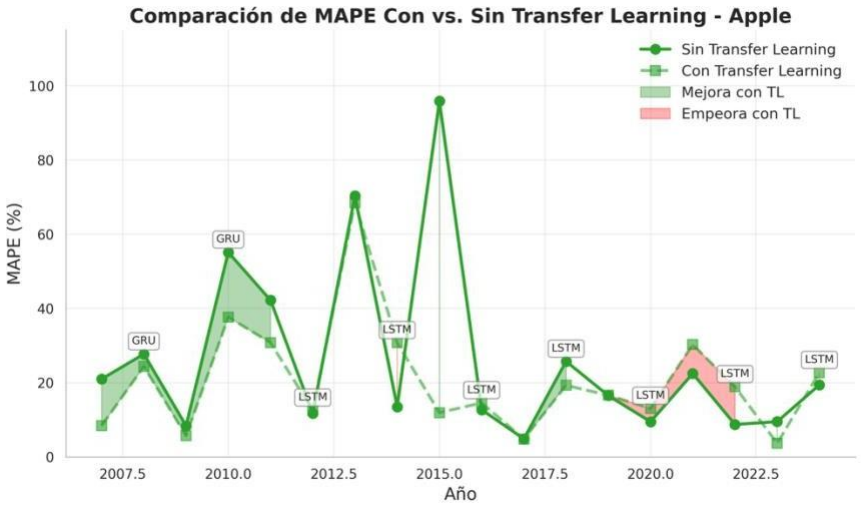


**Ilustración 21.** Estudio Error Modelos Apple Con vs. Sin Transfer Learning.

Como podemos ver, el modelo con Transfer Learning es mejor que aquel sin Transfer Learning, especialmente y de forma repetitiva en los primeros años (entre 2007 y 2015). A partir de ahí, nuevamente vemos cierta onvergencia entre ambos (similar a lo visto con Tesla), donde ambos modelos parecen tener una similitud en cuanto a las predicciones.

En el caso de Planet Fitness, se aprecia una considerable mejora en el primer año. Esto es entendible dado que el Transfer Learning aporta un modelo robusto que permite en un contexto de pocos datos reducir la volatilidad inherente a indicadores de los cuales una red neuronal recurrente requiere un mayor volumen para comprender.

**Ilustración 22.** Estudio Error Modelos Planet Fitness Con vs. Sin Transfer Learning.

No obstante, esta ventaja inicial no se mantiene de forma constante a lo largo del tiempo. En los dos periodos siguientes, el modelo con Transfer Learning es superado por el modelo convencional, entrenado exclusivamente con los datos del activo específico. Esto evidencia que no puede afirmarse categóricamente que uno de los enfoques sea superior al otro en todos los contextos. En efecto, los resultados muestran que en los años intermedios (particularmente entre 2018 y 2022) el modelo con Transfer Learning obtiene un desempeño claramente más favorable, y logra mantenerse ligeramente por delante también en los tres periodos finales, aunque con diferencias mínimas.

En términos cuantitativos, la mejora promedio en el MAPE obtenida por el modelo con Transfer Learning en el caso de Planet Fitness es apenas del 0.41%, una diferencia marginal que indica un rendimiento prácticamente equivalente. En cambio, para Apple, la mejora alcanza un 5.60%, lo que sugiere una mayor utilidad del enfoque transferido en empresas con mayor estructura de datos y comportamiento más alineado con los patrones generales del mercado (ver Ilustración 23).

De esto podemos extraer una conclusión fundamental: el *transfer learning* funciona mejor con activo que tienen una mayor relación con el conjunto de datos de preentrenamiento, en este caso el S&P500. Para situarnos, no solo Apple tiene una mayor relación financiera, macroeconómiuca e histórica con el S&P500, sino que también por su volumen están muy ligadas. En terminos cuantitativos, lo podemos evaluar con la correlación de ambos activos. A continuación, se presentan dos gráficas que denotan de forma concluyente este argumento: por un lado, la mejora porcentual absoluta del MAPE cuando se emplea Transfer Learning, y la segunda la correlación de cada activo con el S&P500.

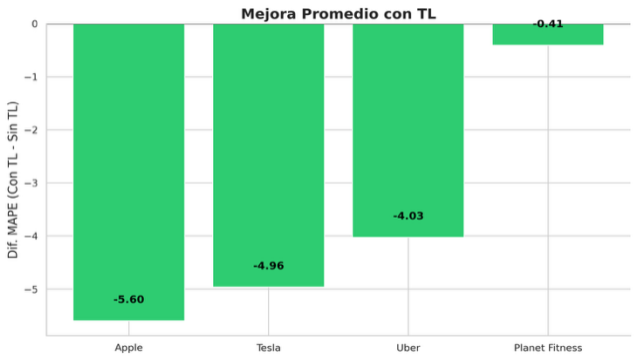


**Ilustración 24.** Resumen mejora promedio por empresa con Transfer Learning.

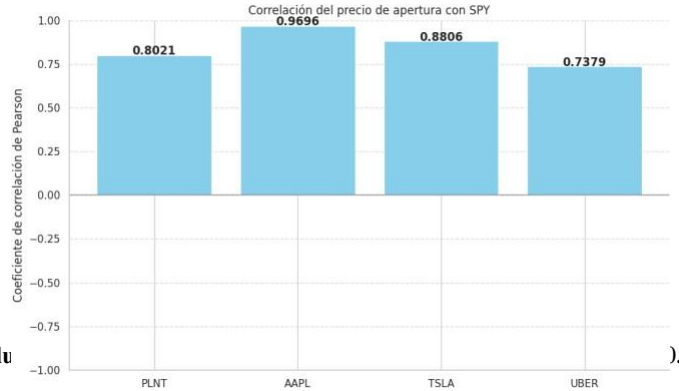


**Ilu** ).

Desde una perspectiva cuantitativa, se observa que Apple, al ser la empresa con mayor correlación histórica con el índice S&P 500, es también la que más se beneficia de la aplicación del Transfer Learning en sus predicciones. Aunque Planet Fitness presenta una correlación significativa, esta es notablemente inferior, lo que sugiere que una correlación financiera parcial no garantiza necesariamente la utilidad del aprendizaje por transferencia. Esta observación respalda la hipótesis de que la similitud entre activos debe ir más allá del comportamiento estadístico y contemplar también elementos estructurales como el sector, el modelo de negocio o la sensibilidad macroeconómica.

En el caso de Uber, que presenta la correlación más baja del conjunto analizado, la mejora promedio mediante *Transfer Learning* alcanza un 4%, superando incluso a Planet Fitness. No obstante, este resultado debe interpretarse con cautela, ya que Uber cuenta con un historial de datos muy limitado desde su salida a bolsa, y sus primeros años de cotización han estado marcados por eventos extraordinarios como la pandemia y crisis sectoriales puntuales. Además, como vimos en la Ilustración 20, en los últimos dos años el modelo sin Transfer Learning fue mejor, pero la mejora abrupta en los primeros dos falsea el neto. El

hecho de que el Transfer Learning haya favorecido, pero no radicalmente ni en todos los periodos, se explica por la correlación de los activos.

Por ello, en las cuatro empresas evaluadas se confirma un patrón común: durante los primeros años posteriores a la IPO, el uso del *Transfer Learning* proporciona una ventaja significativa, reduciendo la volatilidad de las predicciones y ofreciendo una comprensión estructural de los datos que una red neuronal entrenada con apenas 200 registros no puede alcanzar de forma autónoma. Por último, es importante reconocer que las diferencias observadas entre empresas no se explican únicamente por la cantidad de datos disponibles, sino también por factores cualitativos.

El caso de Planet Fitness evidencia que el beneficio del *Transfer Learning* disminuye cuando el activo objetivo se aleja sustancialmente del perfil del activo fuente. Así, se confirma que la identificación previa de la similitud entre activos resulta crítica para aplicar de forma efectiva y dinámica la transferencia de conocimiento en contextos financieros.

### 5.6. Resumen de Resultados

En síntesis, obtenemos que el *Transfer Learning* mejora significativamente las predicciones de los activos financieros. Concretamente, cuando existe una similitud entre el activo de entrenamiento y el componente objetivo, ya sea por cuestiones cuantitativas o cualitativas.

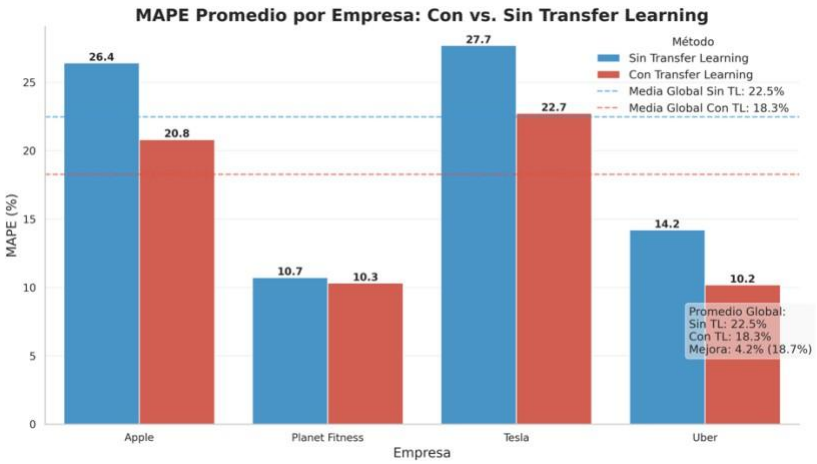


**Ilustración 25.** Síntesis MAPE promedio por Empresa (Con vs. Sin *Transfer Learning*).

Asimismo, se ha desarrollado una estrategia de ajuste de hiperparámetros dinámica y generalizable, capaz de adaptarse a las características del activo y al volumen de datos

disponible en cada escenario. Esta estrategia no solo permite alternar entre diferentes arquitecturas de red neuronal (principalmente GRU y LSTM), sino que también gestiona de forma flexible el número de capas congeladas y las épocas destinadas tanto al preentrenamiento como al fine-tuning.

Considerando que por cada año se generan dos modelos para cada empresa (uno con Transfer Learning y otro sin), se construye un gráfico que sintetiza de manera global los resultados obtenidos. En él se representa la mejora porcentual del MAPE en cada periodo predicho, permitiendo visualizar de forma clara la evolución comparativa de ambos enfoques. Los resultados son en general positivos y respaldan la hipótesis inicial de este trabajo: la transferencia de conocimiento puede mejorar de forma significativa la precisión de las predicciones, especialmente en contextos con datos limitados o inestabilidad inicial.

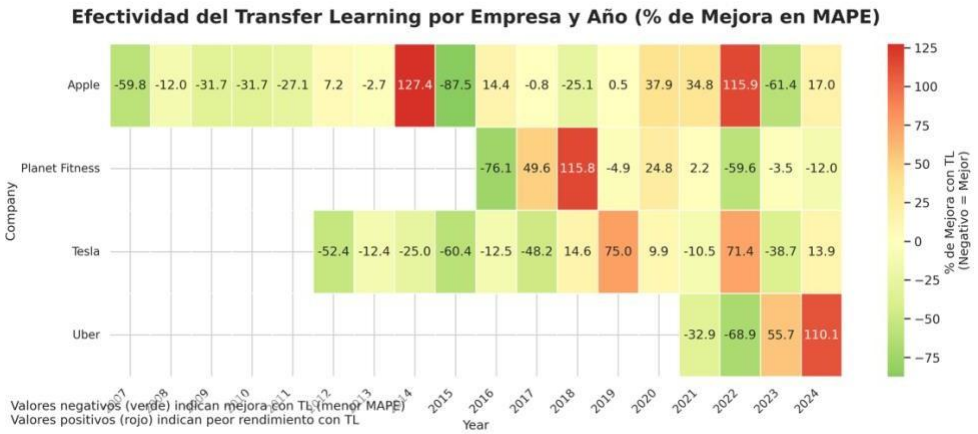


**Ilustración 26.** Heatmap: Efectividad del *Transfer Learning* por empresa y año.

## 6. ANÁLISIS DE NEGOCIO

### 6.1. Presentación de la propuesta

Hoy en día, son los datos la clave de la mejoría predictiva de nuestros modelos. Tendemos a pensar que, a más datos, mejores resultados. Y es así. Sin embargo, no podemos dejar que la falta de datos sean un impedimento, dado que es justamente la inversión temprana la que permite anticiparse y adquirir posiciones a mediano y largo plazo mucho más competitivas. La trasferencia de conocimiento no solo ha demostrado mejorar las predicciones del activo específico, aprendiendo rápidamente los patrones comunes entre ambos, así como las tendencias inherentes al mercado financiero, sino que también ha alcanzado una mejor precisión con escasos datos, permitiendo una temprana toma de decisiones en un entorno globalizado donde el *quant trading* se caracteriza por ser VUCA.

Por ello, dado el impacto positivo de la transferencia de conocimiento en modelos predictivos financieros, la propuesta de negocio concreta es la utilización de modelos financieros robustecidos con transferencia de conocimiento. En esencia, un fondo de inversión que se especialice en la predicción de precios de activos cuyo historial de datos sea escaso, pero demuestren cierto grado de similitud con otro activo del ecosistema. Una propuesta de valor que en vez de apostar por "lo mismo de siempre", crea de manera única un océano azul, un entorno de menor competencia debido a la diferenciación de dicho fondo: especialistas en reducción de volatilidad e imprecisión en entornos de inversión más complejos.

Dichos modelos son una respuesta a la tendencia general del mercado: con el nivel de tecnologización actual, exacerbado por la inteligencia artificial y la disrupción constante, donde nuevas empresas emergen con propuestas innovadoras sin contar con datos históricos suficientes para predicciones confiables. La mayoría de los fondos de inversión tradicionales tienden a operar con estrategias a corto plazo debido a la incertidumbre asociada con estos activos, o jugar a lo seguro con posiciones excesivamente conocidas, con basto historial, manteniendo rendimientos bajos pero estables. En contraste, la solución propuesta se fundamenta en la creación de un modelo de similitud de activos que identifique empresas con patrones de comportamiento análogos en función de indicadores técnicos y macroeconómicos. De este modo, se pueden utilizar datos históricos y modelos de activos similares para mejorar la predictibilidad de nuevas empresas tecnológicas con alta volatilidad.

La principal ventaja competitiva del fondo radica en su capacidad única para transformar la incertidumbre en oportunidad. Mientras otros operadores evitan activos emergentes por su falta de historial, este fondo se apalanca en técnicas avanzadas de transferencia de conocimiento para convertir esa escasez de datos en una ventaja táctica. A esto se suma un sistema automatizado de identificación de activos similares, que permite importar conocimiento de activos con trayectorias consolidadas hacia aquellos que están en sus primeras etapas de cotización. Esta arquitectura no solo mejora la precisión de las predicciones, sino que acelera el proceso de toma de decisiones en escenarios que normalmente requerirían años de observación. Además, el enfoque está respaldado por una metodología científica replicable, alejada del sesgo humano y adaptativa ante la volatilidad, lo que posiciona al fondo como un referente en gestión avanzada del riesgo en mercados complejos y en constante transformación.

Y esto va más allá de meras acciones: la aplicación de esta metodología es análoga en distintos tipos de activos financieros: bonos, letras del tesoro e incluso criptomonedas (de todo ello, se insta a profundizar y evaluar en un trabajo con mayor extensión la viabilidad).

Por ello, el negocio propuesto se beneficiaría de una ventaja competitiva clave: su capacidad para realizar predicciones más sólidas en el mediano y largo plazo, permitiendo tomar decisiones de inversión estratégicas en lugar de depender de especulación a corto plazo. Este enfoque permitiría reducir la exposición al riesgo y mejorar la rentabilidad ajustada al riesgo en un entorno de inversión cada vez más complejo y dinámico.

Además, la automatización mediante inteligencia artificial y la optimización computacional jugarán un papel crucial en la implementación de este fondo, permitiendo procesar grandes volúmenes de datos en tiempo real y generar predicciones continuamente ajustadas a las condiciones del mercado.

### 6.2. Modelo de Negocio

En un contexto financiero marcado por la disrupción tecnológica y la incertidumbre constante, la presente propuesta de negocio plantea la creación de un fondo de inversión especializado en activos con escaso historial de cotización, robustecido mediante técnicas de transferencia de conocimiento. La clave diferencial de este enfoque radica en su capacidad para identificar patrones en activos emergentes a partir del aprendizaje previo sobre activos consolidados, logrando así predicciones más precisas incluso en contextos de alta volatilidad y limitada disponibilidad de datos. Esta estrategia permite no solo anticiparse a tendencias de mercado, sino también posicionarse de forma temprana en activos de alto potencial, generando una ventaja competitiva significativa.

El segmento de clientes al que se dirige este fondo está compuesto principalmente por inversores institucionales y particulares sofisticados que buscan estrategias de mediano y largo plazo. Estos perfiles valoran la innovación, el uso de inteligencia artificial en la toma de decisiones y la posibilidad de invertir en sectores emergentes con fundamentos tecnológicos. A diferencia de los fondos tradicionales que optan por activos consolidados y estrategias conservadoras, este vehículo ofrece la posibilidad de participar en mercados aún no saturados, como el tecnológico, el blockchain o los mercados alternativos.

Las fuentes de ingresos del fondo se basarán en un esquema mixto: por un lado, comisiones de gestión aplicadas al capital invertido; por otro, comisiones sobre beneficios

(performance fees), vinculadas al éxito de las predicciones y resultados del fondo. A largo plazo, también se plantea la posibilidad de licenciar la tecnología predictiva desarrollada, lo que abriría una vía de monetización adicional B2B.

Para la ejecución efectiva del modelo, será fundamental disponer de una infraestructura tecnológica sólida que permita entrenar modelos en tiempo real y adaptarlos dinámicamente al contexto del mercado. Los recursos clave incluyen algoritmos de transferencia de conocimiento, una base de datos consolidada con variables técnicas, macroeconómicas y fuentes alternativas como tendencias en redes sociales o volúmenes de búsqueda, y un equipo multidisciplinar con competencias en finanzas cuantitativas, inteligencia artificial y desarrollo de software financiero.

Las actividades centrales del negocio incluirán la continua mejora del modelo de similitud entre activos, la optimización dinámica de hiperparámetros según condiciones de mercado, la identificación automatizada de oportunidades de inversión, y la validación robusta mediante métricas como MAPE, RMSE y coeficiente de determinación $R^2$. Todo esto sustentado en una metodología científica replicable y orientada a la toma de decisiones estratégicas.

En resumen, este modelo de negocio representa una propuesta de valor innovadora dentro del ámbito de la inversión cuantitativa. A través del uso estratégico de técnicas avanzadas de aprendizaje transferido, permite abordar mercados complejos con un enfoque de gestión del riesgo más preciso y eficaz, abriendo nuevas posibilidades en la inversión en activos emergentes con fundamentos sólidos pero limitada trazabilidad histórica.

### 6.3. Respuesta a los Objetivos

Se ha confirmado que la aplicación de técnicas de Transfer Learning mejora significativamente la capacidad de predicción a lo largo del tiempo, al reducir el sesgo generado por la escasez de datos históricos en activos emergentes. Esta técnica permite generalizar mejor en distintos horizontes temporales y contextos de mercado. Sin embargo, también se ha observado que, conforme se incrementa la disponibilidad de datos específicos del activo en cuestión, resulta conveniente reducir progresivamente la dependencia del modelo base (Anexo 11). En estos casos, el ajuste del modelo debe centrarse con mayor énfasis en las características particulares del activo objetivo y en su evolución histórica, optimizando así la precisión y la adaptabilidad del modelo a su comportamiento único.

Por otro lado, la integración del análisis de sentimiento económico ha mostrado ser una herramienta valiosa para anticipar movimientos de precios impulsados por eventos macroeconómicos, noticias relevantes del sector y factores externos de alta influencia. Esta capa adicional de información ha permitido enriquecer el contexto del modelo, mejorando la detección de señales de cambio y aportando una mayor sensibilidad frente a fenómenos no puramente técnicos, especialmente considerando el análisis de activos fuertemente vinculados al contexto.

Asimismo, se ha validado la utilidad de diversos indicadores técnicos clásicos en la mejora de la capacidad predictiva del modelo. Su inclusión ha permitido afinar las predicciones, sobre todo en fases de alta actividad técnica en el mercado.

Finalmente, la optimización de los recursos computacionales utilizados en el entrenamiento y ajuste de los modelos ha sido una prioridad. La implementación de esquemas dinámicos de ajuste de hiperparámetros, combinados con técnicas de regularización adecuadas, ha permitido reducir significativamente el consumo de recursos sin comprometer la calidad de las predicciones. Esta eficiencia computacional no solo contribuye a la escalabilidad del modelo, sino que también mejora su viabilidad en contextos de implementación práctica y en tiempo real.

### 6.4. Recomendaciones y Limitaciones

Una de las principales líneas de desarrollo futuro consiste en la creación de un índice de similitud entre activos financieros, basado en características técnicas y macroeconómicas. Este índice permitiría identificar de forma sistemática qué activos consolidados pueden actuar como modelo base para aquellos con históricos de datos limitados, facilitando así la aplicación eficiente de técnicas de transferencia de conocimiento en contextos donde la información disponible es insuficiente.

Asimismo, resulta fundamental analizar con mayor profundidad el impacto que la volatilidad tiene sobre la efectividad de la transferencia de conocimiento. Determinar en qué medida la volatilidad condiciona la aplicabilidad del enfoque propuesto permitirá establecer criterios más precisos para su implementación en diferentes tipos de activos, incluyendo acciones, bonos y letras del tesoro. Esta evaluación contribuiría a delimitar el rango óptimo de uso del modelo en función del entorno de riesgo. Probablemente mientras menos volátil el activo, mayor la aplicabilidad del Transfer Learning y su precisión en el corto plazo.

En términos metodológicos, se plantea también la necesidad de explorar arquitecturas alternativas al modelo LSTM, principalmente configuraciones híbridas (ensamblaje).

Del mismo modo, resulta clave avanzar en la implementación de esquemas de optimización de hiperparámetros en tiempo real. La capacidad de ajustar dinámicamente los parámetros del modelo según las condiciones cambiantes del mercado permitiría mantener un alto nivel de precisión sin incurrir en un coste computacional excesivo, lo que contribuiría a la escalabilidad y adaptabilidad del sistema en entornos de producción.

Por último, es importante reconocer ciertas limitaciones del estudio actual. La disponibilidad de datos históricos para empresas emergentes continúa siendo un desafío estructural, lo cual puede afectar la validez y estabilidad de los modelos en entornos de extrema volatilidad. Adicionalmente, las predicciones basadas en análisis de sentimiento pueden verse afectadas por sesgos inherentes a la interpretación del lenguaje natural, lo que compromete la calidad de algunas señales generadas. Finalmente, aunque los modelos desarrollados han demostrado buen desempeño en los datos observados, aún requieren validación adicional bajo condiciones de mercado no contempladas, como crisis financieras profundas o eventos disruptivos inesperados. Si bien no se puede afirmar que el modelo mejore las predicciones en todos los casos, los resultados generales muestran una tendencia consistente hacia una mayor precisión en la mayoría de los escenarios analizados.

# 7. CONCLUSIONES GENERALES DEL TRABAJO

La aplicación del aprendizaje por transferencia (Transfer Learning) en el ámbito financiero, concretamente a través de la transferencia de conocimiento desde un modelo entrenado con datos del S&P 500, ha demostrado mejorar de forma significativa la precisión de las predicciones en activos correlacionados y estructuralmente similares. Este efecto es especialmente notable en los primeros periodos, cuando la escasez de datos impide que un modelo entrenado exclusivamente con información propia alcance resultados precisos y generalizables. A medida que se dispone de un mayor historial del activo, se debe reducir la dependencia del modelo base y priorizar el entrenamiento sobre sus propios datos.

No obstante, los resultados evidencian que el Transfer Learning, por sí solo, no es suficiente. Es necesario realizar un análisis previo de similitud entre el activo origen y el activo objetivo. Cuanto mayor sea el parecido —tanto en términos cuantitativos (correlación histórica) como cualitativos (negocio y sector)— mayor será el impacto positivo de la transferencia de conocimiento. En este sentido, Apple fue el caso más beneficiado, no solo por ser la empresa con mayor correlación, sino por su papel como barómetro económico. Tesla, también altamente correlada, mostró una mejora significativa. Por el contrario, Uber, con baja correlación, mostró mejoría solo en los primeros años, y Planet Fitness, con diferencias tanto cualitativas como cuantitativas, apenas se benefició del enfoque. Esta conclusión refuerza la importancia de definir una metodología rigurosa para seleccionar activos origen adecuados en cada aplicación del modelo.

Además, el trabajo ha confirmado el enorme potencial de las redes neuronales en el entorno financiero, particularmente por su capacidad para detectar patrones ocultos, modelar dependencias temporales y aprender relaciones complejas entre variables heterogéneas. La estrategia de ajuste dinámico de hiperparámetros ha permitido validar la conveniencia de emplear modelos GRU en contextos de datos limitados y LSTM cuando se cuenta con series temporales más extensas, optimizando así la adaptabilidad y la eficiencia del modelo según el volumen de información disponible.

Finalmente, se ha comprobado que incorporar múltiples activos en el entrenamiento mejora la capacidad del modelo para comprender comportamientos interempresariales, lo que favorece la generalización. Asimismo, la integración de análisis de sentimiento aplicado a noticias financieras ha aportado un valor añadido especialmente relevante en sectores sensibles a eventos exógenos, consolidándose como un componente útil.

## 8. REFENCIAS BIBLIOGRÁFICAS


Buckman, S. R., Shapiro, A. H., Sudhof, M., & Wilson, D. J. (2020). News Sentiment in the Time of COVID-19. FRBSF Economic Letter 2020-08 (April 6).

Cao, H., Gu, H., Guo, X., & Rosenbaum, M. (2023). *Risk of transfer learning and its applications in finance*. arXiv. https://arxiv.org/abs/2311.03283 (Accedido el 14 de mayo de 2025).

Cho, K., Van Merriënboer, B., Bahdanau, D., & Bengio, Y. (2014). On the properties of neural machine translation: Encoder-decoder approaches. arXiv preprint arXiv:1409.1259. https://doi.org/10.48550/arXiv.1409.1259

Federal Reserve Bank of San Francisco. (n.d.). Daily News Sentiment Index. Retrieved from https://www.frbsf.org/research-and-insights/data-and-indicators/daily-news-sentiment-index/

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://www.bioinf.jku.at/publications/older/2604.pdf

Hutto, C., & Gilbert, E. (2014). VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216-225.

K, N., & B, A. (2021). Machine learning and predictive models for stock market analysis. *E3S Web of Conferences, 51*, 01040. https://www.e3s-conferences.org/articles/e3sconf/pdf/2021/51/e3sconf_eilcd2021_01040.pdf

Liu, B., Zhang, J., Ma, D., & Hu, Y. (2021). Transfer learning for stock market prediction. Sentic Computing. Retrieved from https://www.sentic.net/transfer-learning-for-stock-market-prediction.pdf

Roondiwala, M., Patel, H., & Varma, S. (2018). Predicting Stock Prices Using LSTM. *ResearchGate*. Retrieved from https://www.researchgate.net/publication/327967988_Predicting_Stock_Prices_Using_LSTM

Sharma, R., & Kumar, S. (2017). Stock market prediction using LSTM. *International Journal of Science and Research, 6*(4), 1142-1147. https://www.ijsr.net/archive/v6i4/ART20172755.pdf

Shaw, A. (2020). Python project: Building a real-time stock market price prediction system. Medium. Retrieved from https://medium.com/@abhishekshaw020/python-project-building-a-real-time-stock-market-price-prediction-system-6ce626907342

Shapiro, A. H., Sudhof, M., & Wilson, D. J. (2020). Measuring News Sentiment. FRB San Francisco Working Paper 2017-01.

Tan, X. W., Chern, C. K., Song, J., Zhou, Z., & Li, S. (2021). Trend Forecast via LSTM & Transfer Learning to Capture Global Drift. Asian Institute of Digital Finance, National University of Singapore. Retrieved from https://www.researchgate.net/publication/366137544_Trend_Forecast_via_LSTM_Transfer_Learning_to_Capture_Global_Drift

Varsamopoulos, S., Bertels, K., & Almudever, C. (2018). Designing neural network based decoders for surface codes. arXiv. https://doi.org/10.48550/arXiv.1811.12456

Zhao, X., & Tang, J. (2017). Exploring transfer learning for crime prediction. En 2017 IEEE International Conference on Data Mining Workshops (ICDMW) (pp. 1158–1159). IEEE. https://doi.org/10.1109/ICDMW.2017.165

Zhong, S., & Hitchcock, D. B. (2021). S&P 500 stock price prediction using technical, fundamental and text data. Department of Statistics, University of South Carolina, Columbia, SC.

# 9. ANEXO

Anexo 1. Boxplot de los precios de apertura del S&P500. ..... 57
Anexo 2. Correlación entre sentimiento y retornos (Diarios, Mensuales y Anuales) ..... 57
Anexo 3. Correlograma entre sentimiento y retornos (Diarios, Mensuales y Anuales) ..... 58
Anexo 4. Boxplot Outliers precio de apertura de Tesla ..... 58
Anexo 5. Evolución del Sentimiento a lo largo del Tiempo. ..... 59
Anexo 6. Evolución del Rentabilidad y Sentimiento comparativo. ..... 59
Anexo 7. Ejemplo comparativo de variable estacionario con Transformación Logarítmica ..... 60
Anexo 8. Estudio de estacionalidad serie temporal SPY (S&P500) ..... 60
Anexo 9. Distribución de Errores Predicciones LSTM Tesla 2012. ..... 61
Anexo 10. Estudio de Volatilidad LSTM Tesla 2021. ..... 61
Anexo 11. Comparación MAPE con y sin Transfer Learning Tesla (por año) ..... 62
Anexo 12. Comparación del MAPE con y sin Transfer Learning (margen de error) ..... 62
Anexo 13. Gráfico predicciones GRU Uber para 2024. ..... 63
Anexo 14. Resumen métricas de error comparativas Apple ..... 63
Anexo 15. Resumen métricas de error comparativas Planet Fitness ..... 63
Anexo 16. Formulación técnica modelo LSTM ..... 64
Anexo 17. Estructura básica de una celda modelo GRU ..... 64

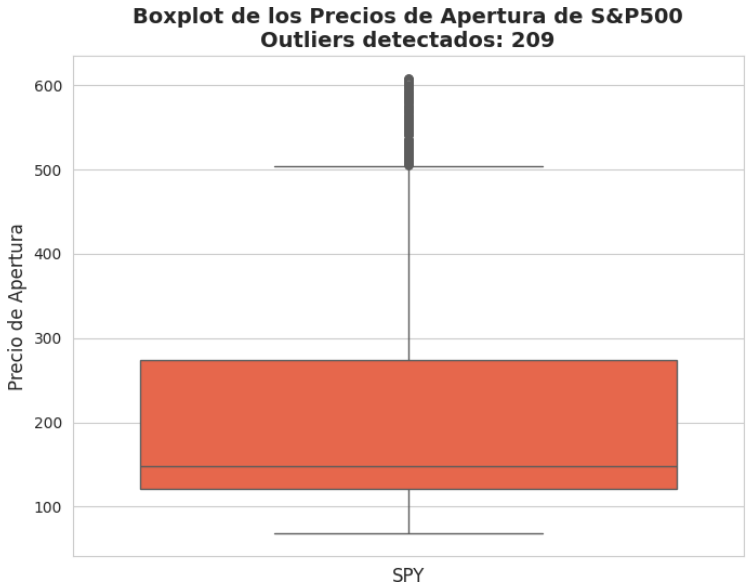


**Anexo 1.** Boxplot de los precios de apertura del S&P500.

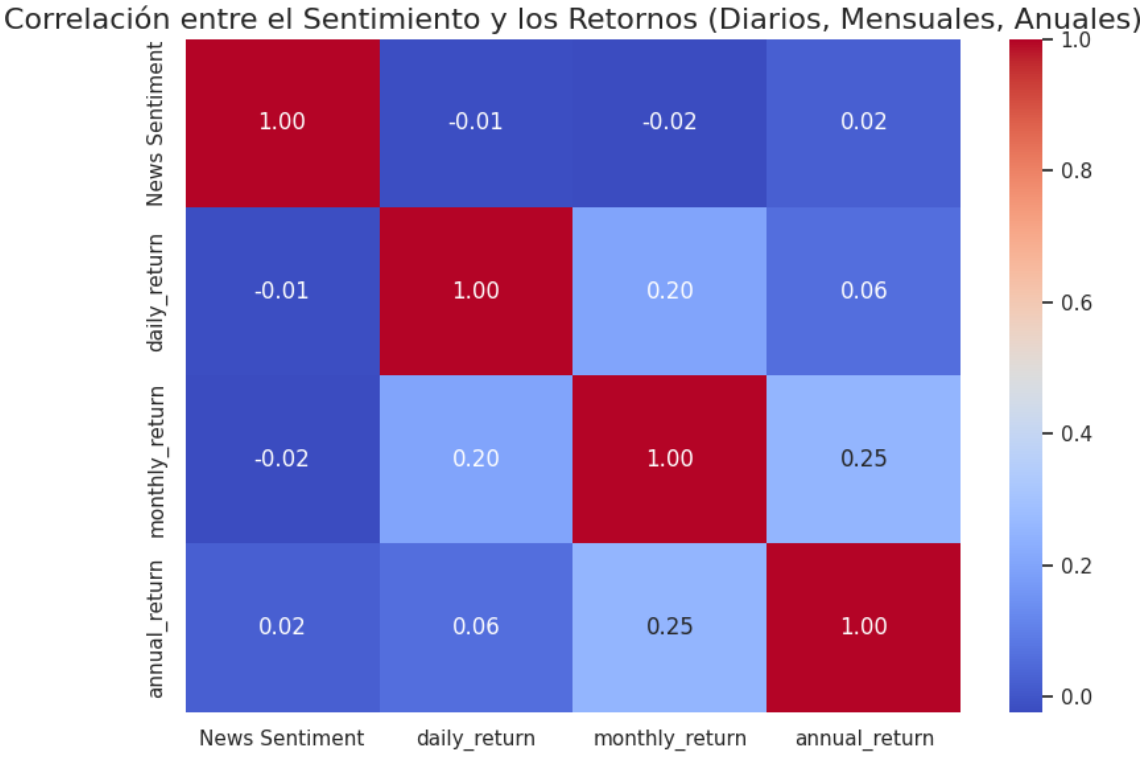


**Anexo 2.** Correlación entre sentimiento y retornos (Diarios, Mensuales y Anuales).

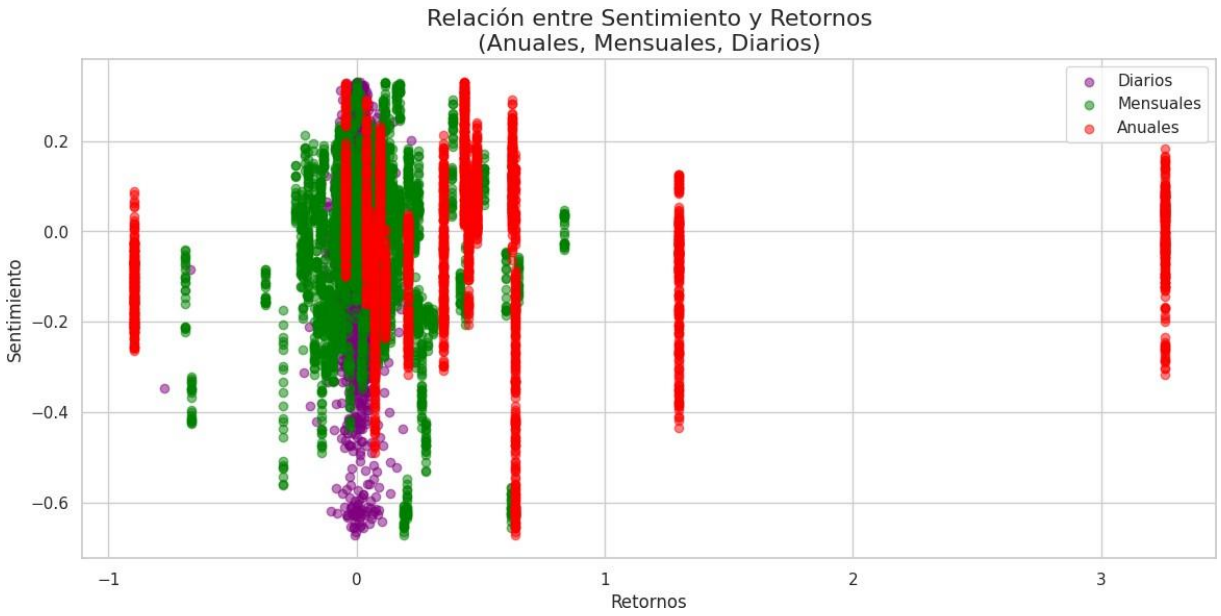


**Anexo 3.** Correlograma entre sentimiento y retornos (Diarios, Mensuales y Anuales).

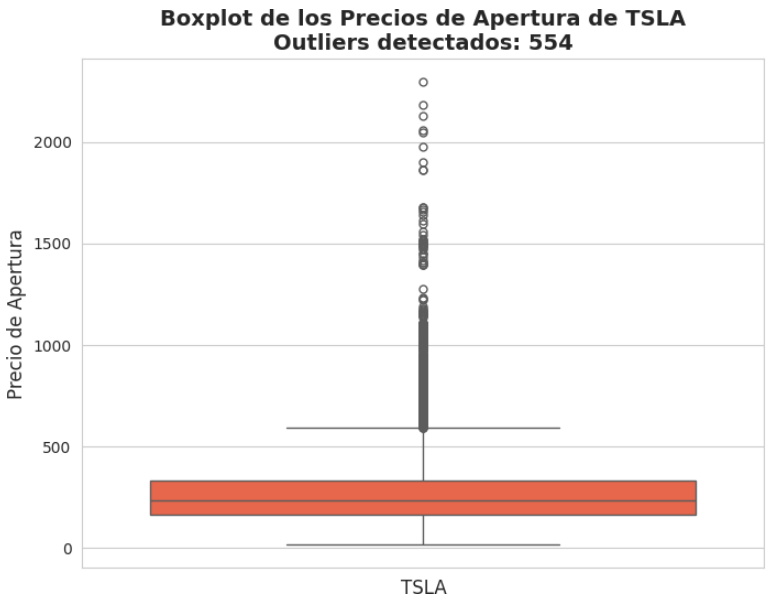


**Anexo 4.** Boxplot Outliers precio de apertura de Tesla.

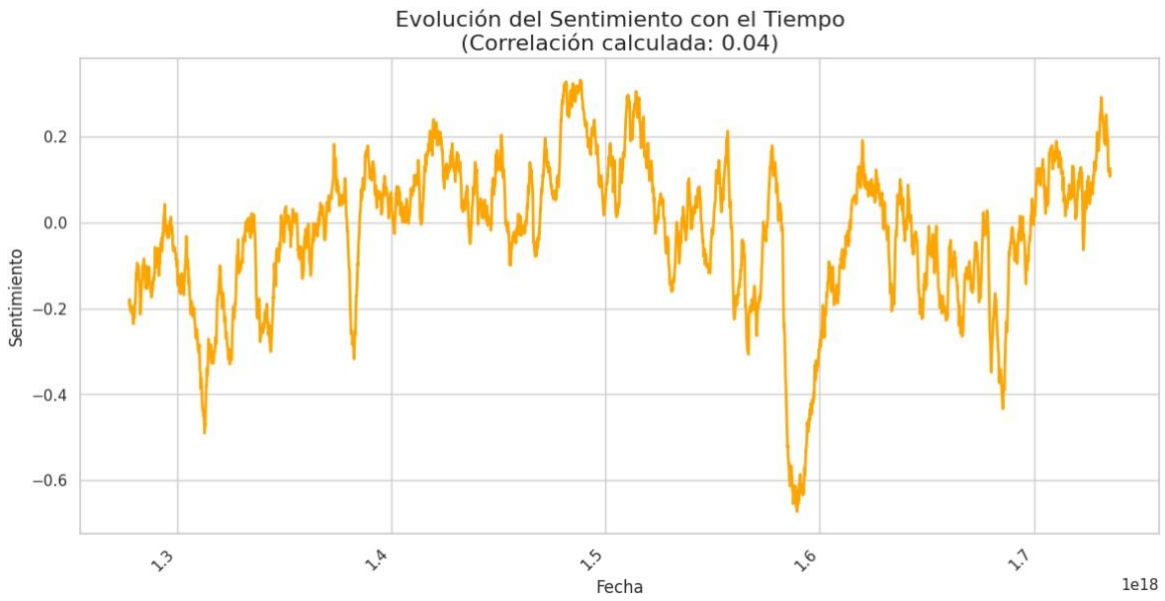


**Anexo 5.** Evolución del Sentimiento a lo largo del Tiempo.

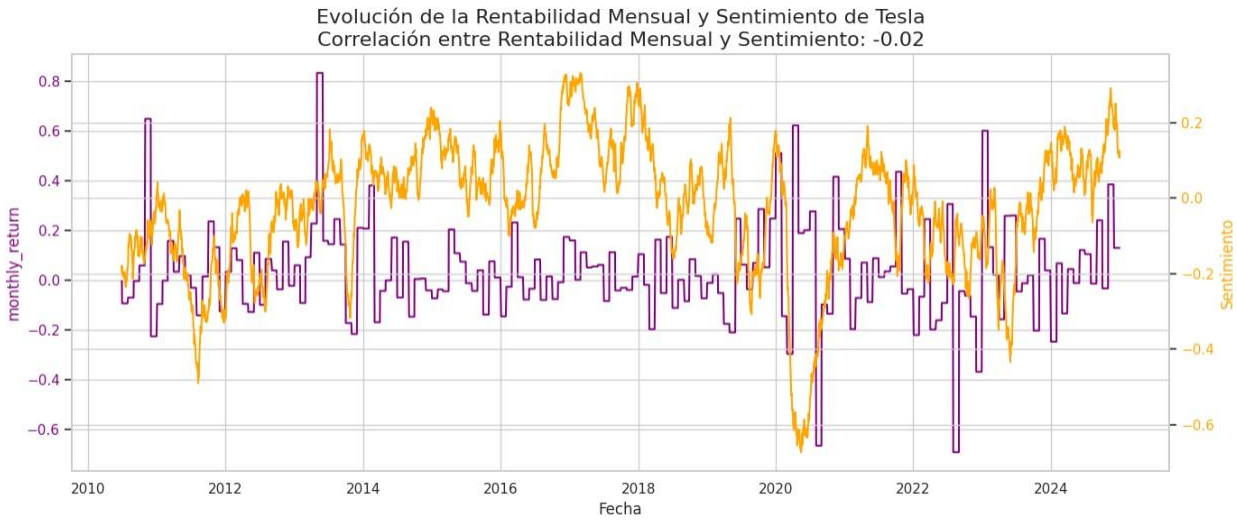


**Anexo 6.** Evolución del Rentabilidad y Sentimiento comparativo.

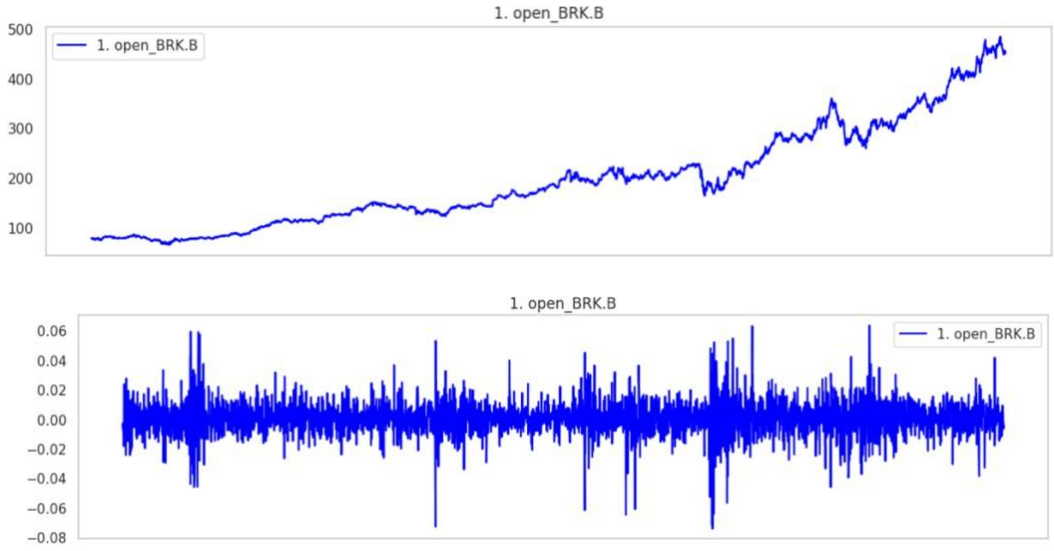


**Anexo 7.** Ejemplo comparativo de variable estacionario con Transformación Logarítmica.

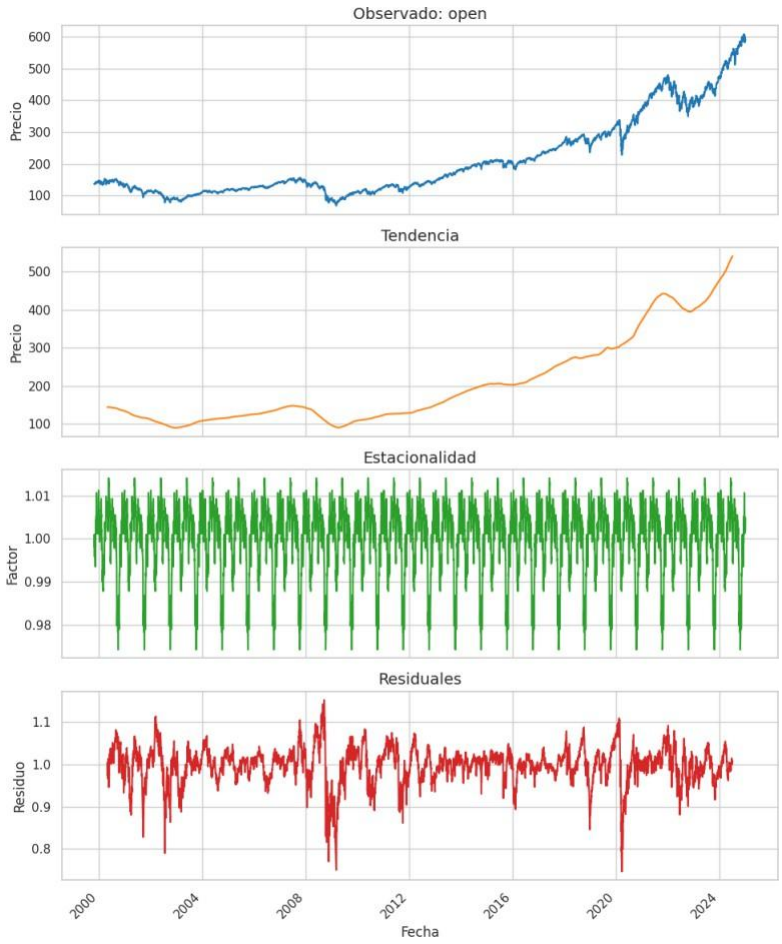


**Anexo 8.** Estudio de estacionalidad serie temporal SPY (S&P500).

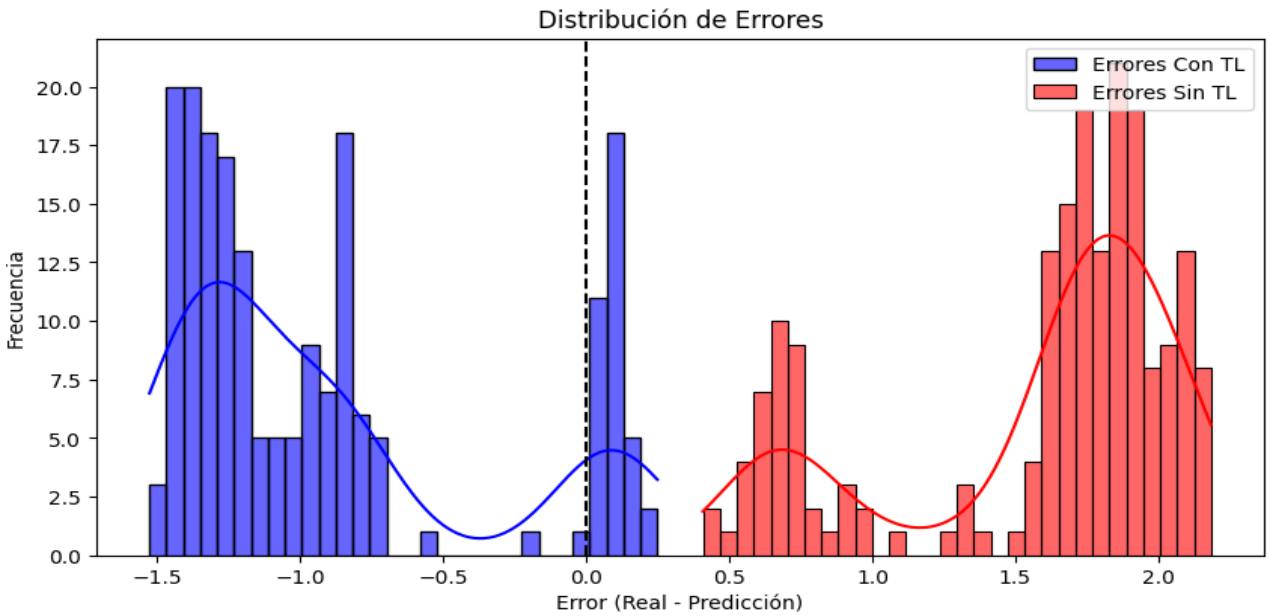


**Anexo 9.** Distribución de Errores Predicciones LSTM Tesla 2012.

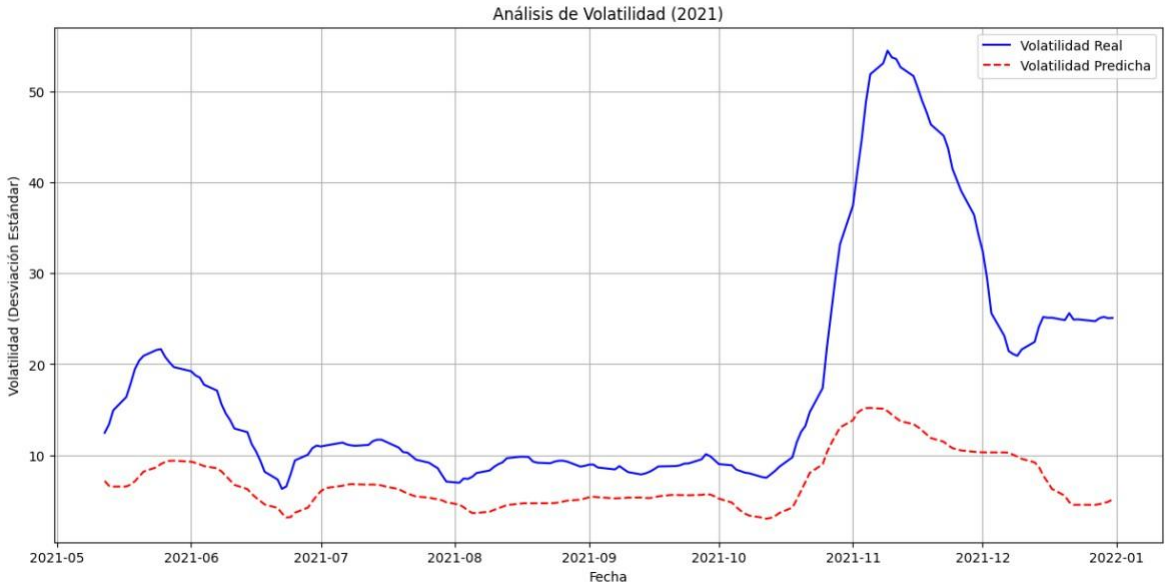


**Anexo 10.** Estudio de Volatilidad LSTM Tesla 2021.

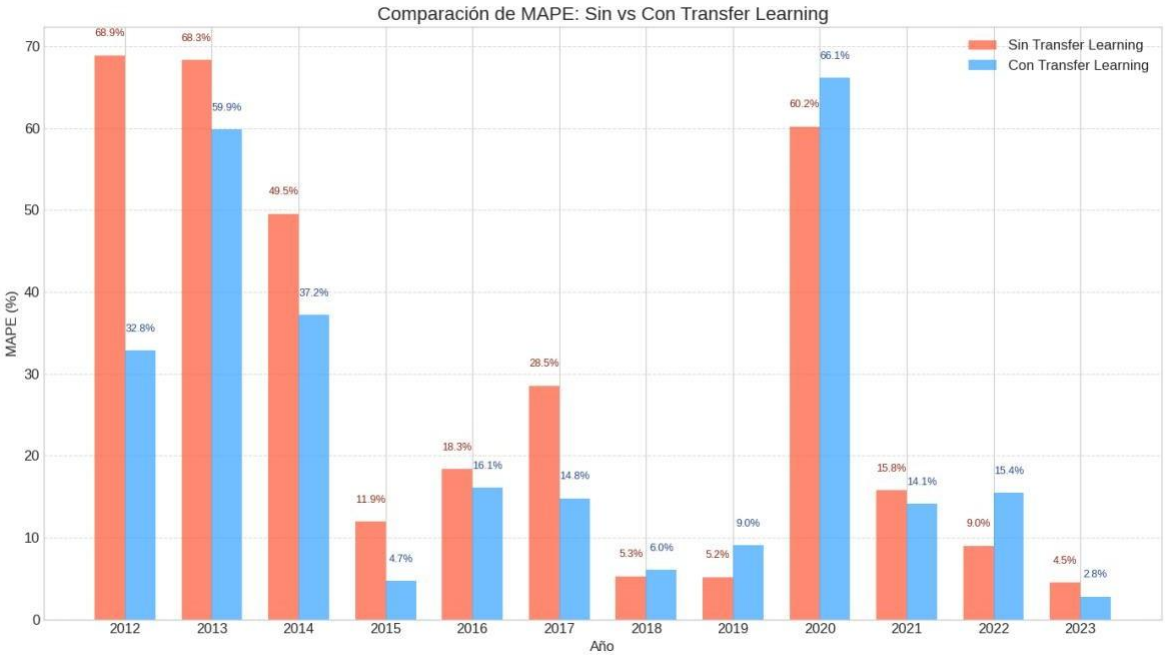


**Anexo 11.** Comparación MAPE con y sin Transfer Learning Tesla (por año)

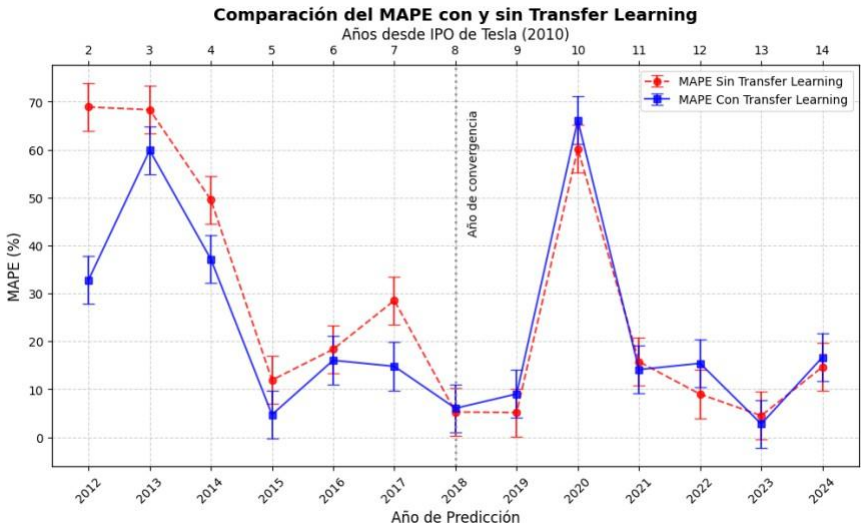


**Anexo 12.** Comparación del MAPE con y sin Transfer Learning (margen de error)

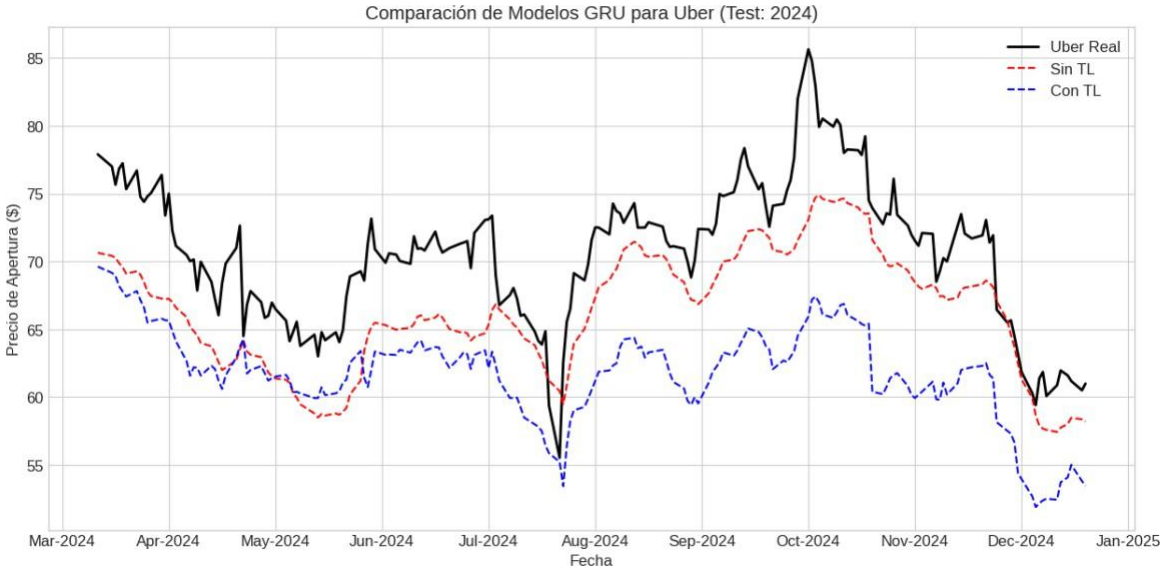


**Anexo 13.** Gráfico predicciones GRU Uber para 2024.

| | RMSE Sin TL | RMSE Con TL | MAPE Sin TL | MAPE Con TL | Modelo (GRU / LSTM) | Años de datos | Épocas modelo base | Épocas fine-tuning | Capas congeladas |
|---|---|---|---|---|---|---|---|---|---|
| **2006** | 0.529809 | 0.314927 | 21.0146 | **8.43914** | GRU | 0.99932 | 49 | 30 | 3 |
| **2007** | 1.720779 | | 27.7306 | **24.3864** | GRU | 1.99863 | 49 | 30 | 3 |
| **2008** | 0.498019 | 0.33399 | 8.38009 | **5.71561** | GRU | 2.99795 | 48 | 31 | 2 |
| **2009** | 5.069521 | 3.420393 | 55.146 | **37.6685** | GRU | 4 | 48 | 32 | 2 |
| **2010** | 5.007897 | 3.727996 | 42.239 | **30.7965** | GRU | 4.99932 | 47 | 32 | 1 |
| **2011** | 1.679258 | 1.802852 | **11.7447** | 12.5868 | LSTM | 5.99863 | 47 | 32 | 1 |
| **2012** | 15.944861 | 15.74717 | 70.3779 | **68.4572** | GRU | 6.99795 | 46 | 33 | 0 |
| **2013** | 2.844631 | 5.985172 | **13.5275** | 30.767 | LSTM | 8 | 46 | 34 | 0 |
| **201** | 23.60674 | 3.435744 | 95.884 | **11.9404** | LSTM | 8.99932 | 45 | 34 | 0 |
| **2015** | 3.913329 | 4.492086 | **12.7398** | 14.5816 | LSTM | 9.99863 | 45 | 34 | 0 |
| **2016** | 1.720384 | 1.442974 | 4.87425 | **4.83078** | LSTM | 10.9979 | 44 | 35 | 0 |
| **2017** | 10.394411 | 7.902592 | 25.7568 | **19.3037** | LSTM | 12 | 44 | 36 | 0 |
| **2018** | 8.738714 | 8.78961 | **16.5432** | 16.6294 | LSTM | 12.9993 | 43 | 36 | 0 |
| **2019** | 6.125876 | 8.49545 | **9.50164** | 13.0977 | LSTM | 13.9986 | 43 | 36 | 0 |
| **2020** | 28.689186 | 36.210443 | **22.4694** | 30.2785 | LSTM | 14.9979 | 42 | 37 | 0 |
| **2021** | 15.559392 | 29.235568 | **8.7611** | 18.91 | LSTM | 16 | 42 | 38 | 0 |
| **2022** | 15.920501 | 6.736815 | 9.51922 | **3.66997** | LSTM | 16.9993 | 41 | 38 | 0 |
| **2023** | 36.020242 | 41.575097 | **19.4343** | 22.7362 | LSTM | 17.9986 | 41 | 38 | 0 |

**Anexo 14.** Resumen métricas de error comparativas Apple.

| | RMSE Sin TL | RMSE Con TL | MAPE Sin TL | MAPE Con TL | Modelo (GRU / LSTM) | Años de datos | Épocas modelo base | Épocas fine-tuning | Capas congeladas |
|---|---|---|---|---|---|---|---|---|---|
| **2016** | 3.667111 | 1.116101 | 15.921427 | **3.807129** | GRU | 0.402464 | 49 | 30 | 3 |
| **2017** | 2.703782 | 4.390362 | **8.143389** | 12.176141 | GRU | 1.404517 | 49 | 30 | 3 |
| **2018** | 5.005132 | 9.543093 | **8.60411** | 18.559902 | GRU | 2.403833 | 48 | 31 | 2 |
| **2019** | 10.861508 | 10.111331 | 13.883167 | **13.19698** | GRU | 3.403149 | 48 | 31 | 2 |
| **2020** | 4.935929 | 6.130564 | **6.693239** | 8.346643 | GRU | 4.402464 | 47 | 32 | 1 |
| **2021** | 12.072838 | 11.870003 | **13.818545** | 14.115766 | LSTM | 5.404517 | 47 | 32 | 1 |
| **2022** | 7.06936 | 2.821239 | 8.06679 | **3.256444** | LSTM | 6.403833 | 46 | 33 | 0 |
| **2023** | 5.024642 | 4.368879 | 6.605773 | **6.384373** | LSTM | 7.403149 | 46 | 33 | 0 |
| **2024** | 14.735295 | 12.979465 | 14.786509 | **13.0097** | LSTM | 8.402464 | 45 | 34 | 0 |

**Anexo 15.** Resumen métricas de error comparativas Planet Fitness.

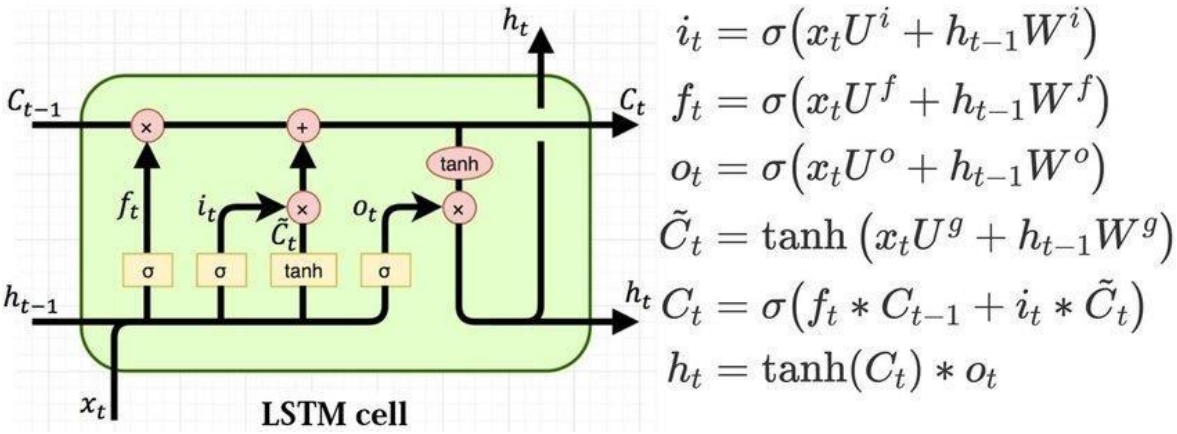


**Anexo 16.** Formulación técnica modelo LSTM

*Elaborado por Varsamopoulos, S (2018)*

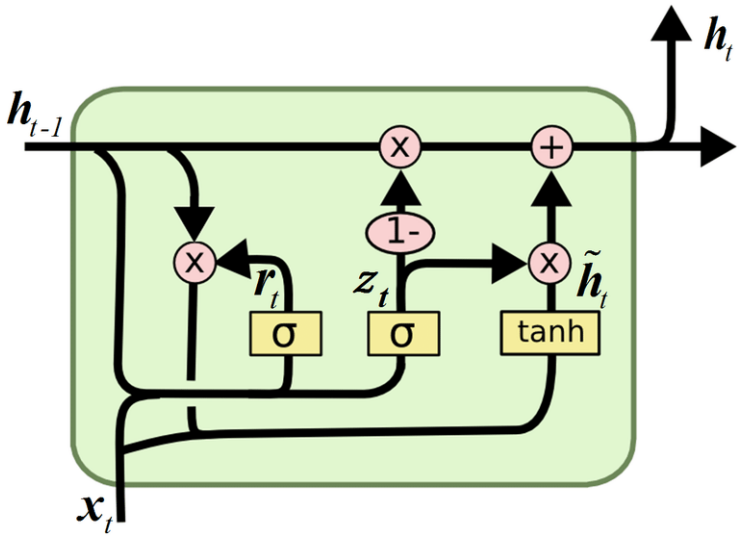


**Anexo 17.** Estructura básica de una celda modelo GRU.

*Extraído de* Guoqiang, J. *(2020)*

**Repositorio GitHub:** https://github.com/scasca03/SP500-TFG