MEMORIA JUSTIFICATIVA PARA LA ACEPTACIÓN DEL ANTEPROYECTO

Título: Predicción del riesgo de quiebra empresarial mediante técnicas de Business Analytics

Autor: Nicolás Vermeulen Fernández

DESCRIPCIÓN DEL PROBLEMA A RESOLVER

✓ Motivación y origen.

A lo largo de la carrera he visto asignaturas relacionadas con contabilidad, análisis financiero, auditoría o dirección estratégica. En todas ellas se insiste en que una empresa puede parecer estable desde fuera, pero tener problemas económicos importantes por dentro que no siempre son fáciles de detectar. Esto me llamó bastante la atención, porque en la realidad muchas empresas acaban quebrando de forma repentina, incluso cuando sus últimas cuentas parecían razonablemente buenas.

A partir de esta idea empecé a interesarme por cómo se evalúa el riesgo de que una empresa entre en dificultades financieras. Normalmente se hace revisando estados financieros y analizando ciertas ratios, pero este método tiene límites. Depende mucho del juicio del analista, del tiempo que se pueda dedicar a cada empresa y de la capacidad para interpretar cifras a lo largo de varios años. Por eso me pareció interesante ver si podía aplicar herramientas de business analytics para intentar detectar patrones que no siempre son evidentes a primera vista.

Además, en los últimos años se habla cada vez más de modelos predictivos aplicados a finanzas y auditoría. Esto me hizo pensar que podría ser una buena oportunidad para combinar lo que he aprendido en distintas asignaturas: las bases financieras y contables, con las técnicas de análisis de datos. El objetivo es intentar construir un modelo que ayude a identificar señales de alerta antes de que una empresa llegue a una situación de quiebra. Me pareció un tema útil, aplicable y conectado con la realidad profesional, ya que tanto bancos, consultoras como auditores trabajan constantemente con este tipo de riesgos.

✓ Datos que lo sustentan.

Para llevar a cabo este proyecto utilizaré datasets públicos que ya han sido utilizados en otras investigaciones sobre quiebra empresarial. Entre ellos destacan el *Polish Companies Bankruptcy Dataset* y el *Taiwan Bankruptcy Prediction Dataset*. Estos datasets incluyen información sobre cientos o miles de empresas que pasaron por situaciones financieras distintas, algunas llegando a quebrar y otras no.

Lo interesante de estos datos es que incluyen variables financieras muy comunes: ratios de liquidez, rentabilidad, endeudamiento, eficiencia, rotación de activos o cambios en ingresos y gastos. Es decir, las mismas variables que se estudian en asignaturas como contabilidad financiera, análisis de balances o auditoría. Esto facilita que pueda entender la información sin necesidad de transformaciones excesivamente complejas.

Otro aspecto importante es que estos datasets suelen estar relativamente limpios y estructurados. Aun así, tendré que revisar valores externos, escalar algunas variables si es necesario y preparar los datos para que los modelos funcionen correctamente.

Trabajar con datos reales de empresas permite observar diferencias claras entre negocios que siguen funcionando y los que acaban en quiebra. Estas diferencias serán la base para entrenar

los modelos predictivos y ver si realmente pueden identificar patrones comunes de las empresas en riesgo.

✓ Impacto de la solución del problema.

Tener una herramienta que ayude a predecir la quiebra de una empresa puede tener efectos muy relevantes en diferentes ámbitos profesionales. Por ejemplo, en el sector bancario los analistas de riesgo deben decidir si conceden préstamos. Si cuentas con un modelo que les dé una estimación del riesgo de quiebra, pueden tomar decisiones mejor fundamentadas y evitar situaciones en las que el banco asuma un riesgo mayor del que debería.

En auditoría también es útil. Los auditores tienen que identificar áreas donde exista un riesgo potencial. Si los datos financieros de una empresa muestran indicadores parecidos a los de empresas que acabaron quebrando, el auditor puede profundizar más en esas áreas.

Los inversores, por su parte, pueden utilizar este tipo de análisis para saber si una empresa es una oportunidad segura o si existe la posibilidad de que entre una situación complicada. Y, por último, las propias empresas podrían analizar sus ratios financieros y detectar problemas con más antelación para corregirlos antes de llegar a una situación irreversible.

En general, creo que este tipo de modelos aporta una visión complementaria a los métodos tradicionales y puede ser una herramienta de apoyo en la toma de decisiones financieras y empresariales.

✓ Problema de investigación en forma de Pregunta.

¿Qué factores financieros ayudan a predecir si una empresa tiene riesgo de entrar en quiebra?

✓ Preguntas de investigación.

1. ¿Qué ratios financieros son los que más influyen en el riesgo de quiebra?
2. ¿Qué modelo funciona mejor para este tipo de predicción: regresión logística o árboles de decisión?
3. ¿Qué diferencias hay entre las empresas que quiebran y las que no según sus datos financieros?
4. ¿Se pueden detectar señales de alerta con cierta antelación?
5. ¿Cómo se podrían usar los resultados del modelo para tomar decisiones en el ámbito financiero o empresarial?

✓ Planificación del proyecto.

Para organizar mi trabajo seguiré la estructura de los tres pilares del grado en business analytics:

- **Ingeniería del dato**: en esta parte prepararé el dataset, revisaré que no haya errores evidentes, elegiré las variables que utilizaré y dejaré los datos en un formato adecuado para los modelos. También almacenaré los datos de forma ordenada para facilitar el resto del análisis.
- **Análisis del dato**: aquí construiré al menos dos modelos predictivos. Mi idea es empezar con una regresión logística por ser el modelo más clásico para este tipo de problemas, y después comparar sus resultados con un árbol de decisión o un random forest. Utilizaré métricas como accuracy, recall o la curva de ROC para valorar cuál funciona mejor.
- **Análisis de negocio**: finalmente, interpretaré los resultados desde un punto de vista financiero. No solo quiero saber qué modelo predice mejor, sino también qué variables parecen tener más peso y cómo esta información podría ser útil para bancos, auditores o empresas.

El proyecto se dividirá en cuatro fases:

1. Preparación de datos.
2. Análisis exploratorio.
3. Creación y comparación de modelos.
4. Interpretación final y conclusiones.

✓ Estado del arte.

Introducción al concepto de quiebra empresarial

La quiebra empresarial, o *financial distress*, es un proceso en el que una empresa empieza a tener dificultades para pagar sus obligaciones y mantener su actividad normal. Aunque pueda parecer que este tipo de situaciones solo ocurren en empresas que ya van mal, en realidad muchos estudios demuestran que los problemas financieros suelen comenzar bastante antes de que una compañía entre en insolvencia formal (Altman, 1968). Por eso, durante años se ha intentado entender qué señales pueden anticipar que una empresa está entrando en una situación de riesgo.

Los primeros investigadores que estudiaron este tema analizaron cómo cambiaban ciertos ratios financieros antes de que una empresa quebrara. Uno de los primeros trabajos conocidos fue el de Beaver (1966), que demostró que algunas métricas, como la liquidez o la capacidad de generar beneficios, suelen deteriorarse antes de que la empresa llegue a una crisis financiera grave. A partir de ahí, muchos autores empezaron a estudiar qué variables podían servir como "alertas tempranas".

Más tarde, Altman (1968) desarrolló el famoso modelo Z-score, que combinaba varias ratios para estimar la probabilidad de quiebra. Aunque hoy en día puede parecer un modelo sencillo, en su momento supuso un gran avance porque demostró que era posible predecir la quiebra utilizando datos contables relativamente básicos. Desde entonces, la predicción del riesgo de insolvencia se convirtió en un tema importante dentro del análisis financiero, la auditoría y la banca.

Con el paso del tiempo, el enfoque evolucionó hacia métodos cada vez más estadísticos. Por ejemplo, Ohlson (1980) introdujo la regresión logística como alternativa a los modelos basados solo en ratios. Esto permitió incorporar más variables y ajustar mejor las relaciones entre los datos financieros y el riesgo de quiebra.

En los últimos años, gracias al aumento de la capacidad de computación y del acceso a grandes bases de datos, han surgido muchos estudios que utilizan técnicas de *machine learning* para mejorar la precisión de las predicciones. Investigaciones como las de Barboza, Kim y Altman (2017) muestran que modelos como los árboles de decisión o los métodos de ensemble pueden conseguir resultados más preciosos que los modelos tradicionales.

Ratios financieros tradicionales para detectar riesgo de quiebra

Los ratios financieros han sido, durante muchos años, una de las herramientas más utilizadas para evaluar la situación económica de una empresa y detectar posibles señales de riesgo. Antes de que existieran modelos estadísticos avanzados, la mayoría de analistas examinaban ratios de liquidez, rentabilidad, endeudamiento o eficiencia para formar una idea sobre la estabilidad de un negocio. Aunque hoy en día existen métodos más complejos, estos ratios siguen siendo una

parte fundamental del análisis financiero y todavía se utilizan como referencia en estudios sobre quiebra empresarial.

El ratio de liquidez, por ejemplo, indica hasta qué punto la empresa puede afrontar sus deudas más inmediatas con los activos que tiene disponibles a corto plazo. Beaver (1966) observó que las empresas que acababan quebrando mostraban un deterioro progresivo en su liquidez, lo que sugería que tenían dificultades para cubrir sus obligaciones a corto plazo. Ratios como la liquidez corriente o la prueba ácida son ejemplos clásicos que se siguen usando en la actualidad.

Otro grupo importante de ratios son los relacionados con el endeudamiento. Estos ratios indican el nivel de deuda de la empresa en relación con sus activos o su patrimonio neto. Un endeudamiento excesivo puede aumentar el riesgo de quiebra, especialmente si los beneficios no son suficientes para cubrir los pagos de intereses. Altman (1968) incluyó varios indicadores de solvencia en su modelo Z-score, demostrando que el nivel de deuda es un factor claro para diferenciar empresas sanas de empresas en riesgo.

La rentabilidad es otro elemento fundamental en el análisis del riesgo financiero. Ratios como el ROA (Return on Assets) o el ROE (Return on Equity) permiten ver si la empresa está generando beneficios suficientes en relación con sus recursos. Cuando estas métricas caen durante varios periodos consecutivos, la empresa puede estar entrando en una fase donde su actividad ya no es sostenible. Estudios posteriores, como los de Ohlson (1980), muestran que la rentabilidad es uno de los indicadores que más contribuye a explicar la probabilidad de quiebra.

También es relevante los ratios de eficiencia o actividad, como la rotación de activos. Estos ratios muestran cómo de bien la empresa utiliza sus recursos para generar ventas. Si la rotación de activos disminuye, puede indicar problemas operativos o una reducción en la demanda que puede terminar afectando a la solvencia de la entidad. Algunos trabajos recientes señalan que estos ratios, aunque menos conocidos, pueden aportar información valiosa cuando se combinan con indicadores de rentabilidad y endeudamiento (Alaminos et al., 2016).

Finalmente, los flujos de caja se han convertido en un aspecto clave para evaluar la salud financiera. Aunque tradicionalmente se hablaba menos de ellos, varios estudios (por ejemplo, Casey & Bartczak, 1985) han demostrado que una caída en el flujo de caja operativo suele ser una señal temprana de problemas financieros, incluso antes de que se refleje la pérdida de rentabilidad.

En conjunto, los ratios financieros han sido la base de los primeros modelos de predicción de quiebra. Aunque por sí solos no siempre son suficientes para obtener una predicción precisa, sí permiten identificar tendencias que ayuden a entender si una empresa está entrando es una situación de riesgo. Por eso, muchos modelos posteriores incorporan estos ratios como variables principales dentro de sus análisis.

Modelos clásicos en la predicción de quiebra empresarial

A partir de los primeros estudios basados únicamente en ratios financieros, comenzaron a desarrollarse modelos más estructurados para predecir la quiebra empresarial. Estos modelos, considerados “clásicos”, fueron los primeros en intentar combinar varios indicadores para obtener una probabilidad de quiebra más precisa. Aunque hoy en día existen métodos más avanzados, muchos de estos modelos siguen siendo importantes porque marcaron el punto de partida de todos los estudios posteriores.

Uno de los modelos más influyentes es el modelo Z-score de Altman (1968). Este modelo utilizó análisis discriminante múltiple para combinar diferentes ratios financieros en una única fórmula capaz de clasificar a las empresas como "saludables" o "en riesgo", Altman incluyó cinco tipos de indicadores: liquidez, rentabilidad, eficiencia, solvencia y actividad. Su fórmula tuvo un gran impacto porque mostraba que era posible obtener una predicción bastante buena usando únicamente información contable básica. A día de hoy, el modelo Z-score se sigue enseñando en muchas asignaturas de análisis financiero y se utiliza como referencia en estudios académicos y aplicaciones reales.

Antes de Altman, Beaver (1966) ya había hecho un trabajo fundamental utilizando análisis univariante. Su idea era estudiar cada ratio por separado para ver cuáles se deterioraban antes de la quiebra. Aunque este enfoque era más simple, sus resultados mostraron por primera vez que algunas métricas, como la liquidez o la capacidad de generar beneficios, eran especialmente sensibles cuando una empresa se acercaba a una situación de insolvencia. El trabajo de Beaver se considera el origen de toda la investigación posterior en predicción de quiebras.

Otro modelo clásico es el de Ohlson (1980), que introdujo la regresión logística como alternativa al análisis discriminante utilizado por Altman. La regresión logística permitía incorporar más variables y superar algunas limitaciones estadísticas del modelo Z-score. Ohlson incluyó factores como el tamaño de la empresa, la estructura del capital y variaciones recientes en los resultados. Uno de los aspectos más interesantes de su estudio fue que demostró que esta técnica podía ofrecer una predicción más flexible y, en algunos casos, más precisa que los modelos anteriores.

Con el paso del tiempo, otros autores propusieron versiones modificadas de estos modelos clásicos. Por ejemplo, Taffler (1983) adaptó el análisis discriminante para el contexto británico, mientas que Zavgren (1985) introdujo mejoras relacionadas con ratios de flujo de caja. Cada una de estas versiones buscaba mejorar la capacidad predictiva en distintos sectores o países, lo que muestra la importancia que tenía (y sigue teniendo) anticipar las dificultades financieras de una empresa.

Aunque estos modelos tienen limitaciones (por ejemplo, dependen mucho de supuestos estadísticos y no siempre capturan relaciones complejas entre variables) su contribución fue clave para abrir la puerta a métodos más modernos. Muchos estudios actuales comparan sus resultados con modelos como regresión logística, árboles de decisión o algoritmos de *machine learning*, lo que demuestra que estos métodos clásicos siguen un punto de referencia importante en el análisis.

Evolución hacia modelos estadísticos y econométricos

Después de los modelos clásicos basados en ratios y análisis discriminantes, la investigación sobre la predicción de quiebra avanzó hacia métodos estadísticos más flexibles. El más influyente de esta etapa fue la regresión logística, un tipo de modelo que empezó a utilizarse de forma más sistemática en los años ochenta. La regresión logística resultó especialmente útil porque permite predecir una variable binaria, como "quiebra" o "no quiebra", a partir de múltiples variables financieras al mismo tiempo.

El trabajo de Ohlson (1980) fue uno de los primeros en aplicar esta técnica al análisis del riesgo de quiebra. Su modelo incluía nueve variables relacionadas con la estructura financiera, los beneficios, el tamaño de la empresa y cambios recientes en la rentabilidad. Uno de los motivos por los que su propuesta ganó tanta relevancia es que la regresión logística no requiere algunos

de los supuestos estrictos del análisis discriminante múltiple, como la normalidad multivariante o la igualdad de varianzas entre grupos. Esto hacía el modelo más aplicable a datos reales, que rara vez cumplen esos requisitos.

Otro aspecto que contribuyó al éxito de la regresión logística es que permite interpretar fácilmente el efecto de cada variable. Por ejemplo, un coeficiente negativo indica que, a medida que esa variable aumenta, disminuye la probabilidad de quiebra. Esto facilitó que analistas financieros y auditores pudieran entender y explicar los resultados sin necesidad de conocimientos matemáticos avanzados. Estudios posteriores, como los de Platt y Platt (1990) y Grice y Dugan (2001), confirmaron que los modelos logísticos ofrecían predicciones sólidas en distintos países y sectores.

Durante los años noventa, también aparecieron otros modelos estadísticos que buscaban mejorar la precisión. Algunos autores exploraron variaciones de los modelos de probabilidad, como los modelos probit o los modelos lineales generalizados (GLM), que permiten manejar diversas formas de relación entre las variables. Aunque estos métodos aportaron mejoras en ciertos casos, la regresión logística continuó siendo uno de los enfoques más utilizados debido a su equilibrio entre simplicidad y capacidad predictiva.

Otra línea de investigación importante fue la incorporación de información temporal, buscando entender cómo evolucionan las variables financieras antes de la quiebra. Por ejemplo, Shumway (2001) propuso un modelo "hazard" que analizaba el riesgo de quiebra como una probabilidad que cambia a lo largo del tiempo. Este enfoque intentaba capturar mejor la dinámica de las empresas, algo que los modelos estáticos no siempre lograban reflejar.

A pesar de estos avances, muchos de los métodos estadísticos tenían limitaciones, especialmente cuando las relaciones entre variables eran muy complejas o cuando los datos no seguían patrones lineales. En este punto es donde empezaron a cobrar importancia los modelos basados en *machine learning*, que pueden manejar estructuras más complicadas y explorar interacciones entre variables que no son evidentes con métodos tradicionales.

Uso de técnicas de machine learning en la predicción de quiebra empresarial

En los últimos años, el análisis del riesgo de quiebra empresarial ha evolucionado muy rápidamente gracias al uso de técnicas de *machine learning*. A diferencia de los modelos estadísticos tradicionales, que suelen asumir relaciones lineales o estructuras concretas entre las variables, los algoritmos de *machine learning* permiten capturar patrones mucho más complejos y no necesitan tantos supuestos previos. Esto ha hecho que muchos estudios recientes exploren si estas técnicas pueden mejorar la precisión de los modelos clásicos.

Uno de los métodos más utilizados es el árbol de decisión, un algoritmo que divide los datos en grupos según las variables que mejor separan a las empresas que quebraron de las que no lo hicieron. Lo interesante de los árboles es que son fáciles de interpretar: muestran qué variables tienen más peso y qué valores suelen marcar la diferencia entre un grupo y otro. Investigaciones como las de Frydman, Altman y Kao (1985) demostraron que estos modelos podían competir con el análisis discriminante y la regresión logística, especialmente porque permiten detectar interacciones entre variables de manera intuitiva.

A partir de los árboles surgieron modelos más avanzados como random forest, que construye muchos árboles diferentes y combina sus resultados para obtener una predicción más estable.

Este enfoque reduce el riesgo de sobreajuste y suele mejorar la precisión del modelo. Barboza, Kim y Altman (2017) mostraron que los métodos de ensamble, incluidos random forest y gradient boosting, obtenían mejores resultados que los modelos tradicionales en varios datasets financieros. Este tipo de estudios reforzó la idea de que el *machine learning* podía aportar un rendimiento superior en escenarios donde la estructura de los datos es compleja

Otro grupo de técnicas muy utilizadas en la literatura reciente son los modelos de vectores soporte (SVM). Los SVM intentan separar las observaciones en dos grupos (quiebra/no quiebra) mediante una frontera óptima. Una de sus ventajas es que funcionan bien cuando los datos no son lineales. Min y Lee (2005) aplicaron SVM a la predicción de quiebras y obtuvieron resultados muy competitivos, confirmando que este método podía superar a modelos como la regresión logística en algunos casos.

También se han utilizado técnicas de redes neuronales, especialmente en estudios con grandes volúmenes de datos. Aunque estos modelos tienden a ser menos interpretables, autores como Atiya (2001) han mostrado que pueden ofrecer predicciones muy precisas. Sin embargo, su principal desventaja es que requieren más recursos computacionales y datos más amplios, por lo que no siempre son la opción más adecuada para datasets pequeños o medianos.

En los últimos años también han aparecido enfoques híbridos que combinan técnicas de *machine learning* con análisis financiero tradicional. Por ejemplo, algunos estudios utilizan ratios financieros clásicos como variables de entrada, pero aplican modelos avanzados como gradient boosting o XGBoost para obtener la predicción final (Sun et al., 2014). Estos métodos suelen destacar por su capacidad para mejorar relaciones no lineales y por ofrecer buenos resultados incluso cuando las variables no están perfectamente limpias.

Aun así, no todo son ventajas. Una de las críticas más comunes a los modelos de *machine learning* es que pueden ser difíciles de interpretar. Mientras que la regresión logística permite ver claramente el efecto de cada variable, modelos como random forest o SVM no ofrecen explicaciones tan directas. Esto puede ser un problema en contextos como auditoría o banca, donde no solo importa la predicción, sino también entender por qué el modelo toma una decisión concreta. Por eso, muchos autores recomiendan combinar estos modelos con técnicas de explicación como la importancia de variables o métodos como SHAP (Lundberg & Lee, 2017), que ayudan a interpretar los resultados.

En conjunto, la literatura moderna muestra que las técnicas de *machine learning* pueden mejorar significativamente la predicción de quiebra empresarial, aunque su éxito depende del tipo de datos, del tamaño del dataset y del equilibrio entre precisión e interpretabilidad. Lo que sí está claro es que hoy en día estos modelos forman parte fundamental del análisis financiero avanzado y representan una evolución natural respecto a los métodos clásicos.

Importancia de la calidad de los datos y de los datasets utilizados

La calidad de los datos es un aspecto fundamental en la predicción de quiebras empresariales. Aunque existan modelos muy avanzados, si los datos de partida no son fiables o presentan muchos errores, el resultado final puede ser poco útil. Esto es especialmente importante en el ámbito financiero, donde pequeñas variaciones en los estados contables pueden tener un impacto grande en el análisis. Por ese motivo, muchos estudios subrayan que la calidad del dataset es tan importante como el modelo elegido (Tsai & Cheng, 2012).
Los datasets más utilizados este ámbito, como el *Polish Companies Bankruptcy Dataset* o el *Taiwan Bankruptcy Prediction Dataset*, tienen la ventaja de ser accesibles y estar relativamente

limpios. Estos conjuntos de datos incluyen variables financieras habituales como liquidez, rentabilidad, endeudamiento o variaciones en los ingresos. Además, suelen estar estructurados de manera que permiten distinguir claramente entre empresas que quebraron y empresas que no lo hicieron, lo que facilita el entrenamiento de los modelos. Sin embargo, incluso en estos casos es necesario revisar si existen valores atípicos, datos faltantes o escalas que puedan distorsionar el análisis.

Otra cuestión importante es que los datos financieros no siempre reflejan toda la información relevante sobre la empresa. Por ejemplo, factores externos como el sector, el ciclo económico o cambios regulatorios también pueden influir en el riesgo de quiebra, pero a veces no están incluidos en los datasets. Algunos autores señalan que esta limitación puede afectar a la precisión del modelo y que, siempre que sea posible, es recomendable complementar los datos contables con información cualitativa o variables macroeconómicas (Charitou, Neophytou & Charalambous, 2004). Aun así, para muchos estudios y para trabajos académicos como es este caso de mi TFG, los datos puramente financieros suelen ser más que suficientes para obtener conclusiones válidas.

En los últimos años se ha prestado más atención a los métodos de procesamiento y selección de variables, ya que preparar bien los datos puede mejorar mucho el rendimiento del modelo. Técnicas como la normalización, la detección de outliers o la selección de características ayudan a que los modelos sean más estables y a que no aprendan patrones erróneos derivados del ruido del dataset (Karels & Prakash, 1987). Este tipo de pasos es especialmente relevante en algoritmos de *machine learning*, que pueden verse afectados por escalas muy diferentes o por variables irrelevantes.

En conjunto, las investigaciones coinciden en que la calidad de los datos es un requisito clave para obtener predicciones fiables. Incluso los modelos más avanzados dependen de que las variables estén bien preparadas y representen de forma adecuada la realidad de las empresas estudiadas. Por ello, una parte importante del trabajo consiste en revisar, limpiar y organizar los datos antes de construir los modelos

Conclusiones del estado del arte

Los informes sobre la predicción de quiebras empresariales muestran claramente que este es un tema que ha ido evolucionando a medida que han cambiado las herramientas disponibles y la cantidad de datos accesibles. Los primeros estudios se centraban sobre todo en observar cómo variaban ciertos ratios financieros antes de que la empresa entrara en una situación de insolvencia. Trabajos clásicos como los de Beaver (1966) demostraron que algunas métricas empezaban a deteriorarse meses o incluso años antes de la quiebra, lo que abrió la puerta a modelos más estructurados.

Con el modelo Z-score, Altman (1968) mostró que era posible combinar distintos ratios para construir una fórmula con bastante poder predictivo. Más tarde, la regresión logística planteada por Ohlson (1980) permitió incorporar más variables y superar algunas limitaciones estadísticas de los primeros modelos. Esta fase marcó el inicio de un enfoque más cuantitativo, donde los modelos ya no dependían solo del juicio subjetivo del analista.
En las últimas décadas, el uso de técnicas de *machine learning* ha ampliado las posibilidades de este tipo de estudios. Métodos como árboles de decisión, random forest o SVM han demostrado que pueden capturar relaciones más complejas entre las variables y mejorar la precisión en muchos casos (Barboza et al., 2017). Aunque a veces sacrifican parta de la interpretabilidad,

estos modelos ofrecen una perspectiva más completa del comportamiento financiero de las empresas.

También hay que enfocarse en la importancia de utilizar datos de calidad. Un buen dataset, correctamente preparado, puede marcar la diferencia entre tener un modelo útil y uno que no aporta conclusiones claras. En general, las investigaciones coinciden en que combinar datos financieros bien estructurados con modelos adecuados puede ayudar a anticipar problemas antes de que sean demasiado graves.

Esta propuesta muestra que todavía hay margen para seguir mejorando las predicciones, pero también deja claro que, con las herramientas actuales, es posible construir modelos bastante fiables. Eso es precisamente lo que busco aplicar en este Trabajo Fin de Grado

✓ Bibliografía en formato APA.

- Alaminos, D., del Castillo, A., & Fernández, V. (2016). A global model for bankruptcy prediction. *PLOS ONE, 11*(11), e0166693.
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. The Journal of Finance, 23(4), 589–609.
- Atiya, A. F. (2001). Bankruptcy prediction for credit risk using neural networks: A survey and new results. IEEE Transactions on Neural Networks, 12(4), 929–935.
- Barboza, F., Kim, J., & Altman, E. (2017). Machine learning models and bankruptcy prediction. *Expert Systems with Applications, 83*, 405–417.
- Beaver, W. H. (1966). Financial ratios as predictors of failure. *Journal of Accounting Research, 4*, 71–111.
- Casey, C., & Bartczak, N. (1985). Using operating cash flow data to predict financial distress: Some extensions. *Journal of Accounting Research, 23*(1), 384–401.
- Charitou, A., Neophytou, E., & Charalambous, C. (2004). Predicting corporate failure: Empirical evidence for the UK. *European Accounting Review, 13*(3), 465–497.
- Frydman, H., Altman, E. I., & Kao, D. L. (1985). Introducing recursive partitioning for financial classification: The case of financial distress. *The Journal of Finance, 40*(1), 269–291.
- Grice, J. S., & Dugan, M. T. (2001). The limitations of bankruptcy prediction models: Some cautions for the researcher. *Review of Quantitative Finance and Accounting, 17*, 151–166.
- Karels, G. V., & Prakash, A. J. (1987). Multivariate normality and forecasting of business bankruptcy. *Journal of Business Finance & Accounting, 14*(4), 573–593.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30.

- Min, J. H., & Lee, Y. C. (2005). Bankruptcy prediction using support vector machine with optimal choice of kernel function parameters. *Expert Systems with Applications, 28*(4), 603–614.

- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research, 18*(1), 109–131.

- Platt, H. D., & Platt, M. B. (1990). Development of a class of stable predictive variables: The case of bankruptcy prediction. *Journal of Business Finance & Accounting, 17*(1), 31–51.

- Shumway, T. (2001). Forecasting bankruptcy more accurately: A simple hazard model. *The Journal of Business, 74*(1), 101–124.

- Sun, J., Li, H., Huang, Q. H., & He, K. Y. (2014). Predicting financial distress and corporate failure: A review from the state-of-the-art definitions, modeling, sampling, and featuring approaches. *Knowledge-Based Systems, 57*, 41–56.

- Taffler, R. J. (1983). The assessment of company solvency and performance using a statistical model. *Accounting and Business Research, 13*(52), 295–308.

- Tsai, C. F., & Cheng, K. C. (2012). Simple instance selection for bankruptcy prediction. *Knowledge-Based Systems, 27*, 333–342.

- Zavgren, C. V. (1985). Assessing the vulnerability to failure of American industrial firms: A logistic analysis. *Journal of Business Finance & Accounting, 12*(1), 19–45.

OBJETIVO GENERAL Y OBJETIVOS ESPECÍFICOS

A la hora de plantear este trabajo, considero importante definir bien qué pretendo conseguir y cómo pienso hacerlo. Como mencioné anteriormente, durante la carrera he visto diferentes asignaturas relacionadas tanto con el análisis financiero como en las técnicas de business analytics, y una de las cosas que más me ha ayudado a organizar trabajos largos es empezar por unos objetivos claros. En este caso, el proyecto se centra en estudiar cómo ciertos datos financieros pueden ayudar a predecir si una empresa corre el riesgo de entrar en quiebra. Para responder a esta cuestión he establecido un objetivo general y varios objetivos específicos que guiarán todo el proceso.

Objetivo general

El objetivo general de este Trabajo Fin de Grado es analizar datos financieros de distintas empresas y construir un modelo predictivo que permita estimar su riesgo de quiebra, identificando qué variables tienen un papel más importante en este proceso y cómo esta información podría utilizarse para apoyar decisiones en contextos reales como banca, auditoría o inversión.

Este objetivo surge de mi interés para combinar los conocimientos adquiridos en la parte de ADE, con las herramientas de Business Analytics que he aprendido a lo largo del grado. Además, creo que desarrollar un modelo de este tipo me permitirá entender mejor cómo se relacionan determinadas cifras financieras con situaciones de riesgo empresarial y, al mismo tiempo, aplicar las metodologías que forman parte de los tres pilares del grado.

Objetivos específicos

Para poder alcanzar este objetivo general de forma ordenada, he dividido el trabajo en varios objetivos más concretos. Cada uno de ellos corresponde a una parte del análisis que considero necesaria para llegar a una conclusión sólida.

1. **Revisar y preparar el dataset**, analizando su estructura, el tipo de variables disponibles y el significado financiero de cada una de ellas. En este paso comprobaré si existen valores faltantes, variables que necesiten ser transformadas y posibles problemas que deban corregirse antes de empezar con los modelos. También justificaré por qué estos datos son adecuados para estudiar la quiebra empresarial.
2. **Realizar un análisis exploratorio (EDA)** para obtener una primera idea de cómo se comportan las empresas que quebraron en comparación con las que no lo hicieron. Este análisis inicial me ayudará a identificar patrones, outliers y relaciones entre variables, y servirá como base para elegir qué variables tienen más sentido incluir en los modelos.
3. **Construir al menos dos modelos predictivos diferentes**, empezando por una regresión logística por ser una de las herramientas más clásicas en estudios financieros, y comparándola después con un segundo modelo como un árbol de decisión o un random forest. La idea es ver si los modelos basados en técnicas más modernas ofrecen resultados significativamente mejores.
4. **Evaluar y comparar el rendimiento de los modelos** utilizando métricas adecuadas como precisión (accuracy), recall, matriz de confusión y la curva ROC-AUC. La intención es determinar qué modelo se ajusta mejor al tipo de datos utilizado y cuál sería más recomendable en un contexto real donde es importante detectar correctamente los casos de riesgo.
5. **Identificar los factores financieros más relevantes** en la predicción del riesgo de quiebra. Esto incluirá analizar la importancia de las variables en cada modelo y relacionar estos resultados con conceptos que he estudiado en asignaturas como análisis financiero o auditoría.
6. **Interpretar los resultados desde una perspectiva de negocio**, explicando cómo diferentes perfiles profesionales (por ejemplo, analistas de riesgo, auditores o inversores) podrían utilizar este tipo de modelos en su trabajo diario. El objetivo es que los resultados no se queden solo en la parte técnica, sino que también tengan una utilidad práctica.

METODOLOGÍA

En este apartado explico cómo voy a desarrollar el proyecto desde el punto de vista técnico y práctico. La idea es seguir un proceso ordenado que me permita, preparar bien los datos, luego construir los modelos, y por último interpretar los resultados desde una perspectiva de negocio. La metodología está basada en los tres pilares del grado: ingeniería del dato, análisis del dato y análisis de negocio.

Enfoque general del trabajo

Para responder a la pregunta de la investigación, seguiré un enfoque cuantitativo basado en el uso de datos financieros reales y en la aplicación de modelos predictivos. La metodología consiste en preparar el dataset elegido, analizarlo paso a paso y crear modelos que permitan estimar si una empresa está en riesgo de quiebra.

Este enfoque me permitirá combinar todo lo aprendido en asignaturas como contabilidad, auditoría... Con herramientas de análisis de datos vistas en otras asignaturas, especialmente con lenguaje de R y Python. La intención es que el proceso sea claro y aplicable, como si fuera un caso real que podría encontrarse en una empresa, un banco o una consultora.

Ingeniería del dato

En esta primera parte trabajaré con el dataset seleccionado, que será uno de los disponibles públicamente en el UCI Machine Learning Repository, como los mencionados *Polish Companies Bankruptcy Dataset* o el *Taiwan Bankruptcy Prediction Dataset*. Estos datasets contienen un conjunto amplio de ratios financieros e información contable de empresas que se clasifican en dos categorías: empresas que quebraron y empresas que no lo hicieron.

1. Revisión inicial del dataset: empezaré explorando la estructura de los datos, número de observaciones, variables incluidas y formato de cada columna. Veré si hay valores faltantes, outliers o inconsistencias que puedan afectar al análisis.
2. Limpieza y preparación de datos: después realizaré una limpieza básica, que incluirá lo siguiente:
    - Eliminar o imputar valores faltantes si los hay.
    - Escalar variables numéricas en caso de que sea necesario para los modelos.
    - Revisar si hay correlaciones muy altas entre variables.
    - Crear nuevas variables si durante el análisis exploratorio veo que podrían aportar valor.

3. Almacenamiento y organización: una vez preparados los datos, los almacenaré en un archivo estructurado (por ejemplo, CSV) para trabajar con ellos tanto en R como en Python. También dejaré una copia con los datos originales sin modificar, tal como pide la parte de ingeniería del dato del TFG.

Análisis del dato

Esta parte consistirá en estudiar los datos con más detalle y construir los modelos predictivos. Para ello seguiré varios pasos:

1. Análisis exploratorio (EDA): antes de construir modelos, quiero entender mejor cómo se comportan las empresas que quebraron frente a las que no. Para eso haré gráficos y resúmenes estadísticos básicos, centrándome en variables como liquidez, endeudamiento o rentabilidad. Este paso me ayudará a detectar patrones iniciales y a elegir las variables más relevantes.
2. Selección de variables relevantes: a partir del EDA veré qué variables pueden aportar más información al modelo. También tendré en cuenta criterios financieros, ya que muchas ratios tienen un significado claro (por ejemplo, un nivel de endeudamiento demasiado alto suele ser una señal de alerta).
3. Construcción de los modelos predictivos: crearé al menos dos modelos diferentes para comparar resultados:
    - **Modelo 1**: regresión logística (por ser el modelo clásico en estudios financieros).
    - **Modelo 2**: árbol de decisión o random forest (modelo más moderno y flexible).

    El objetivo es ver si los métodos tradicionales y los más modernos ofrecen diferencias en precisión y capacidad predictiva.

4. Evaluación y comparación de modelos: para comparar los modelos usaré métricas que ya he aprendido durante la carrera, como:
    - Accuracy
    - Recall
    - Matriz de confusión
    - ROC-AUC

Estas métricas me permitirán identificar qué modelo funciona mejor y cuál sería más útil en un entorno real donde es importante detectar correctamente los casos de riesgo.

Análisis de negocio

Una vez obtenidos los resultados de los modelos, la idea es interpretarlos desde un punto de vista empresarial. No me interesa únicamente cuál modelo predice mejor, sino también entender por qué algunas variables son importantes y qué significan sus valores en términos financieros.

En esta parte del trabajo relacionaré los resultados con decisiones reales que podrían tomar:

- Un banco al evaluar si concede un préstamo.
- Un auditor al identificar áreas con riesgo financiero.
- Un inversor al analizar si una empresa es una buena opción.
- Una empresa al revisar sus propios indicadores para evitar posibles problemas en el futuro.

El objetivo es conectar el análisis técnico con situaciones prácticas y explicar cómo este tipo de modelos puede ser una herramienta adicional de apoyo para profesionales del ámbito financiero y empresarial.

CRONOGRAMA

He diseñado un cronograma previsto para el desarrollo del Trabajo Fin de Grado. Teniendo en cuenta que comienzo el trabajo a partir de enero, que es cuando la universidad ya nos ha comunicado previamente la aceptación del proyecto, y asignado un tutor. Las fechas están alineadas con el calendario oficial del TFG, siguiendo las tutorías obligatorias con los profesores expertos de los tres pilares del grado y las entregas correspondientes.

A continuación, explicó las actividades previstas para cada mes:

Enero – Inicio del proyecto

- Revisión de la aceptación del anteproyecto.
- Asignación del tutor y primera reunión de orientación.
- Selección definitiva del dataset y planificación del trabajo.
- Elaboración del plan inicial de tareas para los meses siguientes

Febrero – Ingeniería del dato (parte l)

- Descarga y análisis inicial del dataset.
- Revisión de la estructura de los datos, tipo de variables y presencia de valores faltantes.
- Limpieza básica y preparación inicial del fichero de trabajo.
- Primera versión del dataset organizado.

Marzo – Ingeniería del dato (parte ll) y análisis exploratorio

- Revisión detallada de outliers, correlaciones y escalas.
- Preparación final del dataset para los modelos.
- Inicio del análisis exploratorio de datos (EDA) para comprender patrones básicos.
- Elaboración de gráficos y resúmenes estadísticos iniciales.

Abril – Modelización y tutoría oficial del pilar 1

- Tutoría obligatoria de ingeniería del dato.
- Construcción del primer modelo (regresión logística).
- Construcción del segundo modelo (árbol de decisión o random forest).
- Comparación inicial entre modelos y primeros ajustes.

Mayo (primera mitad) – Análisis del dato y análisis de negocio

- Tutoría del pilar 2 (análisis del dato).
- Revisión del rendimiento de los modelos y selección del mejor.
- Identificación de variables más relevantes y explicación de su impacto.
- Inicio del análisis de negocio a partir de los resultados obtenidos.

Mayo (segunda mitad) – Redacción de la memoria final

- Tutoría del pilar 3 (análisis de negocio).
- Redacción completa del documento final del TFG.
- Revisión de conclusiones, anexos y visualizaciones.
- Preparación para la entrega oficial.

Junio – Defensa del TFG

- Preparación de la presentación del TFG.
- Ensayo de la exposición oral.
- Defensa ante el tribunal en la convocatorio ordinaria.

Descripción del cronograma

He dividido el trabajo en fases mensuales para poder avanzar de forma ordenada y cumplir con las fechas oficiales de la universidad. Durante enero y febrero me centraré en preparar los datos y reunirme con mi tutor para asegurarme de que el enfoque es correcto. En marzo completaré la parte de ingeniería del dato y empezaré el análisis exploratorio, que servirá como bases para los modelos.

En abril construiré los modelos predictivos, ya que este mes coincide con la tutoría oficial de ingeniería del dato y del modelo analítico. Esto me permitirá comprobar si voy bien orientado y hacer los ajustes necesarios. En mayo realizaré la tutoría del pilar de análisis de negocio, revisaré los resultados y redactaré la memoria final del proyecto.

Por último, en junio prepararé la presentación para la defensa, teniendo en cuenta los tiempos y el formato requerido por la universidad.